学习笔记

博士期间学习笔记

不梦秋深

April 15, 2026

个人课程笔记，持续更新中

Contents

1 MIT 6.S184 学习笔记一: Flow Matching **6**

1.1 Flow Model . . . 7

1.1.1 ODE 的定义 . . . 7

1.1.2 模拟 ODE/数值解 . . . 8

1.1.3 Flow models . . . 8

1.2 构造训练目标 . . . 9

1.2.1 条件与边际概率路径 (Conditional and Marginal Probability Path) . . . 9

1.2.2 条件与边际向量场 (Conditional and Marginal Vector Fields) . . . 10

1.3 训练 . . . 11

2 Mean Flows 阅读笔记 **15**

2.1 Flow Matching . . . 15

2.2 MeanFlow Models . . . 15

2.2.1 MeanFlow 定义 . . . 16

2.2.2 MeanFlow 损失函数 . . . 16

2.2.3 Sampling . . . 16

2.3 一些其他细节 . . . 17

2.3.1 Stop-Gradient . . . 17

2.3.2 JVP . . . 17

3 MIT 6.S184 学习笔记二: SDE **19**

3.1 伊藤过程 (Itô Diffusion Process) . . . 19

3.1.1 物理背景: 从确定性到随机性 . . . 20

3.1.2 噪声的数学建模: 维纳过程 . . . 20

3.2 扩散模型 (Diffusion Model) . . . 20

3.2.1 模拟 SDE/数值解 . . . 21

3.2.2 Diffusion Models . . . 21

3.3 构造训练目标: Conditional and Marginal Score Functions . . . 22

3.4 定理 3.2 解释 . . . 23

3.4.1 ODE 与 SDE 的概率演化对比 . . . 23

3.4.2 如何让 SDE 的概率演化与 ODE 一致? . . . 24

3.4.3 直观理解 . . . 24

3.4.4 为什么得分函数 $\nabla \log p_t$ 能修正噪声? . . . 24

3.4.5 修正后的 SDE 与原始 ODE 具有相同概率演化的意义与优势 . . . 24

3.5 训练: 匹配得分 (Score Matching) . . . 25
3.6 时间反演 vs 求解 FP 方程 . . . 29
3.6.1 时间反演 . . . 29
3.6.2 SDE 的 ODE 概率流 (SDE 的 ODE 概率演化) . . . 30
3.7 小结 . . . 30

4 冷冻电镜学习笔记 32

4.1 TEM(Transmission Electron Microscope) 简介 . . . 32
4.1.1 核心物理原理 . . . 32
4.1.2 仪器构成与功能 . . . 32
4.1.3 主要操作模式与信息获取 . . . 33
4.1.4 样品制备 . . . 34
4.1.5 关键数学与公式 . . . 34
4.2 问题解答 . . . 35
4.2.1 冷冻电镜图像噪声来源 . . . 35
4.2.2 CTF(Contrast Transfer Function), 对比度传递函数 . . . 35
4.2.3 Thon 环 . . . 36
4.2.4 冷冻电镜处理过程 . . . 37
4.2.5 同质和异质 . . . 38
4.2.6 傅里叶切片定理 . . . 38
4.2.7 图像的相位操作与平移 . . . 40

5 傅里叶变换解析 42

5.1 向量空间 . . . 43
5.1.1 向量空间 . . . 43
5.1.2 内积与内积空间 . . . 45
5.1.3 希尔伯特空间 (Hilbert space) . . . 46
5.1.4 对偶 (Duality) . . . 47
5.1.5 算子, 特征值与特征向量 . . . 49
5.1.6 对 FT 的一些观察与猜想 . . . 51
5.2 连续 Parseval 框架 (Continuous Parseval Frame) . . . 52
5.3 装备希尔伯特空间 (rigged Hilbert space) . . . 52
5.3.1 装备希尔伯特空间 (rigged Hilbert space) . . . 53
5.3.2 Gelfand-Naimark-Maurin 定理 . . . 54
5.4 谱定理 (Spectral Theorem) . . . 55
5.4.1 有限维情形: 自伴算子的谱分解 . . . 55
5.4.2 无限维情形: 连续谱与谱测度 . . . 55
5.4.3 谱展开 . . . 55
5.5 总结 . . . 58

6 高斯泼溅算法简介 60

6.1 高斯泼溅简介 . . . 60
6.2 高斯椭球: 定义与性质 . . . 60
6.2.1 数学定义 . . . 61

6.2.2 光学属性建模 61
6.2.3 空间变换与投影 62
6.2.4 混合合成与渲染优化 62
6.3 高斯椭球的渲染技术 63
6.3.1 投影变换的数学推导 63
6.3.2 二维高斯分布的参数化 64
6.4 高斯泼溅示例 65
6.4.1 问题设定 65
6.4.2 坐标变换计算 66
6.4.3 权重计算 66
6.4.4 颜色计算 (一阶球谐函数) 67
6.4.5 最终像素颜色 68
7 深度学习的微分几何基础（一）：流形、切空间与黎曼度量 69
7.1 流形的定义与动机 69
7.1.1 直觉：局部平坦，全局弯曲 69
7.1.2 拓扑流形的严格定义 70
7.1.3 非 Hausdorff 空间的反例：带两个原点的实数轴 70
7.2 转移函数与光滑结构 70
7.2.1 转移函数的定义 71
7.2.2 完整的例子：S^1 是 1 维光滑流形 71
7.3 切空间 72
7.3.1 动机：如何在流形上定义方向 72
7.3.2 定义一：通过曲线的速度向量 72
7.3.3 定义二：导子 73
7.3.4 坐标基底与分量 73
7.4 坐标变换与切向量 74
7.4.1 推前映射 74
7.4.2 分量变换法则 75
7.4.3 转移函数导数的分解 75
7.4.4 基底与分量的反向变换 75
7.5 黎曼度量 76
7.5.1 定义 76
7.5.2 度量矩阵与各符号的含义 77
7.5.3 度量给出的几何量 77
7.5.4 拉回度量与 $G = J^T J$ 78
7.5.5 S^2 球坐标度量的推导 78
7.5.6 与深度学习的联系：Fisher 信息矩阵 79
8 深度学习的微分几何基础（二）：联络、测地线、曲率与微分形式 81
8.1 联络与协变导数 81
8.1.1 动机：为什么需要联络 81
8.1.2 偏导数为什么不够：极坐标中的例子 81
8.1.3 协变导数的直觉 82

8.1.4 仿射联络的严格定义 . . . 82
8.1.5 Christoffel 符号 . . . 83
8.1.6 极坐标中的验证 . . . 83
8.1.7 Levi-Civita 联络 . . . 84
8.1.8 S^2 上的 Christoffel 符号 . . . 85
8.1.9 平行移动 . . . 85
8.2 测地线 . . . 85
8.2.1 定义：弯曲空间中的“直线” . . . 86
8.2.2 测地线方程 . . . 86
8.2.3 在 S^2 上验证 . . . 87
8.2.4 测地线的等价定义：最短路径 . . . 87
8.2.5 指数映射 . . . 87
8.3 曲率 . . . 87
8.3.1 动机：平行移动的路径依赖性 . . . 88
8.3.2 曲率张量的定义 . . . 88
8.3.3 坐标公式 . . . 88
8.3.4 在 S^2 上计算 . . . 89
8.3.5 截面曲率 . . . 90
8.3.6 曲率的不同层次 . . . 90
8.3.7 曲率与平行移动旋转 . . . 91
8.4 流形上的微积分：微分形式 . . . 91
8.4.1 动机 . . . 91
8.4.2 1-形式：切向量的对偶 . . . 91
8.4.3 函数的微分 . . . 92
8.4.4 楔积与 2-形式 . . . 93
8.4.5 k-形式与体积形式 . . . 93
8.4.6 外导数 . . . 93
8.4.7 斯托克斯定理 . . . 94
8.5 总结：概念链条 . . . 95
9 深度学习的微分几何基础（三）：信息几何、流形优化、生成模型与几何深度学习 96
9.1 信息几何与自然梯度 . . . 96
9.1.1 动机 . . . 96
9.1.2 统计流形 . . . 97
9.1.3 Fisher 信息矩阵的定义 . . . 97
9.1.4 验证 Fisher 矩阵是黎曼度量 . . . 98
9.1.5 等价定义：用 Hessian 表示 . . . 98
9.1.6 高斯族的 Fisher 度量：完整计算 . . . 99
9.1.7 KL 散度与 Fisher 度量的关系 . . . 100
9.1.8 自然梯度 . . . 101
9.1.9 与优化器的联系 . . . 102
9.2 流形优化 . . . 103
9.2.1 动机与通用框架 . . . 104
9.2.2 Retraction . . . 104
9.2.3 Stiefel 流形 . . . 105

9.2.4 球面 S^{n-1} . . . 107
9.2.5 对称正定矩阵流形 . . . 107
9.2.6 向量传输 . . . 108
9.2.7 公式汇总 . . . 109
9.3 生成模型的几何视角 . . . 109
9.3.1 总览 . . . 110
9.3.2 Normalizing Flows . . . 110
9.3.3 连续 Normalizing Flows 与神经 ODE . . . 111
9.3.4 扩散模型 . . . 112
9.3.5 Flow Matching . . . 113
9.3.6 黎曼流形上的生成模型 . . . 113
9.3.7 模型对照 . . . 114
9.4 几何深度学习 . . . 114
9.4.1 核心思想 . . . 114
9.4.2 群与群作用 . . . 115
9.4.3 不变性与等变性 . . . 115
9.4.4 CNN = 平移等变网络 . . . 116
9.4.5 GNN = 置换等变网络 . . . 116
9.4.6 Transformer = 置换等变（无位置编码时） . . . 117
9.4.7 统一框架 . . . 118
9.4.8 与黎曼几何的联系 . . . 118
9.5 总结：从数学到深度学习的完整链条 . . . 118

MIT 6.S184 学习笔记一: Flow Matching

May 7, 2025

最近几年, 我们见证了生成式 AI 的快速崛起, 诸如 Stable Diffusion 等图像生成式模型可以从噪声生成出及其丰富多彩的图片. 从形似实拍的照片, 到动漫风的美术, 图片风格一应俱全. 这场 AI 革命的核心是: 生成事物的能力. 与过往用于预测的 AI 不同, 生成式 AI 具有更多的创造性: 生成式 AI 允许用户自定义输入, 并根据这些输入创造新的事物.

MIT Class 6.S184 课程 (https://diffusion.csail.mit.edu/) 主要教学目的是让同学们学会两个著名的生成式 AI 算法: flow matching 和 denoising diffusion models. 这两个模型是当前最好的生成式模型的骨架 (应用如 Stable Diffusion 3 和 Movie Gen Video), 而且在蛋白质结构预测上也有极好的应用 (如 AlphaFold3 是 diffusion model). 毫无疑问, 理解这些模型对我们来说是必要的.

所有的生成式模型都是逐渐从噪声转变为数据. 这个演化主要是由模拟 ODE 或 SDE 实现的. 我们利用神经网络来构造, 训练和模拟这些 ODE/SDE 的过程. 这些模型很容易实现, 但是其背后的数学机理却不那么容易理解. 这份笔记主要记录了理解 flow matching 和 denoising diffusion models 所必要的数学原理.

一些数学符号的意义:

- u: 向量场
- ψ: flow, ODE 的解
- p: 概率分布
- p_{data}: 目标分布
- p_{init}: 初始分布
- $\text{Unif} = \text{Unif}_{[0,1]}$

1.1 Flow Model

1.1.1 ODE 的定义

ODE 的解被 trajectory 所定义, 例如如下形式:

$$X : [0,1] \mapsto \mathbb{R}^d, t \mapsto X_t,$$

从时间 t 映射到 $\mathbb{R}^d$ 空间的某个位置. 每一个 ODE 被一个向量场 (vector field)u 所定义, 例如如下形式:

$$u : \mathbb{R}^d \times [0,1] \mapsto \mathbb{R}^d, (x,t) \mapsto u_t(x)$$

一个 ODE 定义了一条轨迹 (trajectory): 一条轨迹 X, 从 x_0 出发, 沿着向量场 u_t 前进. 我们利用如下方程的解来定义一条轨迹:

$$\frac{d}{dx} X_t = u_t(X_t), \qquad \text{ODE} \tag{1.1a}$$

$$X_0 = x_0, \qquad \text{initial conditions} \tag{1.1b}$$

公式3.7a要求 X_t 的导数直接由 u_t 提供, 公式1.1b要求我们在 $t = 0$ 时刻从 x_0 出发. 在 t 时刻, 我们所在的位置 X_t 由被称为流 (flow) 的函数定义, 也就是我们 ODE 得到解:

$$\psi : \mathbb{R}^d \times [0,1] \to \mathbb{R}^d, \quad (x_0, t) \mapsto \psi_t(x_0) \tag{1.2a}$$

$$\frac{d}{dt} \psi_t(x_0) = u_t(\psi_t(x_0)), \qquad \text{flow ODE} \tag{1.2b}$$

$$\psi_0(x_0) = x_0, \qquad \text{flow initial conditions} \tag{1.2c}$$

公国给定的初始条件 $X_0 = x_0$, 我们可以通过 $X_t = \psi_0(X_0)$ 恢复出一条 ODE 的轨迹. 因此, 向量场 (vector fields), ODEs, 和流 (flows) 的关系是:

- 向量场 (vector fields) 定义了 ODEs
- 流 (flows) 是 ODEs 的解

同时, 对于每一个 ODE, 都有解的存在性和唯一性问题, 若我们对 u_t 做一个弱的假设, 则有:

Theorem 1.1 (Flow existence and uniqueness)

If $u : \mathbb{R}^d \times [0,1] \to \mathbb{R}^d$ is continuously differentiable with a bounded derivative, then the ODE in 1.2 has a unique solution given by a flow ψ_t. Moreover, ψ_t is a **diffeomorphism** for all t, meaning ψ_t is continuously differentiable with a continuously differentiable inverse ψ_t^{-1}.
若 $u : \mathbb{R}^d \times [0,1] \to \mathbb{R}^d$ 连续可微且导数有界，则方程 1.2 的 ODE 存在唯一解，即流 ψ_t。此时，ψ_t 对所有 t 都是微分同胚（diffeomorphism），即 ψ_t 连续可微，且其逆映射 ψ_t^{-1} 也连续可微。

1.1.2 模拟 ODE/数值解

若 ψ_t 的解析解很难得出, 可以数值方法模拟 ODEs, 即求 ODEs 的数值解. 其中一个最简单也最直观的方法是欧拉法 (Euler method): 我们初始化 $X_0 = x_0$, 并通过下式更新:

$$X_{t+h} = X_t + hu_t(X_t), t = 0, h, 2h, 3h, \ldots, 1-h \tag{1.3}$$

其中 $h = 1/n, n \in \mathbb{N}$ 是一个超参数. 若想尝试更复杂的方法, 可以考虑 Heun's method:

$$X'_{t+h} = X_t + hu_t(X_t) \qquad \text{(初始猜测的新状态)} \tag{1.4a}$$

$$X_{t+h} = X_t + \frac{h}{2}\left(u_t(X_t) + u_{t+h}(X'_{t+h})\right) \qquad \text{(用当前和猜测状态的平均值更新)} \tag{1.4b}$$

1.1.3 Flow models

现在我们可以通过 ODE 来构建一个生成式模型. 我们的目标是将一个简单的分布 p_{init} 转变成一个复杂分布 p_{data}. 因此, 使用 ODE 来模拟这个转变的过程是一个很自然的选择. 一个 flow model 可以通过如下的 ODE 来描述:

$$X_0 \sim p_{\text{init}} \qquad \text{random initialization} \tag{1.5a}$$

$$\frac{d}{dt}X_t = u_t^\theta(X_t) \qquad \text{ODE} \tag{1.5b}$$

向量场 u_t^θ 是一个以 θ 为参数的神经网络. 对于现在来说, u_t^θ 就是一个通用的神经网络, 例如一个用有参数 θ 的连续的方程 $u_t^\theta : \mathbb{R}^d \times [0,1] \mapsto \mathbb{R}^d$. 具体的网络结构以后再讨论. 我们的目标是使得轨迹 (trajectory) 的终点 X_1 服从 p_{data} 的分布:

$$X_1 \sim p_{data} \Leftrightarrow \psi_1^\theta(X_0) \sim p_{data} \tag{1.6}$$

$\psi_t^\theta(X_0)$ 是由 u_t^θ 描述的流 (flow).

尽管我们现在叫做 flow model, 实际上**神经网络表征的是向量场, 而不是流 (flow)**. 为了计算流 (flow), 我们需要模拟 ODE 的过程. 在算法1中, 我们总结了 flow model 的采样方法.

Algorithm 1 Sampling from a Flow Model with Euler method

Require: Neural network vector field u_t^θ, number of steps n

```
Set t = 0
Set step size h = 1/n
Draw a sample X_0 ~ p_init
for i = 1, ..., n-1 do
    X_{t+h} = X_t + h u_t^θ(X_t)
    Update t ← t + h
end for
return X_1
```

1.2 构造训练目标

在上一节, 我们构造了服从轨迹 $(X_t)_{0\le t\le 1}$ 的 flow model, 其模拟的 ODE 为:

$$X_0 \sim p_{\text{init}}, \quad dX_t = u_t^\theta(X_t)dt \tag{1.7}$$

u_t^θ 是一个神经网络, 通过训练可以使得这个网络正确的模拟 ODE. 我们通过最小化损失函数 $\mathcal{L}(\theta)$ 来训练参数 θ, 例如 **MSE(mean-squared error)**:

$$\mathcal{L}(\theta) = \|u_t^\theta(x) - \underbrace{u_t^{\text{target}}(x)}_{\text{training target}}\|^2 \tag{1.8}$$

1.2.1 条件与边际概率路径 (Conditional and Marginal Probability Path)

构造 u_t^{target} 的第一步是确定一个**概率路径 (probability path)**. 一个概率路径确定了一条从噪声 p_{init} 到数据 p_{data} 的内插路径. 接下来, 对于数据点 $z \in \mathbb{R}^d$, 我们令其服从 δ_z Dirac delta 分布. 一个 **conditional (interpolating) probability path** 是指一组在 $\mathbb{R}^d$ 上, 服从分布 $p_t(x|z)$ 的集合:

$$p_0(\cdot|z) = p_{\text{init}}, \quad p_1(\cdot|z) = \delta_z \quad \text{for all } z \in \mathbb{R}^d \tag{1.9}$$

换言之, 条件概率路径 (conditional probability path) 逐渐将**一个**数据点 z 转变进分布 p_{init}. 由每个条件概率路径 (conditional probability path)$p_t(x|z)$ 可以推导出**边际概率路径 (marginal probability path)**$p_t(x)$:

$$z \sim p_{\text{data}}, \quad x \sim p_t(\cdot|z) \Rightarrow x \sim p_t, \quad \text{sampling from marginal path} \tag{1.10}$$

$$p_t(x) = \int p_t(x|z)p_{\text{data}}(z)\,dz, \quad \text{density of marginal path} \tag{1.11}$$

边际概率路径 (marginal probability path)p_t 是 p_{init} 到数据 p_{data} 的内插路径:

$$p_0 = p_{\text{init}} \quad \text{and} \quad p_1 = p_{\text{data}} \quad \text{(noise-data interpolation)} \tag{1.12}$$

Example (高斯概率路径 (Gaussian Conditional Probability Path))

高斯概率路径 (Gaussian probability path) 是一个特别流行的概率路径, 这也是 **denoising diffusion models 所使用的概率路径**. 设 α_t, β_t 是**噪声调度器 (noise schedulers)**：它们是两个连续可微的、单调的函数，满足 $\alpha_0 = \beta_1 = 0$ 和 $\alpha_1 = \beta_0 = 1$. 我们定义条件概率路径为:

$$p_t(\cdot|z) = \mathcal{N}(\alpha_t z, \beta_t^2 I) \quad \text{(高斯条件路径)} \tag{1.13}$$

根据我们对 α_t 和 β_t 的约束条件，这个路径满足:

$$p_0(\cdot|z) = \mathcal{N}(\alpha_0 z, \beta_0^2 I) = \mathcal{N}(0, I), \quad p_1(\cdot|z) = \mathcal{N}(\alpha_1 z, \beta_1^2 I) = \delta_z, \tag{1.14}$$

从边缘概率路径 p_t 中采样可得:

$$z \sim p_{\text{data}}, \quad x \sim p_t(\cdot|z) \Rightarrow x = \alpha_t z + \beta_t \epsilon \sim p_t \tag{1.15}$$

1.2.2 条件与边际向量场 (Conditional and Marginal Vector Fields)

基于前文定义的概率路径 p_t，我们现通过解析方法构建流模型的训练目标 u_t^{target}。该方法的核心在于：利用可解析推导 (derive analytically by hand) 的简单分量来构造该向量场。

Theorem 1.2 (Marginalization trick)

对于每个数据点 $z \in \mathbb{R}^d$，设 $u_t^{\text{target}}(\cdot|z)$ 表示一个条件向量场，使得对应的 ODE 产生条件概率路径 $p_t(\cdot|z)$，即：

$$X_0 \sim p_{\text{init}}, \quad \frac{d}{dt} X_t = u_t^{\text{target}}(X_t|z) \Rightarrow X_t \sim p_t(\cdot|z) \quad (0 \le t \le 1) \tag{1.16}$$

那么由下式定义的边缘向量场 $u_t^{\text{target}}(x)$：

$$u_t^{\text{target}}(x) = \int u_t^{\text{target}}(x|z) \frac{p_t(x|z) p_{\text{data}}(z)}{p_t(x)} dz \tag{1.17}$$

将遵循边缘概率路径，即：

$$X_0 \sim p_{\text{init}}, \quad \frac{d}{dt} X_t = u_t^{\text{target}}(X_t) \Rightarrow X_t \sim p_t \quad (0 \le t \le 1) \tag{1.18}$$

特别地，对于该 ODE 有 $X_1 \sim p_{\text{data}}$，因此可以说 "u_t^{target} 将噪声 p_{init} 转换为数据 p_{data}"。

Example (高斯概率路径的 target ODE)

如前所述，设 $p_t(\cdot|z) = \mathcal{N}(\alpha_t z, \beta_t^2 I_d)$，其中 α_t, β_t 是噪声调度器（参见式 (1.13)）。令 $\dot{\alpha}_t = \partial_t \alpha_t$ 和 $\dot{\beta}_t = \partial_t \beta_t$ 分别表示 α_t 和 β_t 的时间导数。这里，我们想要证明由下式给出的 *conditional Gaussian vector field*：

$$u_t^{\text{target}}(x|z) = \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t} \alpha_t \right) z + \frac{\dot{\beta}_t}{\beta_t} x \tag{1.19}$$

是定理1.2意义下的有效条件向量场：如果 $X_0 \sim \mathcal{N}(0, I_d)$，则其 ODE 轨迹 X_t 满足 $X_t \sim p_t(\cdot|z) = \mathcal{N}(\alpha_t z, \beta_t^2 I_d)$。

Proof. 首先我们通过定义构造一个条件流模型 $\psi_t^{\text{target}}(x|z)$：

$$\psi_t^{\text{target}}(x|z) = \alpha_t z + \beta_t x \tag{1.20}$$

如果 X_t 是 $\psi_t^{\text{target}}(\cdot|z)$ 的 ODE 轨迹且 $X_0 \sim p_{\text{init}} = \mathcal{N}(0, I_d)$，那么根据定义：

$$X_t = \psi_t^{\text{target}}(X_0|z) = \alpha_t z + \beta_t X_0 \sim \mathcal{N}(\alpha_t z, \beta_t^2 I_d) = p_t(\cdot|z) \tag{1.21}$$

我们得出结论：轨迹的分布与条件概率路径相同（即满足式 (18)）。剩下的工作是从 $\psi_t^{\text{target}}(x|z)$ 中提取向量场 $u_t^{\text{target}}(x|z)$。根据流的定义 (式1.2)，对于所有 $x, z \in \mathbb{R}^d$ 有：

$$\frac{d}{dt}\psi_t^{\text{target}}(x|z) = u_t^{\text{target}}(\psi_t^{\text{target}}(x|z)|z) \quad \text{对所有} x, z \in \mathbb{R}^d \tag{1.22}$$

$$\overset{(i)}{\Leftrightarrow} \dot{\alpha}_t z + \dot{\beta}_t x = u_t^{\text{target}}(\alpha_t z + \beta_t x|z) \quad \text{对所有} x, z \in \mathbb{R}^d \tag{1.23}$$

$$\overset{(ii)}{\Leftrightarrow} \dot{\alpha}_t z + \dot{\beta}_t \left(\frac{x - \alpha_t z}{\beta_t}\right) = u_t^{\text{target}}(x|z) \quad \text{对所有} x, z \in \mathbb{R}^d \tag{1.24}$$

$$\overset{(iii)}{\Leftrightarrow} \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t}\alpha_t\right) z + \frac{\dot{\beta}_t}{\beta_t} x = u_t^{\text{target}}(x|z) \quad \text{对所有} x, z \in \mathbb{R}^d \tag{1.25}$$

其中在 (i) 中我们使用了 $\psi_t^{\text{target}}(x|z)$ 的定义（式 (1.20)），在 (ii) 中我们进行了变量替换 $x \to (x - \alpha_t z)/\beta_t$，在 (iii) 中我们只是做了一些代数运算. 注意最后一个等式正是我们在式 (1.19) 中定义的条件高斯向量场.

证毕. ■

Theorem 1.3 (连续性方程)

考虑一个具有向量场 u_t^{target} 且 $X_0 \sim p_{\text{init}}$ 的流模型。那么对于所有 $0 \le t \le 1$ 有 $X_t \sim p_t$ 当且仅当满足连续性方程：

$$\partial_t p_t(x) = -\text{div}(p_t u_t^{\text{target}})(x) \quad \text{对所有} x \in \mathbb{R}^d, 0 \le t \le 1 \tag{1.26}$$

其中 $\partial_t p_t(x) = \frac{d}{dt} p_t(x)$ 表示 $p_t(x)$ 的时间导数。方程1.26被称为连续性方程。

1.3 训练

前两节我们如何通过神经网络给定的向量场 u_t^θ 构造生成式模型, 还展示了训练目标 u_t^{target} 的形式, 这一节我们将展示如何使用 u_t^θ 来逼近 u_t^{target}.

Flow matching loss 被定义为:

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t\sim\text{Unif}, x\sim p_t}\left[\|u_t^\theta(x) - u_t^{\text{target}}(x)\|^2\right] \tag{1.27}$$

通过使用式1.10的采样过程，我们可以将公式1.27重写为：

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t\sim\text{Unif}, z\sim p_{\text{data}}, x\sim p_t(\cdot|z)}\left[\|u_t^\theta(x) - u_t^{\text{target}}(x)\|^2\right] \tag{1.28}$$

这两个形式是等价的，因为边际概率路径 $p_t(x)$ 可以表示为：$p_t(x) = \int p_t(x|z)p_{\text{data}}(z)dz$. 通过定理1.2可知 u_t^{target}:

$$u_t^{\text{target}}(x) = \int u_t^{\text{target}}(x|z)\frac{p_t(x|z)p_{\text{data}}(z)}{p_t(x)}dz \tag{1.29}$$

因为上述积分不可处理, 我们转而使用好处理的条件向量场 $u_t^{\text{target}}(x|z)$. 首先, 我们定义 **Condi-**

tional Flow Matching loss:

$$\mathcal{L}_{\mathrm{CFM}}(\theta) = \mathbb{E}_{t\sim\mathcal{U}(0,1), z\sim p_{\mathrm{data}}, x\sim p_t(\cdot|z)}\left[\|u_t^\theta(x) - u_t^{\mathrm{target}}(x|z)\|^2\right] \tag{1.30}$$

Theorem 1.4

Marginal Flow Matching loss 等于 Conditional Flow Matching loss 加一个常数:

$$\mathcal{L}_{\mathrm{FM}}(\theta) = \mathcal{L}_{\mathrm{CFM}}(\theta) + C \tag{1.31}$$

C 与 θ 无关, 也就是说:

$$\nabla_\theta \mathcal{L}_{\mathrm{FM}}(\theta) = \nabla_\theta \mathcal{L}_{\mathrm{CFM}}(\theta) \tag{1.32}$$

因此, 最小化 $\mathcal{L}_{\mathrm{FM}}(\theta)$ 就是最小化 $\mathcal{L}_{\mathrm{CFM}}(\theta)$

Proof.

$$\begin{aligned}
\mathcal{L}_{\mathrm{FM}}(\theta) &\overset{(i)}{=} \mathbb{E}_{t\sim\mathrm{Unif}, x\sim p_t}\left[\|u_t^\theta(x) - u_t^{\mathrm{target}}(x)\|^2\right] \\
&\overset{(ii)}{=} \mathbb{E}_{t\sim\mathrm{Unif}, x\sim p_t}\left[\|u_t^\theta(x)\|^2 - 2u_t^\theta(x)^T u_t^{\mathrm{target}}(x) + \|u_t^{\mathrm{target}}(x)\|^2\right] \\
&\overset{(iii)}{=} \mathbb{E}_{t\sim\mathrm{Unif}, x\sim p_t}\left[\|u_t^\theta(x)\|^2\right] - 2\mathbb{E}_{t\sim\mathrm{Unif}, x\sim p_t}\left[u_t^\theta(x)^T u_t^{\mathrm{target}}(x)\right] + \underbrace{\mathbb{E}_{t\sim\mathrm{Unif}, x\sim p_t}\left[\|u_t^{\mathrm{target}}(x)\|^2\right]}_{=:C_1} \\
&\overset{(iv)}{=} \mathbb{E}_{t\sim\mathrm{Unif}, z\sim p_{\mathrm{data}}, x\sim p_t(\cdot|z)}\left[\|u_t^\theta(x)\|^2\right] - 2\mathbb{E}_{t\sim\mathrm{Unif}, x\sim p_t}\left[u_t^\theta(x)^T u_t^{\mathrm{target}}(x)\right] + C_1
\end{aligned}$$

其中 (i) 就是定义, (ii) 就是 $\|a-b\|^2 = \|a\|^2 - 2ab + \|b\|^2$, (iii) 我们定义了一个常数 C_1, 最后在 (iv) 我们使用了式1.10的采样过程得到 p_t. 对第二项继续展开:

$$\begin{aligned}
\mathbb{E}_{t\sim\mathrm{Unif}, x\sim p_t}\left[u_t^\theta(x)^T u_t^{\mathrm{target}}(x)\right] &\overset{(i)}{=} \int_0^1 \int p_t(x) u_t^\theta(x)^T u_t^{\mathrm{target}}(x)\, dx\, dt \\
&\overset{(ii)}{=} \int_0^1 \int p_t(x) u_t^\theta(x)^T \left(\int u_t^{\mathrm{target}}(x|z) \frac{p_t(x|z) p_{\mathrm{data}}(z)}{p_t(x)}\, dz\right) dx\, dt \\
&\overset{(iii)}{=} \int_0^1 \int \int u_t^\theta(x)^T u_t^{\mathrm{target}}(x|z) p_t(x|z) p_{\mathrm{data}}(z)\, dz\, dx\, dt \\
&\overset{(iv)}{=} \mathbb{E}_{t\sim\mathrm{Unif}, z\sim p_{\mathrm{data}}, x\sim p_t(\cdot|z)}\left[u_t^\theta(x)^T u_t^{\mathrm{target}}(x|z)\right]
\end{aligned}$$

(i) 我们使用积分展开, (ii) 我们使用了公式1.17, (iii) 普通乘法, 最后用 (iv) 我们将公式表示为期望的形式. 在证明一开始我们使用了 marginal vector field $u_t^{\mathrm{target}}(x)$, 而现在我们使用了 conditional

vector field $u_t^{\text{target}}(x|z)$, 我们将其代入 $\mathcal{L}_{\text{FM}}$:

$$
\begin{aligned}
\mathcal{L}_{\text{FM}}(\theta) &\overset{(i)}{=} \mathbb{E}_{t\sim\text{Unif},z\sim p_{\text{data}},x\sim p_t(\cdot|z)}\left[\|u_t^\theta(x)\|^2\right] - 2\mathbb{E}_{t\sim\text{Unif},z\sim p_{\text{data}},x\sim p_t(\cdot|z)}\left[u_t^\theta(x)^T u_t^{\text{target}}(x|z)\right] + C_1 \\
&\overset{(ii)}{=} \mathbb{E}_{t\sim\text{Unif},z\sim p_{\text{data}},x\sim p_t(\cdot|z)}\left[\|u_t^\theta(x)\|^2 - 2u_t^\theta(x)^T u_t^{\text{target}}(x|z) + \|u_t^{\text{target}}(x|z)\|^2 - \|u_t^{\text{target}}(x|z)\|^2\right] + C_1 \\
&\overset{(iii)}{=} \mathbb{E}_{t\sim\text{Unif},z\sim p_{\text{data}},x\sim p_t(\cdot|z)}\left[\|u_t^\theta(x) - u_t^{\text{target}}(x|z)\|^2\right] + \underbrace{\mathbb{E}_{t\sim\text{Unif},z\sim p_{\text{data}},x\sim p_t(\cdot|z)}\left[-\|u_t^{\text{target}}(x|z)\|^2\right]}_{C_2} + C_1 \\
&\overset{(iv)}{=} L_{\text{CFM}}(\theta) + \underbrace{C_2 + C_1}_{=:C}
\end{aligned}
$$

(i) 利用上式替换, (ii) 从 0 中裂项, (iii) 再次使用公式 $\|a-b\|^2 = \|a\|^2 - 2a^Tb + \|b\|^2$, 最后在 (iv) 我们定义了一个与 θ 无关的常数.

证毕. ■

一旦我们得到训练好的 u_t^θ, 我们可以模拟流模型 (flow model):

$$
dX_t = u_t^\theta(X_t)\,dt, \quad X_0 \sim p_{\text{init}} \tag{1.33}
$$

通过算法1我们可以采样得出 $X_1 \sim p_{\text{data}}$, 通过算法2我们可以训练出 u_t^θ

Algorithm 2 Flow Matching Training Procedure (for Gaussian CondOT path $p_t(x|z) = \mathcal{N}(tz, (1-t)^2)$)

Require: A dataset of samples $z \sim p_{\text{data}}$, neural network u_t^θ

for each mini-batch of data **do**
  Sample a data example z from the dataset.
  Sample a random time $t \sim \text{Unif}[0,1]$.
  Sample noise $\epsilon \sim \mathcal{N}(0, I_d)$.
  Set $x = tz + (1-t)\epsilon$ (General case: $x \sim p_t(\cdot|z)$)
  Compute loss

$$
\mathcal{L}(\theta) = \|u_t^\theta(x) - (z-\epsilon)\|, \quad (\text{General case} := \|u_t^\theta(x) - u_t^{\text{target}}(x|z)\|^2)
$$

  Update the model parameters θ via gradient descent on $L(\theta)$.
end for

Example (Flow Matching for Gaussian Conditional Probability Paths)

让我们回到高斯条件概率路径 $p_t(\cdot|z) = \mathcal{N}(\alpha_t z; \beta_t^2 I_d)$ 的例子，其中我们可以通过以下方式从条件路径中采样：

$$
\epsilon \sim \mathcal{N}(0, I_d) \quad \Rightarrow \quad x_t = \alpha_t z + \beta_t \epsilon \sim \mathcal{N}(\alpha_t z, \beta_t^2 I_d) = p_t(\cdot|z). \tag{1.34}
$$

正如我们在公式1.25中推导的那样，条件向量场 $u^t_{\text{target}}(x|z)$ 由下式给出：

$$u_t^{\text{target}}(x|z) = \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t}\alpha_t\right) z + \frac{\dot{\beta}_t}{\beta_t} x, \tag{1.35}$$

其中 $\dot{\alpha}_t = \frac{d\alpha_t}{dt}$ 和 $\dot{\beta}_t = \frac{d\beta_t}{dt}$ 分别是 α_t 和 β_t 的时间导数。将这个公式代入，条件流匹配损失为：

$$\begin{aligned}\mathcal{L}_{\text{CFM}}(\theta) &= \mathbb{E}_{t\sim\text{Unif},z\sim p_{\text{data}},x\sim\mathcal{N}(\alpha_t z,\beta_t^2 I_d)}\left[\|u_t^\theta(x) - \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t}\alpha_t\right) z - \frac{\dot{\beta}_t}{\beta_t} x\|^2\right] \\ &\overset{(i)}{=} \mathbb{E}_{t\sim\text{Unif},z\sim p_{\text{data}},\epsilon\sim\mathcal{N}(0,I_d)}\left[\|u_t^\theta(\alpha_t z + \beta_t\epsilon) - (\dot{\alpha}_t z + \dot{\beta}_t\epsilon)\|^2\right]\end{aligned}$$

在 (i) 中，利用公式1.34, 替换 x 为 $\alpha_t z + \beta_t\epsilon$.$\mathcal{L}_{\text{CFM}}$ 非常简洁：我们只需要采样一个数据点 z，再采样一些噪声 ϵ，然后计算均方误差即可. 在 $\alpha_t = t$ 和 $\beta_t = 1 - t$ 的特殊情况下，对应的概率 $p_t(x|z) = \mathcal{N}(tz, (1-t)^2)$ 有时被称为 (高斯)CondOT 概率路径。那么我们有 $\dot{\alpha}_t = 1$ 和 $\dot{\beta}_t = -1$，因此：

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t\sim\text{Unif},z\sim p_{\text{data}},\epsilon\sim\mathcal{N}(0,I_d)}\left[\|u_t^\theta(tz + (1-t)\epsilon) - (z - \epsilon)\|^2\right].$$

许多著名的最先进的模型都是通过这种简单而有效的程序训练的，例如 Stable Diffusion 3、Meta 的 Movie Gen Video, 以及许多其他专有模型。我们在算法2中总结了训练过程。

Mean Flows 阅读笔记

May 24, 2025

5 月 19 日, Kaiming 团队在 arxiv 上提交了论文 “Mean Flows for One-step Generative Modeling”, 提出了 Mean Flows 方法. Flow Matching 构建了两个分布的一个微分过程, 并通过逐步采样的方式实现分布之间的转移, 但有着推断时间过长的问题. 为了解决这个问题, Kaiming 团队构建了这样一个微分过程的平均过程, 名为 Mean Flows.

本章的符号表示与第1章不同, 采用 Mean Flows 论文中相同的符号表示.

2.1 Flow Matching

取 $x \sim p_{\text{data}}(x)$, $\epsilon \sim p_{\text{prior}}(\epsilon)$($p_{\text{prior}}$ 就是 p_{init}, 例如噪声), 在时间步骤 t 下, 流过程可以表示为 $z_t = a_t x + b_t \epsilon$, a_t, b_t 是 schedules. 其速度 v_t 可以表示为 $v_t = z_t' = a_t' x + b_t' \epsilon$($'$ 代表对时间的导数). 一个常用的 schedule 是 $a_t = 1 - t$, $b_t = t$, 在这个条件下, $v_t = \epsilon - x$.

构建微分过程:

$$\frac{d}{dt} z_t = v(z_t, t) \tag{2.1}$$

从 $z_1 = \epsilon \sim p_{\text{prior}}$ 开始, 其解可以被写成 $z_r = z_t - \int_r^t v(z_\tau, \tau)\, d\tau$, 其中 r 是另一个时间步.

Flow Matching loss $\mathcal{L}_{\text{FM}}(\theta)$ 被定义为:

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t, p_t(z_t)} \| v_\theta(z_t, t) - v(z_t, t) \|^2 \tag{2.2}$$

Conditional Flow Matching loss $\mathcal{L}_{\text{CFM}}(\theta)$ 被定义为:

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, x, \epsilon} \| v_\theta(z_t, t) - v(z_t | x) \|^2 \tag{2.3}$$

$\mathcal{L}_{\text{FM}}$ 与 $\mathcal{L}_{\text{CFM}}$ 只差一个常数.

更详细的内容见第1章.

2.2 MeanFlow Models

2.2.1 MeanFlow 定义

定义时间步 t 和 r 之间速度场的平均值 u 为:

$$u(z_t, r, t) \triangleq \frac{1}{t-r}\int_r^t v(z_\tau, \tau)d\tau \tag{2.4}$$

即:

$$(t-r)u(z_t, r, t) = \int_r^t v(z_\tau, \tau)d\tau \tag{2.5}$$

接下来先做一些数学变换. 两边同时求导得:

$$\frac{d}{dt}\left((t-r)u(z_t, r, t)\right) = \frac{d}{dt}\int_r^t v(z_\tau, \tau)d\tau \quad \Rightarrow \quad u(z_t, r, t) + (t-r)\frac{d}{dt}u(z_t, r, t) = v(z_t, t), \tag{2.6}$$

将上式重排得:

$$\boxed{\underbrace{u(z_t, r, t)}_{\text{Average velocity}} = \underbrace{v(z_t, t)}_{\text{Instant velocity}} - (t-r)\underbrace{\frac{d}{dt}u(z_t, r, t)}_{\text{Time derivative of } u}} \tag{2.7}$$

公式2.7即为 Mean Flows 的定义. 对公式2.7两边继续求导:

$$\frac{d}{dt}u(z_t, r, t) = \underbrace{\frac{dz_t}{dt}\frac{\partial u}{\partial z}}_{\text{JVP with } v} + \underbrace{\frac{dr}{dt}\frac{\partial u}{\partial r}}_{=0} + \underbrace{\frac{dt}{dt}\frac{\partial u}{\partial t}}_{=\partial_t u} \tag{2.8}$$

也就是说:

$$\boxed{\tfrac{d}{dt}u(z_t, r, t) = v(z_t, t)\tfrac{\partial u}{\partial z} + \tfrac{\partial u}{\partial t}} \tag{2.9}$$

2.2.2 MeanFlow 损失函数

对于参数化网络 u_θ 来说, 损失函数定义为:

$$\mathcal{L}(\theta) = \mathbb{E}\left\|u_\theta(z_t, r, t) - \mathrm{sg}(u_{\mathrm{tgt}})\right\|_2^2, \tag{2.10}$$

$$\text{其中} \quad u_{\mathrm{tgt}} = v_t - (t-r)\left(v_t\frac{\partial u_\theta}{\partial z} + \frac{\partial u_\theta}{\partial t}\right) \tag{2.11}$$

公式2.9带入公式2.7得到公式2.11. sg 代表 stop-gradient.

2.2.3 Sampling

将公式2.1的解写成平均值的形式:

$$z_r = z_t - (t-r)u(z_t, r, t) \tag{2.12}$$

一步采样 (1-step sampling) 为:$z_0 = z_1 - u(z_1, 0, 1)$. $z_1 = \epsilon \sim p_{\mathrm{prior}}(\epsilon)$

2.3 一些其他细节

本节内容主要由 DeepSeek 生成.

2.3.1 Stop-Gradient

Stop-Gradient 的数学定义

符号表示：通常记为 $\mathrm{sg}(\cdot)$ 或 detach()（在 PyTorch 中）。
数学行为：对任意变量 x，有：

$$\mathrm{sg}(x) = x \quad \text{（前向传播时）} \tag{2.13}$$

$$\frac{\partial \mathrm{sg}(x)}{\partial \theta} = 0 \quad \text{（反向传播时）} \tag{2.14}$$

即，前向传播时保留原值，反向传播时梯度为零。

在 MeanFlow 中的具体作用

在论文的式2.10和式 2.11 中，Stop-Gradient 用于训练目标 u_{tgt}.
为什么需要 Stop-Gradient?

1. **避免高阶导数：** u_{tgt} 中已经包含 u_θ 的导数项（如 $\frac{\partial u_\theta}{\partial z}$）。如果不对 u_{tgt} 停梯度，损失函数会需要对 u_θ 求二阶导数（即 $\frac{\partial^2 u_\theta}{\partial \theta \partial z}$），计算复杂且不稳定。
2. **固定目标值：** 停梯度将 u_{tgt} 视为一个常数目标，仅让 u_θ 去拟合它，而不是动态调整 u_{tgt} 本身。这类似于强化学习中的“固定目标网络”技术。
3. **理论一致性：** MeanFlow 的推导（式 2.7）要求 u_{tgt} 是理论计算值，而非可学习的变量。停梯度强制模型遵守这一约束。

2.3.2 JVP

在本论文中, 给定一个函数 $u_\theta(z_t, r, t)$，其雅可比矩阵 J 包含所有偏导数：

$$J = \begin{pmatrix} \frac{\partial u}{\partial z} & \frac{\partial u}{\partial r} & \frac{\partial u}{\partial t} \end{pmatrix} \tag{2.15}$$

JVP 计算的是雅可比矩阵 J 与一个向量 $\mathbf{v} = (v, 0, 1)$ 的乘积：

$$J \cdot \mathbf{v} = \frac{\partial u}{\partial z} v + \frac{\partial u}{\partial r} \cdot 0 + \frac{\partial u}{\partial t} \cdot 1 = v \frac{\partial u}{\partial z} + \frac{\partial u}{\partial t} \tag{2.16}$$

这正是论文中式 2.8 和式 2.11的推导结果。
为什么使用 JVP?

1. **避免显式构造雅可比矩阵：** 雅可比矩阵的显式存储需要 $O(n^2)$ 内存（n 是输出维度），而 JVP 通过一次前向和反向传播直接计算乘积，内存效率为 $O(n)$。

2. **支持停梯度（Stop-Gradient）：**在式 (9) 的损失函数中，u_{tgt} 的导数项（通过 JVP 计算）被设为常数（detach()），避免高阶导数计算。

3. **与 Flow Matching 的兼容性：**传统 Flow Matching 只需计算 $v(z_t, t)$，而 MeanFlow 通过 JVP 引入对 u_θ 的导数约束，实现单步生成。

与其他自动微分操作的对比:

操作	计算模式	适用场景	内存开销
JVP	前向模式	计算“函数输出对某一输入的导数”	$O(n)$
反向传播（VJP）	反向模式	计算“标量损失对大量参数的梯度”	$O(m)$
全雅可比矩阵	显式构造	需要完整导数矩阵（如二阶优化）	$O(n^2)$

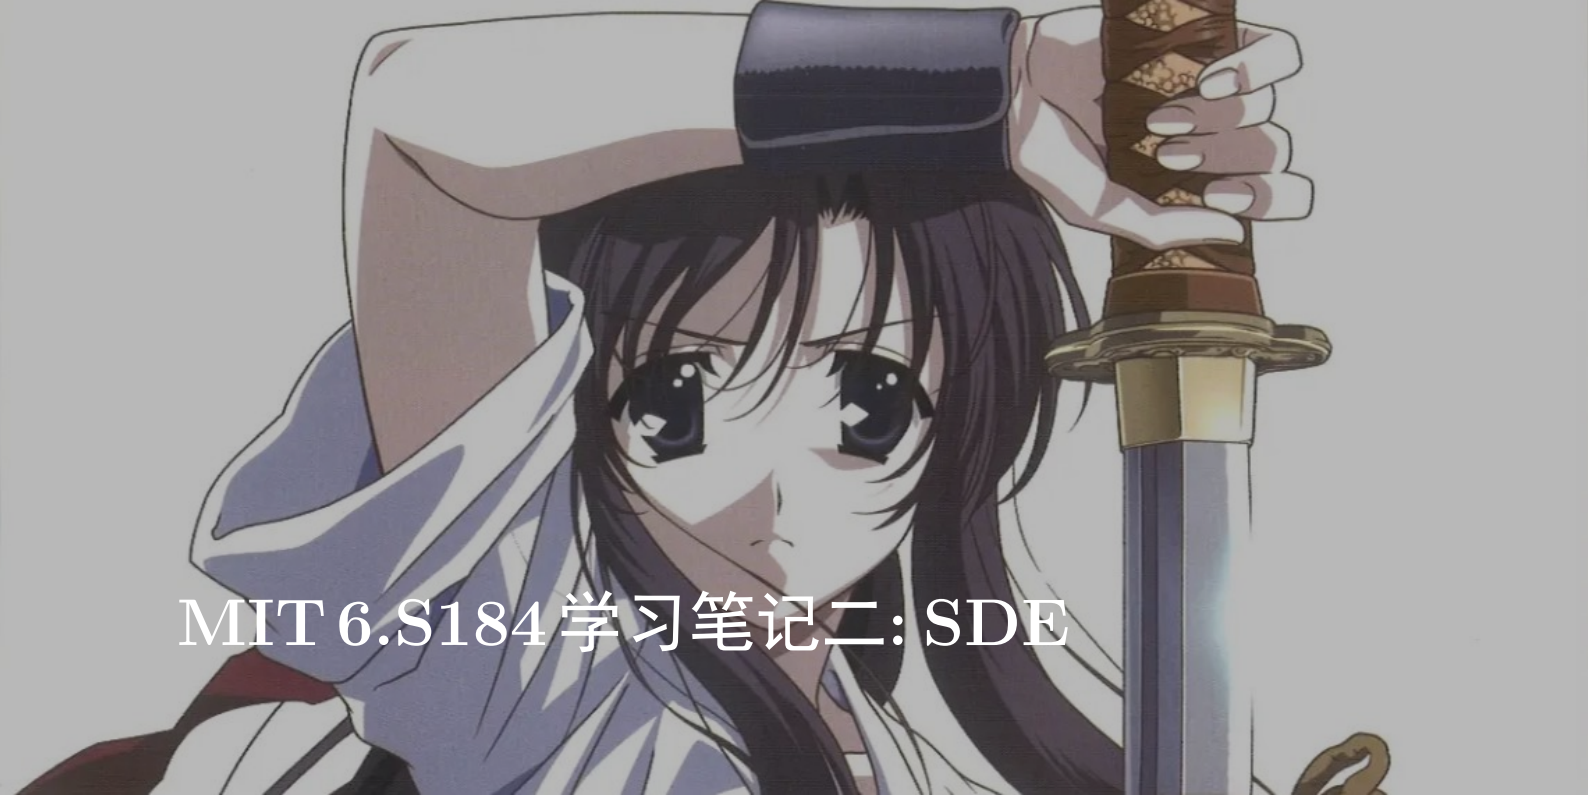

MIT 6.S184 学习笔记二: SDE

May 25, 2025

「選べない……どっちも欲しい」[1]

——《School Days》

近年来, 生成式模型在人工智能领域掀起了一场静默的革命. 从 GAN 的对抗博弈到 Flow 模型的精确可逆, 研究者们不断探索数据生成的本质规律. 而在这条技术演进的路径上, 扩散模型 (Diffusion Model) 名声大噪, DDPM (Denoising Diffusion Probabilistic Model) 为 LDM(Latent Diffusion Models) 以及后续 Stable Diffusion 模型的出现打下了坚实的基础, 但其数学理论未触及本质. Song 提出的 SDE(Stochastic Differential Equation) 为扩散过程提供了坚实的数学框架, 将数据的逐步噪声化与生成视为连续时间的随机过程. Song 的理论不仅解释了扩散模型的本质, 更在图像生成、音频合成等领域实现了超越原有方法的逼真效果.

在 DDPM 原文中,Ho 构建了一个马尔科夫过程 (Forward process 和 Reverse process) 来实现两个数据分布之间转换. 而在 SDE 的视角下,DDPM 的前向过程 (Forward process) 仅为 SDE 的高斯概率路径演化的一种特殊情况. 在 Song 的原文中, 使用了 SDE 时间反演的技巧, 虽然可以这么做, 但略显麻烦. 在本文中, 我们构造 SDE, 使其与 ODE 有相同的概率路径演化, 形式上与 ODE(Flow Matching) 的过程保持一致 (Flow Matching 详见第1章).

本文将侧重 SDE 的数学理论, 主要参考资料为 MIT Class 6.S184 课程, 网址为https://diffusion.csail.mit.edu/.

3.1 伊藤过程 (Itô Diffusion Process)

伊藤过程的 SDE(Stochastic Differential Equations) 的构建源于对物理、金融等领域中随机动力学系统的数学建模需求. 其核心思想是将确定性微分方程 (ODE) 与随机噪声 (维纳过程) 结合, 以描述受随机扰动影响的系统演化. 以下是其来源与推导的逐步解析:

[1]“无法选择……我全都要”. 在随机微分方程的世界里, 路径的选择往往和某著名伊藤氏的人生一样, 充满不可逆的纠结

3.1.1 物理背景: 从确定性到随机性

经典动力学方程

确定性系统通常用常微分方程 (ODE) 描述:

$$\frac{dX_t}{dt} = \mu(X_t, t) \tag{3.1}$$

其中 $\mu(X_t, t)$ 为确定性漂移项 (如速度场).

引入随机扰动

在实际系统中, 噪声和不确定性是普遍存在的. 为了更好地描述这些现象, 我们引入了随机扰动项: 当系统受微观随机扰动 (如分子碰撞、市场波动) 时, 需在方程中加入噪声项:

$$\frac{dX_t}{dt} = \mu(X_t, t) + \sigma(X_t, t) \cdot \text{噪声}, \tag{3.2}$$

其中 $\sigma(X_t, t)$ 控制噪声强度.
关键问题: 如何数学上严格定义“噪声”?

3.1.2 噪声的数学建模: 维纳过程

白噪声与维纳过程

理想白噪声 $\xi(t)$: 均值为零, 瞬时相关 $\langle \xi(t)\xi(t') \rangle = \delta(t - t')$, 但数学上难以直接处理.
维纳过程 W_t: 白噪声的积分 $W_t = \int_0^t \xi(s)ds$ 是数学上良好的定义, 满足:

- $W_0 = 0$, 初始值为零.
- 增量 $\Delta W_t = W_{t+\Delta t} - W_t$ 服从正态分布:$\Delta W_t \sim \mathcal{N}(0, \Delta t)$, 均值为零, 方差为 Δt.
- 增量独立性: 对于任意不重叠的时间区间, 增量相互独立.

随机微分方程的启发式形式

将噪声替换为维纳过程的微分 dW_t:

$$dX_t = \mu(X_t, t)dt + \sigma(X_t, t)dW_t \tag{3.3}$$

注意: dW_t 并非经典微分, 需通过积分严格定义.

3.2 扩散模型 (Diffusion Model)

在 Diffusion Model 中, 我们可以使用如下 SDE 来表示:

$$dX_t = u_t(X_t)dt + \sigma_t dW_t, \qquad \text{SDE} \tag{3.4a}$$

$$X_0 = x_0, \qquad \text{initial conditions} \tag{3.4b}$$

与 ODE 不同的是, 不存在一个流映射 (flow map) 来表示 SDE 的解[2]. 由于 SDE 的演化过程是随机的, 所以 X_t 不再是由 $X_0 \sim p_{\text{init}}$ 所唯一决定的.

对于 SDE 的轨迹 (trajectory)$(X_t)_{0\le t\le 1}$ 来说[3], 一个小的 step 的方向来自于布朗运动加上 $u_t(X_t)$ 方向:

$$X_{t+h} = X_t + \underbrace{hu_t(X_t)}_{\text{deterministic}} + \sigma_t \underbrace{W_{t+h} - W_t}_{\text{stochastic}} + \underbrace{hR_t(h)}_{\text{error term}} \tag{3.5}$$

其中 $\sigma_t \ge 0$ 是扩散系数 (diffusion coefficient), $R_t(h)$ 描述的随机误差项满足 $\mathbb{E}[\|R_t(h)\|^2]^{1/2} \to 0$(当 $h \to 0$).

当然, 类似于 ODE, 我们有:

Theorem 3.1 (SDE 解的存在唯一性定理 (SDE Solution Existence and Uniqueness))

If $u : \mathbb{R}^d \times [0,1] \to \mathbb{R}^d$ is continuously differentiable with a bounded derivative and σ_t is continuous, then the SDE in (7) has a solution given by the unique stochastic process $(X_t)_{0\le t\le 1}$ satisfying eq. 3.5.

如果 $u : \mathbb{R}^d \times [0,1] \to \mathbb{R}^d$ 连续可微且有界导数, 且 σ_t 连续, 那么方程 (7) 中的 SDE 存在解, 且由满足方程3.5的唯一随机过程 $(X_t)_{0\le t\le 1}$ 给出.

3.2.1 模拟 SDE/数值解

寻求 SDE 数值解最简单的方法是**欧拉-丸山法 (Euler-Maruyama method)**, 其重要性等同于 ODE 的欧拉法. 使用欧拉-丸山法, 从 $X_0 = x_0$ 出发, 逐步迭代:

$$X_{t+h} = X_t + hu_t(X_t) + \sqrt{h}\sigma_t\epsilon_t, \quad \epsilon_t \sim N(0, I_d) \tag{3.6}$$

其中 $h = n^{-1} > 0 (n \in \mathbb{E})$ 是一个超参数. 换句话说, 使用欧拉-丸山法进行模拟时, 我们会在 $u_t(X_t)$ 的方向上迈出一小步, 并且加上一些按 $\sqrt{h}\sigma_t$ 缩放的高斯噪声.

3.2.2 Diffusion Models

与 ODE 相同, 我们可以通过 SDE 构造一个生成式模型. 我们的目标依然是将简单分布 p_{init} 转化为复杂分布 p_{data}. 自然地, 用 $X_0 \sim p_{\text{init}}$ 随机初始化的 SDE, 然后模拟这种转换. 为了参数化这个 SDE, 我们只需简单地参数化其核心成分——一个神经网络向量场 u_t^θ. 因此, 一个扩散模型可以表示为:

$$dX_t = u_t(X_t)dt + \sigma_t dW_t, \qquad \text{SDE} \tag{3.7a}$$

$$X_0 \sim p_{\text{init}}, \qquad \text{random conditions} \tag{3.7b}$$

算法3描述了使用欧拉-丸山法采样 (sample) 扩算模型的方法.

[2]ODE 中的流映射是确定性映射, 而 SDE 的解受随机噪声影响, 无法用单一映射描述

[3]Trajectory(轨迹): 数学表示为 $t \mapsto X_t$, 是单个初始条件 X_0 随时间 t 演化的**具体路径** (时间函数); Flow Map(流映射) 数学表示为 $\phi_t : X_0 \mapsto X_t$ 所有初始条件 X_0 在时间 t 后的**全局映射规则** (函数族).

Algorithm 3 Sampling from a Diffusion Model (Euler-Maruyama method)

Require: Neural network vector field u_t^θ, number of steps n, diffusion coefficient σ_t

```
Set t = 0
Set step size h = 1/n
Draw a sample X_0 ~ p_init
for i = 1, ..., n-1 do
    Draw a sample ε ~ N(0, I_d)
    X_{t+h} = X_t + h u_t^θ(X_t) + √h σ_t ε
    Update t ← t + h
end for
return X_1
```

3.3 构造训练目标: Conditional and Marginal Score Functions

在第1章中, 我们介绍了 Flow Model 的训练目标. 现在, 我们要构造 Diffusion Model 的训练目标. 不过在此之前, 我们先来定义 p_t 的 **边际匹配得分 (marginal score function)** 为 $\nabla \log p_t(x)$.

Theorem 3.2 (SDE 扩展技巧)

条件向量场 $u_t^{\text{target}}(x|z)$ 和边际向量场 $u_t^{\text{target}}(x)$ 的定义如公式1.17. 那么, 对于扩散系数 $\sigma_t \geq 0$, 我们可以构造一个 SDE, 使其遵循相同的概率路径:

$$X_0 \sim p_{\text{init}}, \quad dX_t = \left(u_t^{\text{target}}(X_t) + \frac{\sigma_t^2}{2}\nabla \log p_t(X_t)\right) dt + \sigma_t dW_t \tag{3.8}$$

$$\Rightarrow \quad X_t \sim p_t \quad (0 \leq t \leq 1) \tag{3.9}$$

特别地,$X_1 \sim p_{\text{data}}$ 对于这个 SDE. 如果我们将边际概率 $p_t(x)$ 和向量场 $u_t^{\text{target}}(x)$ 替换为条件概率路径 $p_t(x|z)$ 和向量场 $u_t^{\text{target}}(x|z)$, 等式也同样成立.

公式3.8很有用, 因为我们可以将边际匹配得分通过**条件匹配得分 (conditional score function)**$\nabla \log p_t(x|z)$ 得到:

$$\nabla \log p_t(x) = \frac{\nabla p_t(x)}{p_t(x)} = \frac{\nabla \int p_t(x|z)p_{\text{data}}(z)dz}{p_t(x)} = \frac{\int \nabla p_t(x|z)p_{\text{data}}(z)dz}{p_t(x)} = \int \nabla \log p_t(x|z)\frac{p_t(x|z)p_{\text{data}}(z)}{p_t(x)}dz \tag{3.10}$$

大多数条件下, 条件匹配得分 $\nabla \log p_t(x|z)$ 的解析式是已知的.

Example (高斯概率路径的得分函数 (Score Function))

对于高斯概率路径 $p_t(x|z) = \mathcal{N}(x; \alpha_t z, \beta_t^2 I_d)$, 我们可以利用高斯概率密度函数的形式 (高斯分布的函数) 得到:

$$\nabla \log p_t(x|z) = \nabla \log \mathcal{N}(x; \alpha_t z, \beta_t^2 I_d) = -\frac{x - \alpha_t z}{\beta_t^2}. \tag{3.11}$$

注意到, 匹配得分是 x 的线性函数, 这是高斯分布的性质.

Theorem 3.3 (Fokker-Planck 方程)

设 p_t 是一个概率路径, 考虑随机微分方程 (SDE):

$$X_0 \sim p_{\text{init}}, \quad dX_t = u_t(X_t)dt + \sigma_t dW_t. \tag{3.12}$$

则 $X_{t(0\le t\le 1)}$ 的分布为 p_t, 当且仅当其满足 **Fokker-Planck 方程**:

$$\partial_t p_t(x) = -\text{div}(p_t u_t)(x) + \frac{\sigma_t^2}{2}\Delta p_t(x), \quad \forall x \in \mathbb{R}^d,\ 0 \le t \le 1, \tag{3.13}$$

其中:

- $\partial_t p_t(x) = \frac{d}{dt}p_t(x)$ 是概率密度的随时间变化率;
- $\text{div}(p_t u_t)$ 是概率流 $p_t u_t$ 的散度 (描述确定性漂移项的影响);
- Δp_t 是拉普拉斯算子[a]作用到概率密度 p_t 上 (描述扩散项的效应).

[a] $\Delta = \nabla \cdot \nabla$

3.4 定理3.2解释

为什么在定理3.2中我们要**构造**公式3.8?

我们希望通过调整 SDE 的漂移项 (drift) 和扩散项 (diffusion), 使其概率演化与 ODE 保持一致. 具体来说,SDE 的漂移项在 ODE 的向量场基础上增加了一个修正项 $\frac{\sigma_t^2}{2}\nabla \log p_t(x)$, 以抵消噪声引入的分布偏移.

3.4.1 ODE 与 SDE 的概率演化对比

ODE 的演化 (流模型) ODE 的形式为:

$$\frac{dX_t}{dt} = u_t^{\text{target}}(X_t), \tag{3.14}$$

其概率密度 $p_t(x)$ 的演化由连续性方程 (Continuity Equation) 描述:

$$\partial_t p_t(x) = -\text{div}(p_t u_t^{\text{target}})(x). \tag{3.15}$$

这个方程表示概率密度的变化完全由向量场 u_t^{target} 的流动决定.

SDE 的演化 (扩散模型) SDE 的形式为:

$$dX_t = u_t^{\text{target}}(X_t)dt + \sigma_t dW_t, \tag{3.16}$$

其概率密度 $p_t(x)$ 的演化由 Fokker-Planck 方程描述:

$$\partial_t p_t(x) = -\text{div}(p_t u_t^{\text{target}})(x) + \frac{\sigma_t^2}{2}\Delta p_t(x). \tag{3.17}$$

这里多了一项 $\frac{\sigma_t^2}{2}\Delta p_t(x)$, 表示噪声对概率密度的扩散效应.

3.4.2 如何让 SDE 的概率演化与 ODE 一致?

为了让 SDE 的 $p_t(x)$ 与 ODE 的 $p_t(x)$ 相同, 我们需要抵消扩散项的影响. 具体方法是在 SDE 的漂移项中增加一个修正项:

$$dX_t = \left(u_t^{\text{target}}(X_t) + \frac{\sigma_t^2}{2}\nabla \log p_t(X_t)\right) dt + \sigma_t dW_t. \tag{3.18}$$

修正项的数学作用

扩散项 $\frac{\sigma_t^2}{2}\Delta p_t(x)$ 会使得概率密度扩散 (变得更平坦). 修正项 $\frac{\sigma_t^2}{2}\nabla \log p_t(x)$ 的加入会生成一个反向的漂移力, 将扩散的概率质量拉回原始分布.

通过计算修正后的 Fokker-Planck 方程:

$$\partial_t p_t(x) = -\text{div}\left(p_t\left(u_t^{\text{target}} + \frac{\sigma_t^2}{2}\nabla \log p_t\right)\right) + \frac{\sigma_t^2}{2}\Delta p_t, \tag{3.19}$$

展开后可以发现:

$$\partial_t p_t(x) = -\text{div}(p_t u_t^{\text{target}}) - \frac{\sigma_t^2}{2}\text{div}(p_t \nabla \log p_t) + \frac{\sigma_t^2}{2}\Delta p_t. \tag{3.20}$$

由于 $\text{div}(p_t \nabla \log p_t) = \Delta p_t$(因为 $\nabla \log p_t = \frac{\nabla p_t}{p_t}$), 两项相消, 最终得到:

$$\partial_t p_t(x) = -\text{div}(p_t u_t^{\text{target}}), \tag{3.21}$$

这与 ODE 的连续性方程完全一致! 因此, 修正后的 SDE 和原始 ODE 具有**相同的概率演化**.

3.4.3 直观理解

ODE: 确定性流动, 概率质量沿着向量场 u_t^{target} 移动.

SDE: 加入噪声后, 概率质量会扩散 (变得更分散). 为了保持与 ODE 相同的分布, 需要增加一个得分函数驱动的漂移 $\frac{\sigma_t^2}{2}\nabla \log p_t$, 将扩散的部分拉回来.

这类似于朗之万动力学 (Langevin Dynamics) 中的修正力, 确保系统收敛到目标分布.

3.4.4 为什么得分函数 $\nabla \log p_t$ 能修正噪声?

得分函数 $\nabla \log p_t(x)$ 指向概率密度增长最快的方向, 因此:

- 在低密度区域 ($p_t(x)$ 小),$\nabla \log p_t(x)$ 较大, 修正力更强, 防止概率质量扩散到这些区域.
- 在高密度区域 ($p_t(x)$ 大), 修正力较弱, 允许概率质量保持在主流分布附近.

这样,SDE 的轨迹会围绕 ODE 的确定性路径波动, 但整体分布保持一致.

3.4.5 修正后的 SDE 与原始 ODE 具有相同概率演化的意义与优势

如果修正后的 SDE(加入得分函数调整项后) 和原始 ODE 具有完全相同的概率演化 $p_t(x)$, 这意味着:

- **生成样本分布相同**:ODE 和 SDE 的终点 X_1 均服从目标分布 p_{data}
- **路径性质不同**:
  - ODE: 确定性轨迹 ($X_0 \to X_1$ 唯一)
  - SDE: 随机性轨迹 (X_1 随噪声 dW_t 变化)

3.5 训练: 匹配得分 (Score Matching)

若使得 ODE 与 SDE 有相同的边际概率分布 (概率演化均为 $p_t(x)$), 需有:

$$dX_t = \left(u_t^{\text{target}}(X_t) + \frac{\sigma_t^2}{2}\nabla \log p_t(X_t)\right) dt + \sigma_t dW_t \qquad \text{(SDE 形式)} \tag{3.22}$$

$$X_0 \sim p_{\text{init}} \qquad \text{(初始条件)} \tag{3.23}$$

$$\Rightarrow X_t \sim p_t \quad \text{对所有 } 0 \le t \le 1 \qquad \text{(概率路径匹配)} \tag{3.24}$$

其中 u_t^{target} 是边际向量场, $\nabla \log p_t$ 是边际得分函数 (marginal score function), $\nabla \log p_t$ 通过下式得到:

$$\nabla \log p_t(x) = \int \nabla \log p_t(x|z) \underbrace{\frac{p_t(x|z)p_{\text{data}}(z)}{p_t(x)}}_{\text{后验分布}p_t(z|x)} dz \tag{3.25}$$

为估计边际得分函数 $\nabla \log p_t$, 我们可以使用一个**得分网络 (score network)** 的神经网络 $s_t^\theta : \mathbb{R}^d \times [0,1] \to \mathbb{R}^d$. 类似于之前的方法, 我们可以设计两种损失函数, **score matching loss** 和 **conditional score matching loss**:

$$L_{\text{SM}}(\theta) = \mathbb{E}_{t\sim \text{Unif}, z\sim p_{\text{data}}, x\sim p_t(\cdot|z)}\left[\|s_t^\theta(x) - \nabla \log p_t(x)\|^2\right] \qquad \text{(score matching loss)} \tag{3.26}$$

$$L_{\text{CSM}}(\theta) = \mathbb{E}_{t\sim \text{Unif}, z\sim p_{\text{data}}, x\sim p_t(\cdot|z)}\left[\|s_t^\theta(x) - \nabla \log p_t(x|z)\|^2\right] \qquad \text{(conditional score matching loss)} \tag{3.27}$$

关键区别在于:

- 边际匹配得分使用 $\nabla \log p_t(x)$(全局边际分布得分)
- 条件匹配得分使用 $\nabla \log p_t(x|z)$(已知数据点 z 的条件得分)

虽然理想情况下我们希望最小化 L_{SM}(边际得分匹配), 但由于 $\nabla \log p_t(x)$ 未知, 实际上采用可处理的替代方案:

Theorem 3.4 (条件得分匹配的等价性)

Score matching loss 和 Conditional score matching loss 之间之差一个常数:

$$\mathcal{L}_{\text{SM}}(\theta) = \mathcal{L}_{\text{CSM}}(\theta) + C, \tag{3.28}$$

其中 C 与参数 θ 无关. 因此, 他们的梯度相等:

$$\nabla \mathcal{L}_{\mathrm{SM}}(\theta) = \nabla \mathcal{L}_{\mathrm{CSM}}(\theta) \tag{3.29}$$

特别地, 对于最小化的参数 θ^*, 我们有 $\theta^* = \nabla \log p_t$

Proof. 参考1.3, 略. ■

上述过程描述了扩散模型的标准训练流程. 训练完成后, 我们可以选择任意的扩散系数 $\sigma_t \geq 0$ 来模拟随机微分方程 (SDE):

$$X_0 \sim p_{\mathrm{init}}, \quad dX_t = \left(u_t^\theta(X_t) + \frac{\sigma_t^2}{2} s_t^\theta(X_t) \right) dt + \sigma_t dW_t \tag{3.30}$$

从而生成样本 $X_1 \sim p_{\mathrm{data}}$. 理论上, 当训练完美时, 任意 σ_t 都应产生符合目标分布的样本. 但实际上会遇到两类误差:

1. **数值误差**:SDE 数值模拟的不精确性
   - 离散化误差 (如 Euler-Maruyama 方法的 $\mathcal{O}(\Delta t^{1/2})$ 阶误差)
   - 累积误差随模拟步数增加而放大
2. **训练误差**: 得分网络 s_t^θ 的近似不完美

乍一看, 似乎使用扩散模型而不是流模型的一个缺点是我们需要同时学习 s_t^θ 和 u_t^θ. 然而, 需要注意的是, 我们通常可以在一个有双输出的单一网络中直接学习 s_t^θ 和 u_t^θ, 因此额外的计算工作量通常非常小. 此外, 在高斯概率路径的特殊情况下,s_t^θ 和 u_t^θ 可以相互转换, 因此我们不需要分别训练它们.

Remark

Denoising Diffusion Models
如果你对扩散模型有所了解, 你可能已经听说过**去噪扩散模型 (denoising diffusion model)** 这个术语. 这类模型变得如此流行, 以至于现在大多数人干脆省略了 "去噪 (denoising)" 这个词, 直接用 "扩散模型 (diffusion model)" 来称呼它. 在本文档的语境中, 这些就是具有高斯概率路径 $p_t(\cdot|z) = \mathcal{N}(\alpha_t z, \beta_t^2 I)$ 的扩散模型. 然而, 需要注意的是, 在一些最初的扩散模型论文中, 这可能并不那么显而易见. 这些论文使用了不同的时间约定 (时间是倒置的), 因此你需要应用适当的时间重新缩放. 此外, 它们通过所谓的前向过程 (forward process) 来构建概率路径.

Example (Denoising Diffusion Models: Score Matching for Gaussian Probability Paths)

首先, 我们实例化去噪分数匹配损失函数在 $p_t(x|z) = \mathcal{N}(\alpha_t z, \beta_t^2 I_d)$ 情况下的表达式. 如公式3.11所推导, 条件分数 $\nabla \log p_t(x|z)$ 的解析式为:

$$\nabla \log p_t(x|z) = -\frac{x - \alpha_t z}{\beta_t^2}. \tag{3.31}$$

将其代入 conditional score matching loss 可得:

$$L_{\text{CSM}}(\theta) = \mathbb{E}_{t\sim\text{Unif},z\sim p_{\text{data}},x\sim p_t(\cdot|z)}\left[\left\|s_t^\theta(x) + \frac{x-\alpha_t z}{\beta_t^2}\right\|^2\right] \tag{3.32}$$

$$\overset{(i)}{=} \mathbb{E}_{t\sim\text{Unif},z\sim p_{\text{data}},\epsilon\sim\mathcal{N}(0,I_d)}\left[\left\|s_t^\theta(\alpha_t z+\beta_t\epsilon) + \frac{\epsilon}{\beta_t}\right\|^2\right] \tag{3.33}$$

$$= \mathbb{E}_{t\sim\text{Unif},z\sim p_{\text{data}},\epsilon\sim\mathcal{N}(0,I_d)}\left[\frac{1}{\beta_t^2}\left\|\beta_t s_t^\theta(\alpha_t z+\beta_t\epsilon) + \epsilon\right\|^2\right] \tag{3.34}$$

其中步骤 (i) 通过公式1.34将 x 替换为 $\alpha_t z + \beta_t\epsilon$. 值得注意的是, 网络 s_t^θ 本质上学习的是用于破坏数据样本 z 的噪声预测. 因此, 上述训练损失也被称为**去噪匹配得分 (denoising score matching)**, 这是学习扩散模型最早采用的方法之一.
研究发现当 $\beta_t \approx 0$ 接近零时 (即仅在添加足够噪声时有效), 上述损失函数存在数值不稳定性. 在早期去噪扩散概率模型 (如 DDPM) 中, 提出通过舍弃常数 $\frac{1}{\beta_t^2}$ 并将 s_t^θ 重参数化为**噪声预测 (noise predictor)** 网络 $\epsilon_t^\theta : \mathbb{R}^d \times [0,1] \to \mathbb{R}^d$:

$$-\beta_t s_t^\theta(x) = \epsilon_t^\theta(x) \implies L_{\text{DDPM}}(\theta) = \mathbb{E}_{t,z,\epsilon}\left[\|\epsilon_t^\theta(\alpha_t z+\beta_t\epsilon) - \epsilon\|^2\right] \tag{3.35}$$

如上所述, 网络 ϵ_t^θ 本质上是在学习预测用来破坏数据样本 z 的噪声. 算法4总结了该训练流程.

Algorithm 4 Score Matching Training Procedure for Gaussian probability path

Require: A dataset of samples $z \sim p_{\text{data}}$, score network s_t^θ or noise predictor ϵ_t^θ

1: **for** each mini-batch of data **do**
2: Sample a data example z from the dataset.
3: Sample a random time $t \sim \text{Unif}[0,1]$.
4: Sample noise $\epsilon \sim \mathcal{N}(0, I_d)$.
5: Set $x_t = \alpha_t z + \beta_t\epsilon$ (General case: $x_t \sim p_t(\cdot|z)$).
6: Compute loss

$$\mathcal{L}(\theta) = \left\|s_t^\theta(x_t) + \frac{\epsilon}{\beta_t}\right\|^2 \quad \left(\text{General case: } = \left\|s_t^\theta(x_t) - \nabla\log p_t(x_t|z)\right\|^2\right)$$

$$\text{Alternatively :}\mathcal{L}(\theta) = \left\|\epsilon_t^\theta(x_t) - \epsilon\right\|^2$$

7: Update the model parameters θ via gradient descent on $\mathcal{L}(\theta)$.
8: **end for**

除了其简洁性外, 高斯概率路径还具有另一个实用特性: 通过学习得分函数 s_t^θ 或噪声预测器 ϵ_t^θ, 我们可以自动获得对应的向量场 u_t^θ, 反之亦然:

Proposition 3.5 (得分函数与向量场的双向转换 (Conversion formula for Gaussian probability path))

对于任意高斯概率路径 $p_t(x|z) = \mathcal{N}(\alpha_t z, \beta_t^2 I_d)$, 其条件/边际得分与向量场满足以下等价关系:

$$u_t^{\text{target}}(x|z) = \left(\beta_t^2 \frac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t\right) \nabla \log p_t(x|z) + \frac{\dot{\alpha}_t}{\alpha_t} x \tag{3.36}$$

$$u_t^{\text{target}}(x) = \left(\beta_t^2 \frac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t\right) \nabla \log p_t(x) + \frac{\dot{\alpha}_t}{\alpha_t} x \tag{3.37}$$

其中 $\dot{\alpha}_t, \dot{\beta}_t$ 表示时间导数. 其中, 上述边际向量场 u_t^{target} 的公式在文献中被称为概率流 ODE(probability flow ODE)(更准确地说, 是指其对应的常微分方程). 该性质表明二者可通过线性变换相互导出.

Proof. 对于条件向量场和条件分数函数, 我们可以推导:

$$u_t^{\text{target}}(x|z) = \left(\dot{\alpha}_t - \frac{\dot{\beta}_t}{\beta_t}\alpha_t\right) z + \frac{\dot{\beta}_t}{\beta_t} x \tag{3.38}$$

$$\overset{(i)}{=} \left(\beta_t^2 \frac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t\right) \left(\frac{\alpha_t z - x}{\beta_t^2}\right) + \frac{\dot{\alpha}_t}{\alpha_t} x \tag{3.39}$$

$$= \left(\beta_t^2 \frac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t\right) \nabla \log p_t(x|z) + \frac{\dot{\alpha}_t}{\alpha_t} x \tag{3.40}$$

其中步骤 (i) 通过代数运算完成. 通过积分运算, 相同恒等式对边际流向量场和边际分数函数同样成立:

$$u_t^{\text{target}}(x) = \int u_t^{\text{target}}(x|z) \frac{p_t(x|z) p_{\text{data}}(z)}{p_t(x)} dz \tag{3.41}$$

$$= \int \left[\left(\beta_t^2 \frac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t\right) \nabla \log p_t(x|z) + \frac{\dot{\alpha}_t}{\alpha_t} x\right] \frac{p_t(x|z) p_{\text{data}}(z)}{p_t(x)} dz \tag{3.42}$$

$$\overset{(i)}{=} \left(\beta_t^2 \frac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t\right) \nabla \log p_t(x) + \frac{\dot{\alpha}_t}{\alpha_t} x \tag{3.43}$$

其中步骤 (i) 应用了公式3.25的分数函数边际化性质. ■

我们可以利用转换公式, 通过以下方式在得分网络 s_t^θ 和向量场网络 u_t^θ 之间进行参数化转换:

$$\boxed{u_t^\theta = \left(\beta_t^2 \tfrac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t\right) s_t^\theta(x) + \tfrac{\dot{\alpha}_t}{\alpha_t} x} \tag{3.44}$$

类似地, 只要满足 $\beta_t^2 \dot{\alpha}_t - \alpha_t \dot{\beta}_t \beta_t \neq 0$(对于 $t \in [0, 1)$ 恒成立), 则有:

$$\boxed{s_t^\theta(x) = \tfrac{\alpha_t u_t^\theta(x) - \dot{\alpha}_t x}{\beta_t^2 \dot{\alpha}_t - \alpha_t \dot{\beta}_t \beta_t}} \tag{3.45}$$

通过这种参数化方式可以证明,denoising score matching loss 与 conditional flow matching losses

仅相差一个常数项. 由此我们得出结论: **对于高斯概率路径, 无需单独训练边际分数 (marginal score) 和边际向量场 (marginal vector field), 因为已知其中一个就足以计算另一个. 特别地, 我们可以自由选择使用流匹配或匹配得分进行训练.**

若已训练好得分网络 s_t^θ, 根据公式3.30可采用任意 $\sigma_t \geq 0$ 从以下 SDE 采样:

$$X_0 \sim p_{\text{init}}, \quad dX_t = \left[\left(\beta_t^2 \frac{\dot{\alpha}_t}{\alpha_t} - \dot{\beta}_t \beta_t + \frac{\sigma_t^2}{2}\right) s_t^\theta(x) + \frac{\dot{\alpha}_t}{\alpha_t} x\right] dt + \sigma_t dW_t \tag{3.46}$$

从而获得服从 p_{data} 分布的样本 X_1(在训练和模拟误差范围内). 这对应于**去噪扩散模型的随机采样过程 (stochastic sampling from a denoising diffusion model)**.

3.6 时间反演 vs 求解 FP 方程

(Time-Reversals vs Solving the Fokker-Planck equation)

扩散模型的原始描述并未通过 Fokker-Planck 方程 (或连续性方程) 构造训练目标 u_t^θ 或 $\nabla \log p_t$, 而是通过前向过程的时间反演实现. 时间反演 $(X_t)_{0 \leq t \leq T}$ 是一个 SDE, 其轨迹分布与原始过程相同但时间倒置, 即:

$$\mathbb{P}[\bar{X}_{t_1} \in A_1, \ldots, \bar{X}_{t_n} \in A_n] = \mathbb{P}[\bar{X}_{T-t_1} \in A_1, \ldots, \bar{X}_{T-t_n} \in A_n] \tag{3.47}$$

$$\forall 0 \leq t_1, \ldots, t_n \leq T, \text{ and } A_1, \ldots, A_n \subset \mathcal{S} \tag{3.48}$$

根据 Anderson 的研究, 满足上述条件的时间反演可以通过以下 SDE 实现:

$$dX_t = \left(-u_t(X_t) + \sigma_t^2 \nabla \log p_t(X_t)\right) dt + \sigma_t dW_t, u_t(x) = u_{T-t}^{\text{forw}}(x), \sigma_t = \bar{\sigma}_{T-t} \tag{3.49}$$

若 $u_t(X_t) = a_t X_t$, 上述 SDE 对应命题3.5中训练目标的一个特例 (这一点并不显然, 因为使用了不同的时间约定). 然而, 对于生成建模的许多应用, 我们通常只使用马尔可夫过程的终点 X_1(例如生成的图像), 而丢弃中间时间点. 因此, 马尔可夫过程是否是“真正”的时间反演, 或者是否沿着概率路径演化, 对许多应用并不重要. 即使用时间反演并非必要, 且通常会导致次优结果 (例如概率流 ODE 通常效果更好).

3.6.1 时间反演

扩散模型的逆向过程并非直接反转原 SDE 的路径, 而是构造一个新的 SDE, 使得其生成的边缘分布 $p_t(x_t)$ 与原过程的边缘分布反向对齐, 这与伊藤过程不可逆不矛盾。这一构造依赖于以下关键理论: 前向扩散通过 SDE 逐步加噪:

$$dx_t = u(x_t, t)dt + \sigma_t dw_t \tag{3.50}$$

对应的 Fokker-Planck 方程 (描述概率密度 $p_t(x)$ 的演化):

$$\frac{\partial p_t(x)}{\partial t} = -\nabla_x \cdot [u(x,t)p_t(x)] + \frac{\sigma_t^2}{2} \nabla_x^2 p_t(x) \tag{3.51}$$

我们希望找到一个逆向过程 $dx_t = \tilde{u}(x_t, t)dt + \sigma_t d\bar{w}_t$, 使得: 从噪声分布 $p_T(x)$ 出发, 逆向演化回

数据分布 $p_0(x)$；逆向过程的 Fokker-Planck 方程应与前向过程“对称”。

逆向过程的时间是反向的 $(t \to T - t)$, 其 Fokker-Planck 方程为:

$$\frac{\partial p_t(x)}{\partial t} = -\nabla_x \cdot [\tilde{u}(x,t)p_t(x)] - \frac{\sigma_t^2}{2}\nabla_x^2 p_t(x) \tag{3.52}$$

(注意扩散项前的负号, 因为时间方向反转。)

前向 Fokker-Planck 方程可以重写为概率流形式:

$$\frac{\partial p_t(x)}{\partial t} = -\nabla_x \cdot \left(\underbrace{\left(u(x,t) - \frac{\sigma_t^2}{2}\nabla_x \log p_t(x) \right)}_{\text{概率流速度}} p_t(x) \right) \tag{3.53}$$

概率流速度 $v(x,t) = u(x,t) - \frac{\sigma_t^2}{2}\nabla_x \log p_t(x)$ 描述了概率密度的整体运动趋势。

为了使逆向过程“回放”前向过程, 我们需要:

- 反转漂移方向: 概率流速度反向, 即 $\tilde{v}(x,t) = -v(x,t)$；
- 保持扩散强度: 噪声项 σ_t 不变。

因此, 逆向过程的漂移项为:

$$\tilde{f}(x,t) = \tilde{v}(x,t) + \frac{\sigma_t^2}{2}\nabla_x \log p_t(x) = -u(x,t) + \sigma_t^2 \nabla_x \log p_t(x) \tag{3.54}$$

最终得到逆向 SDE:

$$dx_t = \left[u(x_t,t) - \sigma_t^2 \nabla_x \log p_t(x_t) \right] dt + \sigma_t d\bar{w}_t \tag{3.55}$$

3.6.2 SDE 的 ODE 概率流 (SDE 的 ODE 概率演化)

在 Song 的原文中, 给出了与 SDE 方程3.50演化路径相同的 ODE 方程:

$$dx = \left[u_t(x) - \frac{\sigma_t^2}{2}\nabla_x \log p_t(x) \right] dt \tag{3.56}$$

公式3.56的概率流为:

$$\partial_t p_t(x) = -\nabla \left[p_t(u_t(x) - \frac{\sigma_t^2}{2}\nabla_x \log p_t(x)) \right](x) \tag{3.57}$$

$$= -\nabla(p_t u_t)(x) + \frac{\sigma_t^2}{2}\Delta_x \log p_t(x) \tag{3.58}$$

这就是 SDE 的概率流方程 (Fokker-Planck 方程).

利用公式3.56即可在 ODE 中使用 SDE 的概率演化 (联想 DDIM).

3.7 小结

本章主要讲述 SDE 的基本原理, 并利用 Fokker-Planck 方程构造出一个 SDE, 使其拥有与 ODE(Flow Matching) 相同的概率演化, 形式上与 ODE(Flow Matching) 保持一致, 而非利用 Song 所提出的时

间反演方法. 同时, 在本文语境中, DDPM 只是 SDE 的一种高斯概率路径演化的具体情况.

Chapter 4

冷冻电镜学习笔记

October 21, 2025

4.1 TEM(Transmission Electron Microscope) 简介

4.1.1 核心物理原理

- **电子与物质的相互作用**
  - **弹性散射**: 无能量损失
    - 是**衍射衬度成像**和**电子衍射**的基础
    - 用于分析晶体结构、取向和缺陷
  - **非弹性散射**: 有能量损失
    - 是**分析电子显微学** (如 EELS, XEDS) 的基础
    - 用于分析元素组成、化学价态和电子结构
- **波动性**
  - 电子的波动性 (德布罗意波长) 是**衍射**和**高分辨相位衬度成像**的物理基础
- **关键原理**
  - **惠更斯-菲涅耳原理**: 解释了衍射现象, 即波前上每一点都是次级子波源, 它们相干叠加形成新的波前
  - **夫琅禾费衍射**: 远场衍射, 是理解 TEM 中衍射花样的模型

4.1.2 仪器构成与功能

- **电子源**: 产生照明电子束.
  - **热离子源 (如 LaB)**: 亮度较高, 性价比好, 适用于常规 TEM.
  - **场发射源 (FEG)**: 亮度极高、相干性好, 是高分辨成像和微区分析的首选.

- **电磁透镜**: 聚焦和放大电子束. 其不完美性 (**像差**) 是限制分辨率的主要因素.
  - **球差** (C_s): 限制高分辨率的关键像差, 可通过**球差校正器**克服.
  - **色差** (C_c): 由电子能量分散引起, 对厚样品影响显著, 可通过**能量过滤**或**单色器**改善.
  - **像散**: 导致图像定向模糊, 可通过**消像散器**校正.
- **真空系统**: 为电子束提供无干扰的路径, 并保护电子源.
- **样品杆**: 在真空中承载和操控样品, 实现平移、倾斜、加热、冷却等多种功能.
- **探测系统**:
  - 荧光屏/CCD 相机: 用于接收图像和衍射花样.
  - X 射线能谱仪 (XEDS/EDS): 用于元素成分分析.
  - 电子能量损失谱仪 (EELS): 用于轻元素分析、化学态和电子结构研究.

4.1.3 主要操作模式与信息获取

- **成像模式**: 观察样品的**实空间**形貌和结构
  - **明场像 (BF)**: 使用直射束成像, 质量/厚度大的区域显暗
  - **暗场像 (DF)**: 使用衍射束成像, 用于凸显特定取向的晶体或相
  - **高分辨像 (HRTEM)**: 利用透射束与衍射束的干涉, 直接观察晶格条纹甚至原子柱
    - 其解释依赖于**衬度传递函数 (CTF)** 理论
    - 最佳条件是 **Scherzer 欠焦**
- **衍射模式**: 获取样品的**倒易空间**信息, 用于晶体结构分析
  - **选区电子衍射 (SAED)**: 分析样品特定微区的晶体结构
  - **会聚束电子衍射 (CBED)**: 提供更丰富的晶体学信息, 如厚度、应变等
- **扫描透射模式 (STEM)**
  - 用聚焦的细电子束在样品上扫描, 同步收集各种信号
  - **高角环形暗场像 (HAADF)**: 衬度近似与原子序数的平方 (Z^2) 成正比, 又称"Z 衬度像"
- **分析模式**
  - **XEDS**: 适用于重元素的成分分析
  - **EELS**: 适用于轻元素, 并提供化学键合信息

4.1.4 样品制备

- **核心要求**: 样品必须非常薄 (通常 < 100 nm) 以保证电子束透明
- **常用方法**
  - **电解双喷**: 适用于金属和合金
  - **离子减薄**: 适用于陶瓷、半导体、岩石等硬脆材料
  - **超薄切片**: 适用于聚合物、生物等软材料
  - **聚焦离子束 (FIB)**: 可进行**定点**、**截面**样品制备, 精度极高
- **特殊分支: 冷冻电镜 (Cryo-EM)**
  - **原理**: 将生物样品在液态乙烷中快速冷冻, 使其包埋在玻璃态冰中, 从而在低温下用 TEM 观察其近天然状态的结构
  - **关键技术**: 直接电子探测器、强大的三维重构软件
  - **应用**: 主要用于解析**生物大分子** (如蛋白质、病毒) 的**高分辨率三维结构**, 无需结晶

4.1.5 关键数学与公式

1. **电子波长** (相对论修正):
$$\lambda = \frac{h}{\sqrt{2m_0eV(1+\frac{eV}{2m_0c^2})}}$$
2. **布拉格定律** (衍射几何基础):
$$n\lambda = 2d\sin\theta$$
3. **散射截面**: 描述散射概率, 与原子序数 (Z) 和电子能量 (E) 密切相关 (例如, 卢瑟福截面 $\sigma \propto Z^2/E^2$).
4. **平均自由程**:
$$\lambda_{mfp} = 1/\sigma_{total}$$
决定样品理想厚度.
5. **分辨率**:
   - **衍射极限**:$r_{th} \approx 0.61\lambda/\beta$
   - **球差限制** (Scherzer 分辨率):$r_{min} \approx 0.66C_s^{1/4}\lambda^{3/4}$
6. **衬度传递函数 (CTF)**: 是理解 HRTEM 图像的核心.
$$\mathrm{CTF}(k) = \sin(\chi(k)), \quad \chi(k) = \frac{\pi}{2}C_s\lambda^3k^4 + \pi\Delta f\lambda k^2$$
7. **Scherzer 欠焦**:
$$\Delta f_{Sch} = -\sqrt{\frac{4}{3}C_s\lambda}$$

4.2 问题解答

4.2.1 冷冻电镜图像噪声来源

- **非弹性散射电子:** 当高能电子穿过样品时, 会与样品中的原子发生相互作用, 主要产生弹性散射与非弹性散射. 弹性散射电子携带了样品内部结构 (原子位置) 的相位信息, 是构成高分辨率图像有用信号的核心; 非弹性散射电子主要携带关于样品元素组成、化学键 (电子结构) 的信息. 但对于成像来说, 它们不直接携带高分辨率的空间结构信息. 非弹性散射电子由于能量损失和方向随机改变, 会形成一个弥漫的、非相干背景. 这个背景会叠加在由弹性散射形成的清晰信号之上, 降低了图像的信噪比和衬度, 使得微弱的细节 (尤其是高分辨率信息) 更难被探测.
- **CMOS 噪声:** CMOS 探测器的噪声可以按其产生环节分为以下几类:
  - **读出噪声:** 这是当相机将每个像素收集的电荷 (模拟信号) 转换为数字值时引入的随机噪声. 主要来自读出电路中的热噪声和晶体管开关噪声.
  - **暗电流噪声:** 由于热效应, 探测器像素在完全没有光或电子照射的情况下, 也会自发地产生电荷.
  - **散粒噪声:** 虽然散粒噪声的本质是电子数量的量子涨落 (物理噪声), 但它最终体现在探测器接收到的信号上.
  - **像素响应非均匀性:** 制造工艺导致探测器的数百万个像素之间存在微小差异. 有的像素可能对电子更“敏感”(增益高), 有的则更“迟钝”(增益低).
- **样品相关噪声:** 这是由样品本身及其制备过程引入的:
  - **冰层噪声/背景:** 样品被包裹在无定形冰中. 冰层本身并非绝对均匀, 其密度起伏会在图像中产生背景信号, 掩盖微弱的样品信号.
  - **样品异质性:** 样品的结构和状态差异会引起重构模糊, 主要包括:
    1. **构象异质性:** 蛋白质分子处于不同的功能状态 (如“开放”态、“关闭”态).
    2. **化学组成异质性:** 复合物中组分的结合与否、化学修饰的不同等.
    3. **取向异质性:** 颗粒在冰层中以随机取向存在, 但如果某些取向缺失, 会导致重构缺失信息, 产生“伪影”.
  - **污染物和杂质:** 品中存在的盐晶、去垢剂胶束、降解的蛋白片段等, 都会增加图像的复杂性.
- **电子束引起的噪声/损伤:** 高能电子束在轰击样品时, 会破坏化学键, 导致样品结构发生损伤. 这种损伤是累积性的, 随着电子剂量的增加而加剧.

4.2.2 CTF(Contrast Transfer Function), 对比度传递函数

在理想的光学透镜中, 一个物点经过透镜后会完美地汇聚成一个像点. 但在现实中, 由于像差的存在, 物点会变成一个模糊的斑 (艾里斑). 在电子光学中, 这个问题尤为严重.

当一束平行的电子波穿过一个极薄的晶体样品时, 它会与样品中的原子发生相互作用, 发生衍射. 出射的电子波包含两种信息:

- **振幅衬度:** 由于电子被样品吸收或散射到光阑外而造成的强度差异. 这在较厚的样品中占主导.
- **相位衬度:** 对于 HRTEM 观察的极薄样品, 电子波主要通过改变相位来携带信息. 我们的眼睛和探测器无法直接感知相位, 只能感知强度 (振幅的平方).

这些携带了样品结构信息的衍射波和直接透射波, 在穿过 TEM 的电磁透镜系统时, 会因为透镜的不完美性 (像差) 和欠焦操作而发生额外的相位改变. 最终, 它们在像平面上干涉, 形成了我们看到的灰度图像.

CTF 的核心作用就是描述: 一个来自样品的空间频率信息 (可以想象成不同间距的晶格), 在经过整个显微镜系统后, 其相位和振幅是如何被改变的.

CTF 公式:

$$\mathrm{CTF}(k) = \sin(\chi(k)) = \sin\left(\frac{\pi}{2}C_s\lambda^3k^4 + \pi\Delta f\lambda k^2\right) \tag{4.1}$$

这里, $\chi(k)$ 是相位, Δf 是欠焦值 (Defocus),λ 是电子束的在样品中的波长, k 是空间频率 (Spatial Frequency), C_s 是透镜的球差 (Spherical Aberration).

在透射电镜中, 当 Electron Gun 的电压确定了, 那么电子束的波长 λ 也就确定了.Δf 和 C_s 是可以人为控制的参量. 所以, 在 CTF 中, 实际上只有一个自变量 k.

成像系统决定的参数: C_s, λ, Δf

4.2.3 Thon 环

Thon 环 (Thon rings) 是透射电子显微镜 (TEM) 成像中出现的一种周期性明暗交替的条纹图案, 通常出现在欠焦或过焦条件下的离焦像中. 其产生原因与电子波的离焦衬度和衍射效应有关

物理背景: 电子波的波动性: 在 TEM 中, 电子束穿过样品时, 与样品内部的电势场发生相互作用, 导致电子波的相位发生变化. 当电子波穿过样品后, 其波前会发生畸变, 形成携带样品信息的相位衬度.

离焦引入的衬度: 在 TEM 中, 电子束穿过样品时, 与样品内部的电势场发生相互作用, 导致电子波的相位发生变化. 当电子波穿过样品后, 其波前会发生畸变, 形成携带样品信息的相位衬度. 为了将相位衬度转换为可见的强度衬度, 通常需要让成像平面偏离样品的准确焦平面 (即离焦). 离焦会引入一个相位衬度传递函数 (CTF, 如公式4.1)

Thon 环的形成机制: $\mathrm{CTF}(\sin(\chi(k)))$ 随空间频率 k 的变化而振荡, 导致某些空间频率 (对应样品的特定结构周期) 被增强, 而另一些被抑制. 在特定的离焦条件下,CTF 的振荡会在傅里叶变换 (或衍射图) 中表现为明暗相间的同心圆环, 即 Thon 环. 环的间距与离焦量 (Δf) 和电子波长 (λ) 相关, 通过分析 Thon 环可以反推离焦量或校正透镜参数. 在收集完图片之后, 我们要对图片进行 CTF 修正, 还原它在各个分辨率的衬度.

Thon 环完整: 能够看到清晰、规整的 Thon 环, 说明了以下几点:

- **仪器状态极佳:** 这表明电镜的相干性非常好 (电子束像一道完美的激光), 机械稳定性高 (没有漂移和振动), 像散被完美校正 (否则环会变成椭圆). 这是获得高分辨图像的前提.
- **样品质量合格:** 样品必须非常薄且均匀, 才能产生强烈的相位衬度干涉, 从而形成清晰的 Thon 环. 如果样品太厚、污染严重或不均匀, 环会变得模糊或不完整.
- **图像信息量足:** 清晰的 Thon 环意味着图像包含了从低频到高频的丰富信息. 环能延伸到的空间频率越高, 说明图像的分辨率潜力越大.

4.2.4 冷冻电镜处理过程

Workflow: 单颗粒冷冻电镜 (cryo-EM SPA) 拍摄 Workflow 如图4.1:

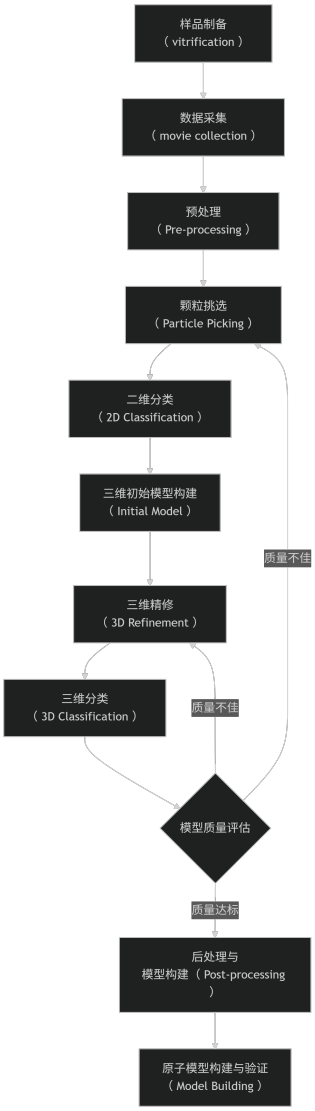

Figure 4.1: 冷冻电镜 workflow

拍摄角度: 在冷冻电镜中: 研究者将样品快速冷冻成一层无定形冰 (vitrified ice). 在这层冰中, 每个分子 (粒子) 会被随机嵌入、随机取向. 电镜在拍摄时, 对冰层进行垂直照射 (电子束几乎固定方向), 因此:

- 每个粒子的朝向不同;
- 每张 micrograph 中, 其实包含了成千上万个不同角度的投影图像.

在标准的单颗粒冷冻电镜拍摄中, 电子束方向固定不变, 样品角度也不是动态变化的. 我们依靠样品中粒子的随机取向分布来获得各个方向的投影图像, 从而通过计算重建出三维结构.

4.2.5 同质和异质

同质: 指的是样品中所有蛋白质颗粒在结构上都是完全相同的. **定义:** 样品中的所有蛋白质分子都具有完全相同的三维结构、构象和化学组成. **侧重点:** 同质样品数据分析的核心目标是提高信噪比和分辨率.

异质: 指的是样品中存在结构上不同的多种颗粒. **定义:** 样品中的蛋白质颗粒在结构上存在差异. 这种差异可以是:

- 组成型异质性: 样品中本身就存在不同的分子. 例如: 蛋白质与不同配体的结合/未结合状态; 蛋白质复合物中不同亚基的组成比例不同; 样品中混杂了完全不同的蛋白质.
- 构象型异质性: 同一个蛋白质分子可以动态地在不同三维形状之间转换. 例如: 核糖体在翻译过程中的不同状态; 膜通道的“开放”与“关闭”状态; 酶在催化循环中的不同中间态.

侧重点: 异质样品数据分析的核心目标是“分离”与“分类”, 即从混合的颗粒集合中, 识别出不同的结构状态, 并分别重构出它们各自的三维结构.

4.2.6 傅里叶切片定理

傅里叶切片定理 (Fourier Slice Theorem), 也称为中心切片定理 (Central Slice Theorem) 或投影切片定理, 是计算机断层成像 (CT) 和医学影像领域中的一个基本数学原理. 该定理建立了图像的投影数据与其傅里叶变换之间的关系, 是理解 CT 图像重建算法的核心. 傅里叶切片定理可以表述为: 一个二维函数 (例如图像) 在某个角度下的投影的一维傅里叶变换, 等于该二维函数的二维傅里叶变换在相同角度下通过原点的切片.

数学表达: 设 $f(x,y)$ 是一个二维函数, 其二维傅里叶变换为:

$$F(u,v) = \iint_{-\infty}^{\infty} f(x,y) e^{-i2\pi(ux+vy)}\, dx\, dy \tag{4.2}$$

在角度 θ 下的投影 $p_\theta(t)$ 定义为:

$$p_\theta(t) = \int_{-\infty}^{\infty} f(t\cos\theta - s\sin\theta, t\sin\theta + s\cos\theta)\, ds \tag{4.3}$$

其中,t 是投影的坐标轴. 投影 $p_\theta(t)$ 的一维傅里叶变换为:

$$P_\theta(\omega) = \int_{-\infty}^{\infty} p_\theta(t) e^{-i2\pi\omega t}\, dt \tag{4.4}$$

傅里叶切片定理指出:

$$P_\theta(\omega) = F(\omega\cos\theta, \omega\sin\theta) \tag{4.5}$$

即, 投影的一维傅里叶变换等于二维傅里叶变换在频率平面中沿角度 θ 的径向切片. 公式4.5即为傅里叶切片定理

Proof. 在角度 θ 下的投影 $p_\theta(t)$ 定义为沿直线 $L(t,\theta): x\cos\theta + y\sin\theta = t$ 的线积分:

$$p_\theta(t) = \int_{L(t,\theta)} f(x,y)\, ds \tag{4.6}$$

其中 s 是沿该直线的坐标. 易得:

$$\begin{cases} t = x\cos\theta + y\sin\theta \\ s = -x\sin\theta + y\cos\theta \end{cases} \tag{4.7}$$

注意到公式4.7同时可以表示坐标 (x, y) 旋转 θ 得到坐标系 (t, s), 则其逆变换为:

$$\begin{cases} x &= t\cos\theta - s\sin\theta \\ y &= t\sin\theta + s\cos\theta \end{cases} \tag{4.8}$$

该坐标变换的雅可比行列式为:

$$\left|\frac{\partial(x,y)}{\partial(t,s)}\right| = \begin{vmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{vmatrix} = \cos^2\theta + \sin^2\theta = 1 \tag{4.9}$$

因此,$dx\,dy = dt\,ds$. 于是投影可写为:

$$p_\theta(t) = \int_{-\infty}^{\infty} f(t\cos\theta - s\sin\theta,\, t\sin\theta + s\cos\theta)\,ds \tag{4.10}$$

投影 $p_\theta(t)$ 的一维傅里叶变换为:

$$P_\theta(\omega) = \int_{-\infty}^{\infty} p_\theta(t) e^{-i2\pi\omega t}\,dt \tag{4.11}$$

将 $p_\theta(t)$ 的表达式代入:

$$\begin{aligned} P_\theta(\omega) &= \int_{-\infty}^{\infty}\left[\int_{-\infty}^{\infty} f(t\cos\theta - s\sin\theta,\, t\sin\theta + s\cos\theta)\,ds\right] e^{-i2\pi\omega t}\,dt \\ &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f(t\cos\theta - s\sin\theta,\, t\sin\theta + s\cos\theta)\, e^{-i2\pi\omega t}\,dt\,ds \\ &= \iint_{-\infty}^{\infty} f(x,y)\, e^{-i2\pi\omega(x\cos\theta + y\sin\theta)}\,dx\,dy \end{aligned} \tag{4.12}$$

函数 $f(x, y)$ 的二维傅里叶变换定义为:

$$F(u,v) = \iint_{-\infty}^{\infty} f(x,y) e^{-i2\pi(ux+vy)}\,dx\,dy \tag{4.13}$$

现在, 比较 $P_\theta(\omega)$ 的表达式与 $F(u, v)$ 的定义. 如果我们令:

$$u = \omega\cos\theta, \quad v = \omega\sin\theta \tag{4.14}$$

那么:

$$ux + vy = \omega\cos\theta\cdot x + \omega\sin\theta\cdot y = \omega(x\cos\theta + y\sin\theta) \tag{4.15}$$

因此:

$$P_\theta(\omega) = \iint_{-\infty}^{\infty} f(x,y) e^{-i2\pi(ux+vy)}\,dx\,dy = F(u,v)\Big|_{u=\omega\cos\theta,\, v=\omega\sin\theta} \tag{4.16}$$

即:

$$P_\theta(\omega) = F(\omega\cos\theta, \omega\sin\theta) \tag{4.17}$$

证毕. ■

4.2.7 图像的相位操作与平移

我们有一个离散图像 $f[m,n]$, 尺寸为 $M \times N$（行 × 列）. 目标: 证明在频域乘以相位因子 $e^{-j2\pi(\frac{d_x l}{N}+\frac{d_y k}{M})}$ 对应空域的循环平移.

Proof. 图像的 2D-DFT:

$$F[k,l] = \sum_{m=0}^{M-1}\sum_{n=0}^{N-1} f[m,n]e^{-j2\pi\left(\frac{km}{M}+\frac{ln}{N}\right)}, \quad k=0,1,\ldots,M-1, l=0,1,\ldots,N-1 \tag{4.18}$$

在频域乘以相位因子:

$$G[k,l] = F[k,l]\cdot e^{-j2\pi\left(\frac{d_x l}{N}+\frac{d_y k}{M}\right)} \tag{4.19}$$

其中 d_x, d_y 是平移参数（整数）.

对 $G[k,l]$ 进行逆 DFT:

$$g[m,n] = \frac{1}{MN}\sum_{k=0}^{M-1}\sum_{l=0}^{N-1} G[k,l]e^{j2\pi\left(\frac{km}{M}+\frac{ln}{N}\right)} \tag{4.20}$$

代入 $G[k,l]$:

$$g[m,n] = \frac{1}{MN}\sum_{k=0}^{M-1}\sum_{l=0}^{N-1} F[k,l]e^{-j2\pi\left(\frac{d_x l}{N}+\frac{d_y k}{M}\right)}e^{j2\pi\left(\frac{km}{M}+\frac{ln}{N}\right)} \tag{4.21}$$

将 $F[k,l]$ 的 DFT 定义代入:

$$g[m,n] = \frac{1}{MN}\sum_{k=0}^{M-1}\sum_{l=0}^{N-1}\left[\sum_{m'=0}^{M-1}\sum_{n'=0}^{N-1} f[m',n']e^{-j2\pi\left(\frac{km'}{M}+\frac{ln'}{N}\right)}\right]e^{j2\pi\left(\frac{k(m-d_y)}{M}+\frac{l(n-d_x)}{N}\right)} \tag{4.22}$$

重新排列求和顺序:

$$g[m,n] = \sum_{m'=0}^{M-1}\sum_{n'=0}^{N-1} f[m',n']\left[\frac{1}{MN}\sum_{k=0}^{M-1}\sum_{l=0}^{N-1} e^{j2\pi\left(\frac{k(m-d_y-m')}{M}+\frac{l(n-d_x-n')}{N}\right)}\right] \tag{4.23}$$

离散复指数的正交性, 对于行方向:

$$\frac{1}{M}\sum_{k=0}^{M-1} e^{j2\pi\frac{k(m-m')}{M}} = \delta[(m-m') \bmod M] \tag{4.24}$$

对于列方向:

$$\frac{1}{N}\sum_{l=0}^{N-1} e^{j2\pi\frac{l(n-n')}{N}} = \delta[(n-n') \bmod N] \tag{4.25}$$

因此:

$$\frac{1}{MN}\sum_{k=0}^{M-1}\sum_{l=0}^{N-1} e^{j2\pi\left(\frac{k(m-d_y-m')}{M}+\frac{l(n-d_x-n')}{N}\right)} = \delta[(m-d_y-m') \bmod M]\cdot\delta[(n-d_x-n') \bmod N] \tag{4.26}$$

代入正交性关系:

$$g[m,n] = \sum_{m'=0}^{M-1}\sum_{n'=0}^{N-1} f[m',n']\cdot\delta[(m-d_y-m') \bmod M]\cdot\delta[(n-d_x-n') \bmod N] \tag{4.27}$$

因此:

$$g[m,n] = f[(m-d_y) \bmod M, (n-d_x) \bmod N] \tag{4.28}$$

最终结果:

$$\boxed{g[m,n] = f[(m-d_y) \bmod M, (n-d_x) \bmod N]} \tag{4.29}$$

这正好是循环平移的定义:

- 垂直方向循环平移 d_y 像素
- 水平方向循环平移 d_x 像素

特别情况: 当 $d_x \equiv 0 \pmod N$ 且 $d_y \equiv 0 \pmod M$ 时, 图像保持不变.

证毕. ■

傅里叶变换解析

February 20, 2026

L'étude approfondie de la nature est la source la plus féconde des découvertes mathématiques.[1]

—*Joseph Fourier*

自第一次学习傅里叶变换 (Fourier Transform, FT) 时, 我便对教科书上 "时域到频域的变换" 这一解释感到不满足. 这个看似直观的说法背后, 隐藏着三个未被澄清的问题:

1. 什么是时域? 它仅仅是一堆随时间变化的函数吗?
2. 什么是频域? 为什么时域可以通过变换的到频域?
3. 什么是变换? 它真的只是把函数从时间变量改写为频率变量吗?

这些疑问促使我寻找一个更深刻、更统一的数学框架来理解傅里叶变换. 最终, 我在 Parseval 框架理论与谱分析理论中找到了答案—傅里叶变换本质上是一种广义的正交基变换, 更是自伴算子谱分解的具体实现. 在装备希尔伯特空间 (rigged Hilbert space)$\Phi \subset \mathcal{H} \subset \Phi'$ 的框架下:

1. 时域是由 Dirac 函数族 $\{\delta(t-\tau)\}_{\tau\in\mathbb{R}}$ 构成的广义连续 Parseval 框架, 对应着位置算子的广义特征函数;
2. 频域是由复指数函数族 $\{e^{i\omega t}\}_{\omega\in\mathbb{R}}$ 构成的广义连续 Parseval 框架, 对应着动量算子的广义特征函数;
3. 傅里叶变换则是这两个框架之间的幺正变换 (unitary transformation), 它实现了信号在不同 "广义基" 下的表示转换, 本质上是对微分算子进行谱分解的数学工具.

本文旨在从 Parseval 框架与谱分析的视角, 为读者重新解读傅里叶变换的数学本质. 我们将看到, 傅里叶变换不仅是信号分析的利器, 更是理解算子谱理论、量子力学对易关系以及无穷维空间几何结构的窗口. 我们假设读者具备微积分和线性代数的基础知识, 文中会自然地引入实分析、泛函分析等概念, 但力求直观清晰、深入浅出. 通过这一框架, 读者不仅能看到 FT 的 "形", 更能理解其背后的 "神"—它如何统一地描述信号、算子与空间, 如何将复杂的微分运算转化为简单的乘法运算, 以及如何揭示物理系统的基本对称性.

[1] 数学最吸引人的地方, 就是它能够揭示那些看似不同事物之间的深刻联系.

5.1 向量空间

本节内容主要参考 Axler 所著书籍 *Linear Algebra Done Right*.

5.1.1 向量空间

首先是对加法和标量乘法的定义:

Definition 5.1 (加法, 标量乘法)

- 集合 V 上的**加法**是指这样一个函数: 对任意 $u, v \in V$, 它都指定一个对应的元素 $u + v \in V$.
- 集合 V 上的**标量乘法**是指这样一个函数: 对任意 $\lambda \in \mathbb{F}$[a] 和 $v \in V$, 它都指定一个对应的元素 $\lambda v \in V$.

[a] $\mathbb{F}$ 表示实数域 $\mathbb{R}$ 或复数域 $\mathbb{C}$, 下同

有了加法和标量乘法的定义之后, 我们可以定义向量空间:

Definition 5.2 (向量空间 (vector space))

设 V 是一个集合, 其上定义了加法和标量乘法运算. 如果这些运算满足以下条件, 则称 V 是一个**向量空间**:

- **加法交换律 (commutativity)**
  对任意 $u, v \in V$, 有 $u + v = v + u$;
- **结合律 (associativity)**
  对任意 $u, v, w \in V$ 和 $a, b \in \mathbb{F}$, 有 $(u + v) + w = u + (v + w)$ 且 $(ab)v = a(bv)$;
- **零元存在性 (additive identity)**
  存在元素 $0 \in V$, 使得对任意 $v \in V$, 有 $v + 0 = v$;
- **负元存在性 (additive inverse)**
  对任意 $v \in V$, 都存在 $w \in V$, 使得 $v + w = 0$;
- **单位标量作用 (multiplicative identity)**
  对任意 $v \in V$, 有 $1v = v$;
- **分配律 (distributive properties)**
  对任意 $a, b \in \mathbb{F}$ 和 $u, v \in V$, 有 $a(u + v) = au + av$ 且 $(a + b)v = av + bv$.

同时, 以下几何语言符合我们的直觉:

Definition 5.3 (向量, 点)

向量空间中的元素称为**向量**, 有时也称为**点**.

以下给出示例:

Example (一个由三角函数构成的向量空间)

考虑所有形如 $a\sin x + b\cos x$ 的实值函数组成的集合, 其中 $a, b \in \mathbb{R}$:

$$V = \{f : \mathbb{R} \to \mathbb{R} \mid f(x) = a\sin x + b\cos x,\ a, b \in \mathbb{R}\} \tag{5.1}$$

在 V 上定义加法和标量乘法如下:

- **加法**: 对任意 $f, g \in V$, 设 $f(x) = a_1 \sin x + b_1 \cos x$,$g(x) = a_2 \sin x + b_2 \cos x$, 定义

$$(f+g)(x) = f(x) + g(x) = (a_1 + a_2)\sin x + (b_1 + b_2)\cos x \tag{5.2}$$

- **标量乘法**: 对任意 $\lambda \in \mathbb{R}$ 和 $f \in V$, 设 $f(x) = a\sin x + b\cos x$, 定义

$$(\lambda f)(x) = \lambda f(x) = (\lambda a)\sin x + (\lambda b)\cos x \tag{5.3}$$

验证向量空间各项性质:

1. **封闭性**:$f + g$ 和 λf 仍然是 $a\sin x + b\cos x$ 的形式, 所以属于 V.
2. **加法交换律**:$(f+g)(x) = f(x) + g(x) = g(x) + f(x) = (g+f)(x)$.
3. **零函数**: 取 $a = 0, b = 0$, 得到零函数 $0(x) = 0$, 满足 $f + 0 = f$.
4. **负函数**: 对 $f(x) = a\sin x + b\cos x$, 取 $-f(x) = (-a)\sin x + (-b)\cos x$.
5. **标量乘法单位元**:$1 \cdot f = f$.
6. **加法结合律**: 对 $f, g, h \in V$,$[(f+g)+h](x) = (f+g)(x) + h(x) = f(x) + g(x) + h(x) = f(x) + (g+h)(x) = [f + (g+h)](x)$
7. **第一分配律 (标量对向量加法的分配)**: 对 $\lambda \in \mathbb{R}$ 和 $f, g \in V$,$[\lambda(f+g)](x) = \lambda[f(x)+g(x)] = \lambda f(x) + \lambda g(x) = (\lambda f)(x) + (\lambda g)(x) = [\lambda f + \lambda g](x)$
8. **第二分配律 (向量对标量加法的分配)**: 对 $\lambda, \mu \in \mathbb{R}$ 和 $f \in V$,$[(\lambda+\mu)f](x) = (\lambda+\mu)f(x) = \lambda f(x) + \mu f(x) = (\lambda f)(x) + (\mu f)(x) = [\lambda f + \mu f](x)$

具体例子:

- $f(x) = 2\sin x + 3\cos x$,$g(x) = -\sin x + \cos x$
- 加法:$(f+g)(x) = (2-1)\sin x + (3+1)\cos x = \sin x + 4\cos x$
- 标量乘法:$3f(x) = 6\sin x + 9\cos x$
- 零函数:$0(x) = 0\sin x + 0\cos x = 0$

示例5.1.1展示了函数也可以构成向量空间, 函数之间的加法和数乘运算满足向量空间的所有公理.

5.1.2 内积与内积空间

接下来是关于内积和内积空间的定义.

Definition 5.4 (内积)

设 V 是 $\mathbb{F}$ 上的向量空间.V 上的一个**内积**是一个函数, 它将 V 中每个有序对 (u, v) 对应到 $\mathbb{F}$ 中的一个数 $\langle u, v\rangle$, 并且满足以下性质:

1. **正定性 (positivity)**: 对所有 $v \in V$, 有 $\langle v, v\rangle \geq 0$;
2. **确定性 (definiteness)**:$\langle v, v\rangle = 0$ 当且仅当 $v = 0$;
3. **第一个变量的可加性 (additivity in first slot)**: 对所有 $u, v, w \in V$, 有 $\langle u + v, w\rangle = \langle u, w\rangle + \langle v, w\rangle$;
4. **第一个变量的齐次性 (homogeneity in first slot)**[a]: 对所有 $\lambda \in \mathbb{F}$ 和所有 $u, v \in V$, 有 $\langle \lambda u, v\rangle = \lambda\langle u, v\rangle$;
5. **共轭对称性 (conjugate symmetry)**: 对所有 $u, v \in V$, 有 $\langle u, v\rangle = \overline{\langle v, u\rangle}$.

[a] 大多数数学家采用上述方式定义内积, 而许多物理学家则采用另一种定义, 要求齐次性体现在第二个变量而非第一个变量.

Definition 5.5 (内积空间)

一个**内积空间**是一个向量空间 V 连同 V 上的一个内积.

以及关于正交 (orthogonal) 的定义:

Definition 5.6 (正交)

若向量 $u, v \in V$ 满足 $\langle u, v\rangle = 0$, 则称 u 与 v 是**正交**的.

以下给出一个示例:

Example (傅里叶级数正交基)

考虑定义在区间 $[-\pi, \pi]$ 上的连续实值函数空间 $C_{\mathbb{R}}[-\pi, \pi]$[a], 其上定义内积为:

$$\langle f, g\rangle = \int_{-\pi}^{\pi} f(x)g(x)\,dx \tag{5.4}$$

考虑三角函数集合:

$$\left\{\frac{1}{\sqrt{2\pi}}, \frac{\cos x}{\sqrt{\pi}}, \frac{\sin x}{\sqrt{\pi}}, \frac{\cos 2x}{\sqrt{\pi}}, \frac{\sin 2x}{\sqrt{\pi}}, \ldots, \frac{\cos nx}{\sqrt{\pi}}, \frac{\sin nx}{\sqrt{\pi}}, \ldots\right\} \tag{5.5}$$

这些函数在该内积下构成一个正交集合, 因为:

$$\langle \cos mx, \cos nx \rangle = \int_{-\pi}^{\pi} \cos(mx)\cos(nx)\,dx = \begin{cases} 0 & 若 m \neq n \\ \pi & 若 m = n \neq 0 \\ 2\pi & 若 m = n = 0 \end{cases}$$

$$\langle \sin mx, \sin nx \rangle = \int_{-\pi}^{\pi} \sin(mx)\sin(nx)\,dx = \begin{cases} 0 & 若 m \neq n \\ \pi & 若 m = n \neq 0 \end{cases}$$

$$\langle \cos mx, \sin nx \rangle = \int_{-\pi}^{\pi} \cos(mx)\sin(nx)\,dx = 0 \quad 对所有 m, n$$

特别地, 对于任意不同的正整数 $m \neq n$:

- $\cos mx$ 与 $\cos nx$ 正交
- $\sin mx$ 与 $\sin nx$ 正交
- $\cos mx$ 与 $\sin nx$ 正交 (对所有 m, n)

将每个函数除以其范数 (即 $\sqrt{\langle f, f \rangle}$) 后, 我们得到标准正交函数集:

$$\left\{ \frac{1}{\sqrt{2\pi}}, \frac{\cos x}{\sqrt{\pi}}, \frac{\sin x}{\sqrt{\pi}}, \frac{\cos 2x}{\sqrt{\pi}}, \frac{\sin 2x}{\sqrt{\pi}}, \dots \right\} \tag{5.6}$$

这个正交函数系构成了 $L^2[-\pi, \pi]$[b] 空间的一组完备正交基, 是傅里叶级数展开的基础.

[a] $C_{\mathbb{R}}[-\pi, \pi] = \{f : [-\pi, \pi] \to \mathbb{R} \mid f$ 在$[-\pi, \pi]$ 上连续$\}$
[b] 希尔伯特空间 (Hilbert space), 一种内积空间, 下面会提到

示例5.1.2显示, 可以由式5.5构成一个向量空间. 同时, 公式5.5中元素的正交性, 也是正交频分复用 (Orthogonal Frequency Division Multiplexing, OFDM) 技术的数学基础.

5.1.3 希尔伯特空间 (Hilbert space)

Definition 5.7 (希尔伯特空间)

希尔伯特空间就是**完备的内积空间**. 具体来说:
设 $(\mathcal{H}, \langle \cdot, \cdot \rangle)$ 是一个内积空间, 定义范数 $\|x\| = \sqrt{\langle x, x \rangle}$. 如果 $\mathcal{H}$ 在这个范数诱导的度量下是完备的 (即每个柯西序列都收敛), 那么 $\mathcal{H}$ 就是一个希尔伯特空间.

Example (经典的希尔伯特空间)

1. **有限维空间**:

$$\mathbb{R}^n \text{ 和} \mathbb{C}^n \text{ 装备标准内积} \langle x, y \rangle = \sum_{i=1}^{n} x_i \overline{y_i} \tag{5.7}$$

都是希尔伯特空间 (有限维空间自动完备).

2. **序列空间** ℓ^2:

$$\ell^2 = \left\{ (x_n)_{n=1}^{\infty} : x_n \in \mathbb{C}, \sum_{n=1}^{\infty} |x_n|^2 < \infty \right\} \tag{5.8}$$

装备内积 $\langle x, y \rangle = \sum_{n=1}^{\infty} x_n \overline{y_n}$, 这是无限维希尔伯特空间的典型例子.

3. **函数空间** $L^2[a,b]$**(平方可积空间)**:

$$L^2[a,b] = \left\{ f : [a,b] \to \mathbb{C} : \int_a^b |f(x)|^2 \, dx < \infty \right\} \tag{5.9}$$

装备内积 $\langle f, g \rangle = \int_a^b f(x)\overline{g(x)} \, dx$, 这是信号处理和量子力学中最重要的希尔伯特空间.

5.1.4 对偶 (Duality)

Definition 5.8 (线性映射 (linear map))

设 V 和 W 是域 $\mathbb{F}$ 上的向量空间. 从 V 到 W 的**线性映射**是指满足以下性质的函数 $T : V \to W$:

- **可加性**: 对任意 $u, v \in V$, 有 $T(u+v) = Tu + Tv$;
- **齐次性**: 对任意 $\lambda \in \mathbb{F}$ 和 $v \in V$, 有 $T(\lambda v) = \lambda(Tv)$.

Remark

有些数学家使用 “线性变换 (linear transformation)” 这一术语, 其含义与 “线性映射” 相同.

Remark

设 V 和 W 是域 $\mathbf{F}$ 上的向量空间. 所有从 V 到 W 的线性映射构成的集合记作 $\mathcal{L}(V, W)$.

Example

考虑函数空间 $L^1(\mathbb{R})$. **傅里叶变换** $\mathcal{F} : L^1(\mathbb{R}) \to C_0(\mathbb{R})$ 定义为:

$$(\mathcal{F}f)(\omega) = \int_{-\infty}^{\infty} f(t) e^{-i\omega t} \, dt. \tag{5.10}$$

对任意 $f, g \in L^1(\mathbb{R})$ 和 $\alpha, \beta \in \mathbb{C}$, 有:

$$\mathcal{F}(\alpha f + \beta g) = \alpha \mathcal{F} f + \beta \mathcal{F} g, \tag{5.11}$$

因此 $\mathcal{F}$ 是线性映射.

这里解答了我们抛出的问题 3).

Definition 5.9 (线性泛函 (linear functional))

设 V 是域 $\mathbb{F}$ 上的向量空间.V 上的**线性泛函**是指从 V 到 $\mathbb{F}$ 的线性映射. 也就是说, 线性泛函是 $\mathcal{L}(V,\mathbb{F})$ 中的元素..

Definition 5.10 (对偶空间 (dual space, V'))

设 V 是域 $\mathbb{F}$ 上的向量空间.V 的**对偶空间**, 记作 V', 是指由 V 上所有线性泛函构成的向量空间. 换言之,$V' = \mathcal{L}(V,\mathbb{F})$.

Example (对偶空间)

1. **有限维情形**: 设 $V = \mathbb{R}^n$, 其标准基为 $\{e_1,\dots,e_n\}$. 对偶空间 V' 由所有形如

$$\varphi(x) = a_1x_1 + \cdots + a_nx_n, \quad a_i \in \mathbb{R} \tag{5.12}$$

的线性泛函组成. 事实上,V' 与 $\mathbb{R}^n$ 同构: 每个 $\varphi_a(x) = a \cdot x$ 对应向量 $a \in \mathbb{R}^n$.

2. **对偶基**: 对标准基 $\{e_1,\dots,e_n\}$, 其对偶基 $\{\varphi_1,\dots,\varphi_n\} \subset V'$ 定义为

$$\varphi_i(e_j) = \delta_{ij} = \begin{cases} 1 & 若 i = j, \\ 0 & 若 i \neq j. \end{cases} \tag{5.13}$$

具体地,$\varphi_i(x_1,\dots,x_n) = x_i$, 即第 i 个坐标函数.

3. **函数空间情形**: 设 $V = \mathcal{P}_n(\mathbb{R})$ 为次数不超过 n 的多项式空间. 考虑线性泛函

$$\varphi_k(p) = p^{(k)}(0) \quad (k \text{ 阶导数在 } 0 \text{ 点的值}). \tag{5.14}$$

对基 $\{1, x, x^2, \dots, x^n\}$, 其对偶基为 $\{\varphi_0, \varphi_1, \frac{1}{2!}\varphi_2, \dots, \frac{1}{n!}\varphi_n\}$, 其中

$$\frac{1}{k!}\varphi_k(x^j) = \delta_{jk}. \tag{5.15}$$

Example (对偶空间的计算)

设 $V = \mathbb{R}^3$, 考虑线性泛函 $\varphi : \mathbb{R}^3 \to \mathbb{R}$ 定义为

$$\varphi(x,y,z) = 2x - 3y + 5z. \tag{5.16}$$

1. **矩阵表示**:φ 可写为 $\varphi(v) = a^Tv$, 其中 $a = (2,-3,5)^T$.

2. **在基下的坐标**: 对标准基 $e_1 = (1,0,0), e_2 = (0,1,0), e_3 = (0,0,1)$, 有

$$\varphi(e_1) = 2, \quad \varphi(e_2) = -3, \quad \varphi(e_3) = 5. \tag{5.17}$$

因此 φ 在对偶基下的坐标为 $(2,-3,5)$[a].

3. **对偶空间的维数**:$\dim V' = \dim V = 3$, 且 V' 的基可取为坐标函数:

$$\varphi_1(x,y,z) = x, \quad \varphi_2(x,y,z) = y, \quad \varphi_3(x,y,z) = z. \tag{5.18}$$

[a]线性泛函提供了一种不依赖于具体基的向量描述方式

5.1.5 算子, 特征值与特征向量

Definition 5.11 (算子,$\mathcal{L}(V)$)

- 从一个向量空间到其自身的线性映射称为算子.
- 记号 $\mathcal{L}(V)$ 表示 V 上所有算子的集合. 换言之,$\mathcal{L}(V) = \mathcal{L}(V,V)$.

Definition 5.12 (特征值)

设 $T \in \mathcal{L}(V)$. 若存在非零向量 $v \in V$ 使得 $Tv = \lambda v$, 则称数 $\lambda \in \mathbb{F}$ 为 T 的特征值.

Definition 5.13 (特征向量)

设 $T \in \mathcal{L}(V)$, 且 $\lambda \in \mathbb{F}$ 是 T 的特征值. 若向量 $v \in V$ 满足 $v \neq 0$ 且 $Tv = \lambda v$, 则称 v 为对应于特征值 λ 的特征向量.

例如, 对于微分算子 $\frac{d}{dx}$ 而言, 其特征向量为 $e^{\lambda x}(\lambda \in \mathbb{F})$, 特征值为 λ.

Example (位置算子与动量算子的特征值问题)

1. **位置算子** $\hat{x}$

   定义: 在一维空间中, 位置算子 $\hat{x}$ 作用在波函数 $\psi(x)$ 上就是乘以坐标 x:

$$\hat{x}\,\psi(x) = x\,\psi(x) \tag{5.19}$$

   特征方程: 要找特征值 x_0 和特征函数 $\psi_{x_0}(x)$ 使得:

$$\hat{x}\,\psi_{x_0}(x) = x_0\,\psi_{x_0}(x) \tag{5.20}$$

   即:

$$x\,\psi_{x_0}(x) = x_0\,\psi_{x_0}(x) \quad \Longrightarrow \quad (x - x_0)\,\psi_{x_0}(x) = 0 \tag{5.21}$$

   解: 这个方程意味着 $\psi_{x_0}(x)$ 在 $x \neq x_0$ 时必须为零. 唯一满足此条件 (且在平方可积函数空间中非零) 的广义函数是**狄拉克 δ 函数**:

$$\psi_{x_0}(x) = \delta(x - x_0) \tag{5.22}$$

验证:

$$\hat{x}\,\delta(x-x_0) = x\,\delta(x-x_0) = x_0\,\delta(x-x_0) \tag{5.23}$$

(利用 δ 函数的筛选性质)

2. **动量算子** $\hat{p}$

定义: 在一维空间中 (取 $\hbar = 1$):

$$\hat{p} = -i\frac{d}{dx} \tag{5.24}$$

作用为:

$$\hat{p}\,\psi(x) = -i\frac{d\psi}{dx} \tag{5.25}$$

特征方程: 找特征值 p 和特征函数 $\psi_p(x)$ 使得:

$$-i\frac{d\psi_p}{dx} = p\,\psi_p(x) \tag{5.26}$$

这是一个一阶常微分方程:

$$\frac{d\psi_p}{dx} = ip\,\psi_p(x) \tag{5.27}$$

解: 解为平面波:

$$\psi_p(x) = Ce^{ipx} \tag{5.28}$$

其中 C 是归一化常数.

验证:

$$\hat{p}\,e^{ipx} = -i\frac{d}{dx}e^{ipx} = -i(ip)e^{ipx} = p\,e^{ipx} \tag{5.29}$$

关键对易关系: 位置和动量算子满足著名的对易关系:

$$[\hat{x},\hat{p}] = \hat{x}\hat{p} - \hat{p}\hat{x} = i\hbar \tag{5.30}$$

对于任意两个不对易的算子 $\hat{A}$ 和 $\hat{B}$，它们对应的物理量 A 和 B 的测量精度存在根本限制:

$$\Delta A \cdot \Delta B \geq \frac{1}{2}|\langle[\hat{A},\hat{B}]\rangle| \tag{5.31}$$

对于位置和动量, 这个对易关系直接导致了海森堡不确定性原理:

$$\Delta x\,\Delta p \geq \frac{\hbar}{2} \tag{5.32}$$

意味着位置和动量不能同时被精确确定.

Definition 5.14 (谱, Spectral)

设 $T \in \mathcal{L}(V)$, 其中 V 是数域 $\mathbb{F}$(通常为实数域或复数域) 上的向量空间 (可以是有限维或无限维).T 的谱, 记作 $\sigma(T)$, 是指所有满足以下条件的标量 $\lambda \in \mathbb{F}$ 的集合: 算子

$$T - \lambda I \tag{5.33}$$

在 V 上不可逆 (即不存在有界逆算子).
在有限维情形下, 谱 $\sigma(T)$ 恰好是 T 的所有特征值的集合.
在无限维情形下, 谱 $\sigma(T)$ 包含了特征值, 但也可能包含其他使得 $T - \lambda I$ 不是双射 (即使得该算子不可逆) 的非特征值标量. 谱通常可分为以下部分:

- **点谱 (特征值谱)**: 所有使得 $T - \lambda I$ 不是单射的 λ, 即存在非零向量 $v \in V$ 使得 $Tv = \lambda v$.
- **连续谱**: 所有使得 $T - \lambda I$ 是单射、值域稠密但不可逆的 λ.
- **剩余谱**: 所有使得 $T - \lambda I$ 是单射但其值域不稠密的 λ.

Remark

在例 5.1.5 中:

- 位置算子 $\hat{x}$ 的谱是连续的, 由所有实数构成 (在物理中通常取实数), 其特征函数是狄拉克 δ 函数, 它们不属于平方可积函数空间 $L^2(\mathbb{R})$, 而是广义特征函数.
- 动量算子 $\hat{p}$ 的谱也是连续的, 由所有实数构成 (若取 $\hbar = 1$), 其特征函数是平面波 e^{ipx}, 同样不属于 $L^2(\mathbb{R})$, 而是广义特征函数.

这两个算子的谱都是纯连续谱, 没有特征值 (在通常的平方可积函数空间中).

5.1.6 对 FT 的一些观察与猜想

到目前为止, 本文都在介绍空间的定义. 学习内积空间有利于我们完成对时域和频域的定义.
观察下面两个公式:

$$f(t) = \int_{-\infty}^{\infty} f(\tau)\delta(t-\tau)\, d\tau \tag{5.34}$$

$$f(t) = \int_{-\infty}^{\infty} F(\omega)e^{i\omega t}\, d\frac{\omega}{2\pi} \tag{5.35}$$

如果可以将 $\delta(t-\tau)$ 和 $e^{i\omega t}$ 视作时域和频域的 “正交基”, 我们即可完成对时域和频域的完整定义, 也就是说, 可以很好的回答问题 1) 和问题 2).

5.2 连续 Parseval 框架 (Continuous Parseval Frame)

Definition 5.15 (连续 Parseval 框架 (Continuous Parseval Frame))

假设 $\mathcal{H}$ 是一个 Hilbert 空间,(Ω, μ) 是一个测度空间. 如果一个族向量 $\{\phi_\omega\}_{\omega\in\Omega} \subset \mathcal{H}$ 满足对于任何 $f \in \mathcal{H}$, 映射 $\omega \mapsto \langle f, \phi_\omega\rangle$ 是可测的, 且满足以下等式:

$$\|f\|^2 = \int_\Omega |\langle f, \phi_\omega\rangle|^2 d\mu(\omega) \tag{5.36}$$

那么这个向量族 $\{\phi_\omega\}$ 就被称为一个连续 Parseval 框架.

Theorem 5.16 (连续 Parseval 框架重建公式)

设 $\{\phi_\omega\}_{\omega\in\Omega}$ 是 $\mathcal{H}$ 上的一个连续 Parseval 框架. 那么对于任意 $f \in \mathcal{H}$, 有以下弱收敛意义下的重建公式:

$$f = \int_\Omega \langle f, \phi_\omega\rangle \phi_\omega d\mu(\omega) \tag{5.37}$$

即, 对任意 $g \in \mathcal{H}$, 有 $\langle f, g\rangle = \int_\Omega \langle f, \phi_\omega\rangle\langle \phi_\omega, g\rangle d\mu(\omega)$.

我们可以对 $f(t)$ 做如下两种变形, 第一种是利用函数族 $\delta(\tau), \tau \in \mathbb{R}$ 来进行重构:

$$\begin{aligned}
f(t) &= \int_{-\infty}^{\infty} f(\tau)\delta(t-\tau)\, d\tau && (5.38)\\
&= \int_{-\infty}^{\infty} (\int_{-\infty}^{\infty} f(t)\delta(\tau - t)\delta(t-\tau)\, dt) d\tau && (5.39)\\
&= \int_{-\infty}^{\infty} \langle f(t), \delta(\tau - t)\rangle \delta(t-\tau)\, d\tau && (5.40)\\
&= \int_{-\infty}^{\infty} \langle f(t), \delta(t - \tau)\rangle \delta(t-\tau)\, d\tau && (5.41)
\end{aligned}$$

第二种是利用函数族 $e^{i\omega t}, \omega \in \mathbb{R}$ 来进行重构:

$$\begin{aligned}
f(t) &= \int_{-\infty}^{\infty} F(\omega) e^{i\omega t}\, d\frac{\omega}{2\pi} && (5.42)\\
&= \int_{-\infty}^{\infty} (\int_{-\infty}^{\infty} f(t) e^{-i\omega t}\, dt) e^{i\omega t}\, d\frac{\omega}{2\pi} && (5.43)\\
&= \int_{-\infty}^{\infty} \langle f(t), e^{i\omega t}\rangle e^{i\omega t}\, d\frac{\omega}{2\pi} && (5.44)
\end{aligned}$$

注意到 $\delta(t-\tau)$ 和 $e^{i\omega t}$ 都不在希尔伯特空间 $\mathcal{H}$ 中 (不是平方可积函数). 因此, 我们需要更加完备的数学框架.

5.3 装备希尔伯特空间 (rigged Hilbert space)

为解决 δ 函数不在希尔伯特空间中的问题, 由量子力学发展出了装备希尔伯特空间的理论.

5.3.1 装备希尔伯特空间 (rigged Hilbert space)

Gelfand 三元组 (Gelfand triple), 也称为装备 Hilbert 空间, 是泛函分析中一个重要的结构, 用于将 Hilbert 空间理论与广义函数 (分布) 理论统一起来.

Definition 5.17 (装备希尔伯特空间)

装备希尔伯特空间 (Rigged Hilbert Space), 也称为 **Gelfand 三元组** (Gelfand triple), 是由三个嵌套的拓扑向量空间构成的结构:

$$\Phi \subset \mathcal{H} \subset \Phi^* \tag{5.45}$$

其中:

1. Hilbert 空间 $\mathcal{H}$: 通常是我们主要工作的空间, 例如 $L^2(\mathbb{R}^n)$.
2. 测试函数空间 Φ:
   - Φ 是 $\mathcal{H}$ 的一个稠密子空间.
   - Φ 上赋予一个比 $\mathcal{H}$ 范数更强的拓扑 (通常由一族半范数定义), 使得 Φ 成为一个完备的、可分的、局部凸的拓扑向量空间 (通常是 Fréchet 空间或可数 Hilbert 空间).
   - 典型例子:Schwartz 空间 $\mathcal{S}(\mathbb{R}^n)$.
3. 对偶空间 Φ':
   - Φ' 是 Φ 的连续对偶空间, 即所有连续线性泛函 $T : \Phi \to \mathbb{C}$ 构成的空间.
   - Φ' 中的元素称为广义函数 (分布).
   - 赋予 Φ' 弱拓扑 (即逐点收敛拓扑).

Example (量子力学应用)

量子力学中最常见的装备希尔伯特空间是:

$$\mathcal{S}(\mathbb{R}^n) \subset L^2(\mathbb{R}^n) \subset \mathcal{S}'(\mathbb{R}^n) \tag{5.46}$$

其中:

- $\mathcal{S}(\mathbb{R}^n)$: **施瓦茨空间** (Schwartz space), 由所有速降光滑函数组成

$$\mathcal{S}(\mathbb{R}^n) = \{f \in C^\infty(\mathbb{R}^n) : \sup_{x\in\mathbb{R}^n} |x^\alpha \partial^\beta f(x)| < \infty \ \forall \alpha, \beta\} \tag{5.47}$$

- $L^2(\mathbb{R}^n)$: 平方可积函数空间, 标准量子力学态空间
- $\mathcal{S}'(\mathbb{R}^n)$: **缓增分布空间** (tempered distributions),$\mathcal{S}(\mathbb{R}^n)$ 的连续对偶

在量子力学中, 装备希尔伯特空间解决了以下问题:

1. **连续谱算子的本征矢**: 位置算符 $\hat{x}$ 和动量算符 $\hat{p}$ 在 $L^2(\mathbb{R})$ 中没有真正的本征矢, 但在 $\mathcal{S}'(\mathbb{R})$

中有:

$$\hat{x}\delta(x-x_0) = x_0\delta(x-x_0), \quad \hat{p}e^{ip_0x/\hbar} = p_0e^{ip_0x/\hbar} \tag{5.48}$$

其中 $\delta(x-x_0) \in \mathcal{S}'(\mathbb{R})$,$e^{ip_0x/\hbar} \in \mathcal{S}'(\mathbb{R})$.(因为 $\delta(x-x_0)$ 和 $e^{ip_0x/\hbar}$ 都是 $\mathcal{S}(\mathbb{R})$ 上的线性泛函, 证明略. 同时注意 5.1.6 小节中我们想要的 "正交基")

2. **傅里叶变换**: 在 $\mathcal{S}(\mathbb{R}) \subset L^2(\mathbb{R}) \subset \mathcal{S}'(\mathbb{R})$ 上, 傅里叶变换是良定义的同构. 特别地, 傅里叶变换将位置表象与动量表象联系起来:

$$\mathcal{F} : \mathcal{S}(\mathbb{R}) \to \mathcal{S}(\mathbb{R}), \quad (\mathcal{F}\psi)(p) = \frac{1}{\sqrt{2\pi\hbar}} \int_{-\infty}^{\infty} e^{-ipx/\hbar}\psi(x)dx \tag{5.49}$$

在此变换下, 位置算符和动量算符的角色互换.

5.3.2 Gelfand-Naimark-Maurin 定理

Theorem 5.18 (Gelfand-Naimark-Maurin 定理)

设 A 是装备希尔伯特空间 $(\Phi, \mathcal{H}, \Phi^*)$ 上的自伴算子, 则存在测度空间 (Λ, μ) 和一系列广义特征向量 $e_\lambda \in \Phi^*$, 使得对于任意 $f \in \Phi$, 其谱分解可以写为:

$$f = \int_\Lambda \hat{f}(\lambda)e_\lambda \, d\mu(\lambda) \tag{5.50}$$

其中,$\hat{f}(\lambda) = \langle f, e_\lambda \rangle$

对于量子力学中的位置算子和动量算子,Gelfand-Naimark-Maurin 定理的具体形式如下:

Example (位置算子 $\hat{x}$)

设装备希尔伯特空间为 $(\mathcal{S}(\mathbb{R}), L^2(\mathbb{R}), \mathcal{S}'(\mathbb{R}))$, 其中 $\mathcal{S}(\mathbb{R})$ 是 Schwartz 空间,$\mathcal{S}'(\mathbb{R})$ 是缓增分布空间. 自伴算子 $\hat{x} : f(x) \mapsto xf(x)$. 则存在测度空间 $(\mathbb{R}, dx)$ 和广义特征向量 $e_\lambda \in \mathcal{S}'(\mathbb{R})$,$e_\lambda(x) = \delta(x-\lambda)$, 使得对于任意 $f \in \mathcal{S}(\mathbb{R})$, 其谱分解为:

$$f = \int_\mathbb{R} \hat{f}(\lambda)e_\lambda \, d\lambda, \quad \hat{f}(\lambda) = \langle f, e_\lambda \rangle = f(\lambda). \tag{5.51}$$

Example (动量算子 $\hat{p}$)

设装备希尔伯特空间为 $(\mathcal{S}(\mathbb{R}), L^2(\mathbb{R}), \mathcal{S}'(\mathbb{R}))$, 自伴算子 $\hat{p} = -i\hbar\frac{d}{dx}$(取 $\hbar = 1$). 则存在测度空间 $(\mathbb{R}, dp)$ 和广义特征向量 $e_p \in \mathcal{S}'(\mathbb{R})$,$e_p(x) = \frac{1}{\sqrt{2\pi}}e^{ipx}$, 使得对于任意 $f \in \mathcal{S}(\mathbb{R})$, 其谱分解为:

$$f = \int_\mathbb{R} \hat{f}(p)e_p \, dp, \quad \hat{f}(p) = \langle f, e_p \rangle = \frac{1}{\sqrt{2\pi}} \int_\mathbb{R} f(x)e^{-ipx} \, dx. \tag{5.52}$$

这里 $\langle \cdot, \cdot \rangle$ 表示 $\mathcal{S}'$ 与 $\mathcal{S}$ 之间的对偶配对, 在计算时需理解为广义函数意义下的积分.

5.4 谱定理 (Spectral Theorem)

谱定理 (Spectral Theorem) 是线性代数中 “对角化” 概念在一般算子空间上的推广. 它断言: 对于一类重要的算子 (自伴算子), 我们总能找到一个合适的基 (或测度), 使得算子的作用表现为简单的标量乘法.

5.4.1 有限维情形: 自伴算子的谱分解

在有限维希尔伯特空间 $\mathcal{H}$ 中, 谱定理即是对称 (或厄米特) 矩阵的对角化:

Theorem 5.19 (有限维谱定理)

设 $T \in \mathcal{L}(V)$ 是自伴算子 ($T = T^*$), 则存在 V 的一组标准正交基 $\{e_1, \ldots, e_n\}$, 由 T 的特征向量组成. 算子 T 可以表示为:

$$T = \sum_{i=1}^{n} \lambda_i |e_i\rangle\langle e_i| \tag{5.53}$$

其中 $\lambda_i \in \sigma(T)$ 是特征值,$|e_i\rangle$ 是列向量,$\langle e_i|$ 是行向量, $|e_i\rangle\langle e_i|$ 是向对应特征子空间的投影算子.

5.4.2 无限维情形: 连续谱与谱测度

当算子具有连续谱时, 求和符号 $\sum$ 必须演变为积分符号 $\int$.

Theorem 5.20 (无限维谱定理 - 算子形式)

设 $\mathcal{H}$ 为希尔伯特空间,T 为 H 上的有界自伴算子. 则存在唯一的谱测度 (Spectral Measure)E, 使得:

$$T = \int_{\sigma(T)} \lambda \, dE(\lambda) \tag{5.54}$$

Remark

只有自伴算子的谱 $\sigma(T)$ 才是实数轴上的子集, 且其剩余谱 (Residual Spectrum) 一定为空. 这意味着自伴算子的谱结构最清晰, 物理意义最明确

5.4.3 谱展开

定理5.16即为希尔伯特空间中的谱展开.
定理5.18即为装备希尔伯特空间中的谱展开.

Example (自伴算子 $A = -i\frac{d}{dx}$ 的谱展开)

考虑希尔伯特空间 $H = L^2(\mathbb{R})$ 上的自伴算子 $A = -i\frac{d}{dx}$(定义在适当域上, 如 Sobolev 空间 $H^1(\mathbb{R})$). 根据谱定理, 对于自伴算子 A, 存在唯一的谱测度 E 使得

$$A = \int_{\mathbb{R}} \lambda \, dE(\lambda). \tag{5.55}$$

谱定理的另一形式指出, 存在酉算子 $U : H \to L^2(\mathbb{R}, d\mu)$ 将 A 转换为乘法算子, 即

$$(UAU^{-1}\phi)(\lambda) = \lambda\phi(\lambda), \quad \forall \phi \in L^2(\mathbb{R}, d\mu), \tag{5.56}$$

其中 μ 是 A 的谱测度. 对于 $A = -id/dx$, 其谱为连续谱 $\sigma(A) = \mathbb{R}$, 且谱测度等价于勒贝格测度. 为了得到 U 的具体形式, 求解 A 的广义特征值问题:

$$A\phi_\lambda = \lambda\phi_\lambda \quad \Rightarrow \quad -i\frac{d}{dx}\phi_\lambda(x) = \lambda\phi_\lambda(x). \tag{5.57}$$

解此微分方程得 $\phi_\lambda(x) = Ce^{i\lambda x}$, 其中 C 为归一化常数. 广义特征函数不在 $L^2(\mathbb{R})$ 中, 但可在分布意义下使用. 为使广义特征函数满足 δ 归一化条件:

$$\int_{\mathbb{R}} \phi_\lambda(x)\overline{\phi_{\lambda'}(x)}\, dx = \delta(\lambda - \lambda'), \tag{5.58}$$

计算得

$$\int_{\mathbb{R}} Ce^{i\lambda x}\overline{Ce^{i\lambda' x}}\, dx = |C|^2 \int_{\mathbb{R}} e^{i(\lambda-\lambda')x}\, dx = 2\pi|C|^2\delta(\lambda - \lambda'), \tag{5.59}$$

因此取 $C = \frac{1}{\sqrt{2\pi}}$[a], 即

$$\phi_\lambda(x) = \frac{1}{\sqrt{2\pi}}e^{i\lambda x}. \tag{5.60}$$

根据谱展开的思想, 任意函数 $f \in L^2(\mathbb{R}) \cap L^1(\mathbb{R})$ 可表示为广义特征函数的连续叠加:

$$f(x) = \int_{\mathbb{R}} c(\lambda)\phi_\lambda(x)\, d\lambda, \tag{5.61}$$

其中系数 $c(\lambda)$ 由 f 与 ϕ_λ 的内积给出:

$$c(\lambda) = \langle f, \phi_\lambda\rangle = \int_{\mathbb{R}} f(x)\overline{\phi_\lambda(x)}\, dx = \frac{1}{\sqrt{2\pi}}\int_{\mathbb{R}} f(x)e^{-i\lambda x}\, dx. \tag{5.62}$$

定义 $\hat{f}(\lambda) = c(\lambda)$, 即得傅里叶变换:

$$\hat{f}(\lambda) = \frac{1}{\sqrt{2\pi}}\int_{\mathbb{R}} f(x)e^{-i\lambda x}\, dx. \tag{5.63}$$

代入展开式即得傅里叶逆变换:

$$f(x) = \int_{\mathbb{R}} \hat{f}(\lambda)\phi_\lambda(x)\, d\lambda = \frac{1}{\sqrt{2\pi}}\int_{\mathbb{R}} \hat{f}(\lambda)e^{i\lambda x}\, d\lambda. \tag{5.64}$$

上述变换 $U : f \mapsto \hat{f}$ 是酉算子, 它将 A 转化为乘法算子:

$$(UAU^{-1}\hat{f})(\lambda) = \lambda\hat{f}(\lambda), \tag{5.65}$$

这正是谱定理所保证的. 因此, 傅里叶变换与逆变换可视为自伴算子 $A = -id/dx$ 的谱表示的具体实现.

[a]取 $C = \frac{1}{2\pi}$ 即为常见形式的 FT

Example (拉普拉斯算子的谱展开)

考虑一维拉普拉斯算子 $A = -\frac{d^2}{dx^2}$, 定义在希尔伯特空间 $H = L^2(\mathbb{R})$ 的适当子集上 (例如 Sobolev 空间 $H^2(\mathbb{R})$). 该算子是自伴的, 其谱为连续谱 $\sigma(A) = [0, \infty)$. 下面通过谱定理推导相应的变换—傅里叶变换及其逆变换.
根据谱定理, 存在谱测度 E 使得

$$A = \int_0^\infty \lambda \, dE(\lambda), \tag{5.66}$$

且存在酉算子 $U : H \to L^2(\mathbb{R}, d\mu)$ 将 A 转换为乘法算子. 为了显式构造 U, 求解广义特征值问题:

$$A\phi = \lambda\phi \quad \Rightarrow \quad -\frac{d^2}{dx^2}\phi(x) = \lambda\phi(x). \tag{5.67}$$

令 $\lambda = k^2 (k \in \mathbb{R})$, 则方程化为

$$\phi''(x) = -k^2\phi(x), \tag{5.68}$$

其基本解为 e^{ikx} 和 e^{-ikx}. 选择参数 $k \in \mathbb{R}$, 广义特征函数可取为

$$\phi_k(x) = Ce^{ikx}, \tag{5.69}$$

对应特征值 $\lambda = k^2$. 注意 k 与 $-k$ 对应相同的 λ, 因此谱具有二重性.
广义特征函数不在 $L^2(\mathbb{R})$ 中, 但可在分布意义下使用. 为使其满足 δ 归一化:

$$\int_{\mathbb{R}} \phi_k(x)\overline{\phi_{k'}(x)} \, dx = \delta(k - k'), \tag{5.70}$$

计算左式:

$$\int_{\mathbb{R}} Ce^{ikx}\overline{Ce^{ik'x}} \, dx = |C|^2 \int_{\mathbb{R}} e^{i(k'-k)x} \, dx = 2\pi|C|^2\delta(k' - k) = 2\pi|C|^2\delta(k - k'). \tag{5.71}$$

因此取 $C = \frac{1}{\sqrt{2\pi}}$[a], 即

$$\phi_k(x) = \frac{1}{\sqrt{2\pi}}e^{ikx}. \tag{5.72}$$

对于 $f \in L^2(\mathbb{R}) \cap L^1(\mathbb{R})$, 按广义特征函数展开:

$$f(x) = \int_{\mathbb{R}} c(k)\phi_k(x) \, dk, \tag{5.73}$$

其中系数 $c(k)$ 由 f 与 ϕ_k 的内积给出:

$$c(k) = \langle f, \phi_k \rangle = \int_{\mathbb{R}} f(x)\overline{\phi_k(x)} \, dx = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} f(x)e^{-ikx} \, dx. \tag{5.74}$$

定义 $\hat{f}(k) = c(k)$, 即得傅里叶变换:

$$\hat{f}(k) = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} f(x) e^{-ikx}\, dx. \tag{5.75}$$

代入展开式即得傅里叶逆变换:

$$f(x) = \int_{\mathbb{R}} \hat{f}(k) \phi_k(x)\, dk = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \hat{f}(k) e^{ikx}\, dk. \tag{5.76}$$

变换 $U : f \mapsto \hat{f}$ 是酉算子, 且将拉普拉斯算子转化为乘法算子:

$$(UAU^{-1}\hat{f})(k) = k^2 \hat{f}(k). \tag{5.77}$$

这验证了谱定理: 在变换后的空间 $L^2(\mathbb{R}, dk)$ 中,A 表现为乘以 k^2 的算子.
通过一维拉普拉斯算子的谱展开, 我们同样导出了傅里叶变换与逆变换. 这再次表明傅里叶变换是实现自伴算子对角化的具体酉变换, 其中广义特征函数 $e^{ikx}/\sqrt{2\pi}$ 构成连续谱下的 "基". 该推导揭示了傅里叶变换在分析微分算子谱理论中的核心作用.

[a] 取 $C = \frac{1}{2\pi}$ 即为常见形式的 FT

5.5 总结

现在, 我们可以对时域、频域和傅里叶变换给出一个统一而清晰的解释:

时域是由广义函数簇 $\{\delta(t-\tau)\}_{\tau\in\mathbb{R}}$ 作为 "连续基" 所张成的空间. 直观上, 时域就是我们通常所说的信号 $f(t)$ 所在的函数空间 (例如 $L^2(\mathbb{R})$). 狄拉克 δ 函数 $\delta(t-\tau)$ 是广义函数 (分布), 它满足筛选性质:

$$\int_{-\infty}^{\infty} f(t)\delta(\tau - t)\, dt = f(\tau). \tag{5.78}$$

因此, 任意充分正则的函数 f 都可以写成

$$f(t) = \int_{\mathbb{R}} f(\tau)\delta(t-\tau)\, d\tau, \tag{5.79}$$

这相当于将 f 按 "时间点" τ 进行分解.$\delta(t-\tau)$ 可以看作是时间平移算子 (或位置算子) 的广义特征函数, 对应的特征值就是 τ. 虽然它们不属于平方可积空间 L^2, 但在装备希尔伯特空间 (如 $\mathcal{S}'(\mathbb{R})$) 的框架下, 它们构成了时域的连续 "广义基".

频域是由复指数函数簇 $\{e^{i\omega t}\}_{\omega\in\mathbb{R}}$ 作为 "连续正交基" 所张成的空间. 频域是傅里叶变换后函数 $F(\omega)$ 所在的空间. 函数 $e^{i\omega t}$ 是微分算子 $-i\frac{d}{dt}$(动量算子) 的广义特征函数, 满足

$$-i\frac{d}{dt}e^{i\omega t} = \omega e^{i\omega t}. \tag{5.80}$$

它们在分布意义下具有正交性:

$$\int_{-\infty}^{\infty} e^{i(\omega-\omega')t}\, dt = 2\pi\delta(\omega - \omega'), \tag{5.81}$$

因此构成频域的连续 “正交基”. 同时, 它们也是拉普拉斯算子 $\frac{d^2}{dt^2}$ 的广义特征函数, 对应的特征值为 $-\omega^2$.

傅里叶变换是时域与频域之间的正交基变换 (幺正变换). 傅里叶正变换

$$\mathcal{F} : f(t) \mapsto F(\omega) = \int_{\mathbb{R}} f(t) e^{-i\omega t}\, dt. \tag{5.82}$$

将信号 f 从时域的 δ 基表示 (即 $f(t)$ 本身) 转换到频域的指数基表示 (系数 $F(\omega)$). 由于两种广义基在适当的内积下是正交的, 该变换保持内积不变, 即满足 Parseval 恒等式:

$$\int |f(t)|^2 dt = \int |F(\omega)|^2 \frac{d\omega}{2\pi}, \tag{5.83}$$

因此, 傅里叶变换实际上是无穷维希尔伯特空间中的一个正交变换 (更准确地说, 是酉算子), 类似于有限维空间中从一个正交基到另一个正交基的变换.

傅里叶逆变换是时域信号关于拉普拉斯算子 (或动量算子) 的谱展开. 逆变换

$$f(t) = \frac{1}{2\pi} \int_{\mathbb{R}} F(\omega) e^{i\omega t}\, d\omega \tag{5.84}$$

将时域信号 f 表示为复指数函数 $e^{i\omega t}$ 的连续线性组合. 由于 $e^{i\omega t}$ 是微分算子 $-i\frac{d}{dt}$ 或拉普拉斯算子 $\frac{d^2}{dt^2}$ 的广义特征函数, 这一展开正是这些自伴算子的谱展开. 傅里叶变换实际上实现了所有平移不变线性算子 (特别是微分算子) 的对角化: 在频域中, 这些算子的作用简化为乘法运算.

这些观点统一于调和分析与算子理论的框架: 傅里叶变换是平移算子群表示论中的谱分解工具, 同时实现了函数在时域和频域两种对偶广义基之间的转换, 从而为求解微分方程、分析信号以及理解物理系统的频谱结构提供了核心的数学基础.

Chapter 6

高斯泼溅算法简介

March 06, 2026

Es ist nicht das Wissen, sondern das Lernen, nicht das Besitzen, sondern das Erwerben, nicht das Dasein, sondern das Hinkommen, was den größten Genuß gewährt.[1]

—*Carl Friedrich Gauss*

6.1 高斯泼溅简介

高斯泼溅 (Gaussian Splatting) 是一种基于三维点云的直接渲染技术, 其核心思想是通过高斯核函数模型将离散的空间点转换为连续的视觉表示. 该方法避免了传统三维重建中必需的表面网格化步骤, 直接对原始点数据进行可视化处理, 在科学计算可视化、医学成像和地理信息系统等领域具有重要应用价值.

从数学本质上讲, 高斯泼溅为每个三维空间点赋予一个三维高斯函数. 该函数在空间中表现为一个椭球状的密度场, 中心密度最高, 沿径向按指数规律衰减. 在渲染过程中, 每个三维高斯椭球通过相机投影变换为二维高斯椭圆, 随后按深度排序并通过前向透明度合成 (alpha blending) 进行融合, 最终生成连续平滑的渲染图像.

该技术的优势主要体现在三个方面: 首先, 它保持了原始数据的完整性, 避免了网格重建过程中的信息损失和人为误差; 其次, 高斯函数的自然衰减特性使得渲染结果具有连续性, 特别适合表现模糊边界和渐变特征; 最后, 算法支持各向异性调整, 能够通过协方差矩阵控制椭球的形状和方向, 从而准确表达材料的空间各向异性特征.

在技术实现层面, 高斯泼溅建立了一套完整的渲染管线. 输入的点云数据经过参数化处理, 为每个点分配位置、协方差矩阵、颜色和不透明度等属性. 随后, 系统执行三维到二维的投影变换, 将三维高斯椭球映射为屏幕空间的二维高斯分布. 在光栅化阶段, 通过深度排序并执行前向透明度合成处理椭球间的遮挡关系, 最终生成输出图像.

本文将简单介绍高斯泼溅算法的数学原理.

6.2 高斯椭球: 定义与性质

[1] 并非知识本身, 而是学习的过程; 并非占有, 而是获取; 并非存在, 而是抵达——这些才给予我们最大的愉悦.

6.2.1 数学定义

三维高斯函数构成了高斯泼溅技术的数学基础. 其标准形式定义为:

$$G(\mathbf{x}) = \exp\left(-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})\right) \tag{6.1}$$

其中 $\mathbf{x} \in \mathbb{R}^3$ 表示空间中的任意点,$\boldsymbol{\mu} \in \mathbb{R}^3$ 是高斯椭球的中心位置,$\boldsymbol{\Sigma} \in \mathbb{R}^{3\times 3}$ 是协方差矩阵. 该矩阵必须是实对称正定矩阵, 这一性质保证了高斯函数在三维空间中形成一个椭球状的密度分布. 协方差矩阵 $\boldsymbol{\Sigma}$ 的几何意义至关重要, 它完整地定义了椭球的形状、大小和空间取向. 通过矩阵分解, 可以将 $\boldsymbol{\Sigma}$ 表示为:

$$\boldsymbol{\Sigma} = \mathbf{R}\mathbf{S}\mathbf{S}^\top\mathbf{R}^\top \tag{6.2}$$

其中 $\mathbf{S} = \mathrm{diag}(s_x, s_y, s_z)$ 是对角缩放矩阵, 其对角线元素 s_x, s_y, s_z 分别表示沿三个主轴方向的缩放因子.$\mathbf{R} \in \mathbb{R}^{3\times 3}$ 是旋转矩阵, 描述了椭球主轴在空间中的方向.

在实际应用中, 旋转矩阵 $\mathbf{R}$ 通常采用四元数 (quaternion) 表示. 四元数 $\mathbf{q} = (q_w, q_x, q_y, q_z)$ 是一个四维超复数, 满足 $q_w^2 + q_x^2 + q_y^2 + q_z^2 = 1$. 与欧拉角相比, 四元数表示具有以下优势: 避免了万向节锁问题, 插值计算更加平滑 (通过球面线性插值 SLERP), 且存储效率更高 (仅需 4 个浮点数). 从四元数到旋转矩阵的转换公式为:

$$\mathbf{R} = \begin{pmatrix} 1-2(q_y^2+q_z^2) & 2(q_xq_y - q_wq_z) & 2(q_xq_z + q_wq_y) \\ 2(q_xq_y + q_wq_z) & 1-2(q_x^2+q_z^2) & 2(q_yq_z - q_wq_x) \\ 2(q_xq_z - q_wq_y) & 2(q_yq_z + q_wq_x) & 1-2(q_x^2+q_y^2) \end{pmatrix} \tag{6.3}$$

6.2.2 光学属性建模

基础颜色表示

每个高斯椭球除了几何参数外, 还需要定义其光学特性. 最简单的表示方式是赋予每个椭球一个 RGB 颜色值 $\mathbf{c} \in [0,1]^3$, 该颜色在传统实现中被视为与视角无关的常量. 然而, 这种简化表示无法捕捉真实世界中材质外观随观察角度变化的现象, 特别是对于具有镜面反射或复杂表面散射特性的材料.

球谐函数表示法

为更精确地建模视角相关的外观变化, 现代高斯泼溅系统普遍采用球谐函数 (Spherical Harmonics)[2]作为颜色表示的基础数学工具.

球谐函数 $Y_l^m(\theta, \phi)$ 构成了一组定义在单位球面上的完备正交基函数, 其中 $l \geq 0$ 表示函数的阶数,$m \in [-l, l]$ 是阶内索引,(θ, ϕ) 为球坐标系下的方向角. 在计算机图形学中, 球谐函数因其良好的数学性质而被广泛使用: 它们具有旋转不变性, 能够通过有限阶截断有效近似低频信号, 且计算相对高效.

[2]球谐函数是拉普拉斯算子在球坐标下的特征函数, 特征函数之间互相正交. 球坐标下性质良好的函数可由球谐函数进行谱展开, 对应直角坐标系的谱展开可参考示例5.4.3. 一般而言, 无界区域的谱是连续谱, 而球坐标系中两个角度坐标都是有界的, 在相应的边界条件下, 使得拉普拉斯算子在两个角度方向上的谱是离散谱.

将视角相关的颜色函数 $c(\mathbf{d})$ 表示为球谐基函数的线性组合:

$$c(\mathbf{d}) = \sum_{l=0}^{L} \sum_{m=-l}^{l} c_l^m Y_l^m(\mathbf{d}) \tag{6.4}$$

这里 $\mathbf{d}$ 是观察方向 (单位向量),c_l^m 是对应的球谐系数 (通常为三维 RGB 向量),L 是使用的最大阶数. 实际应用中,$L = 3$(对应 16 个系数) 或 $L = 4$(对应 25 个系数) 通常能在表达能力和存储成本之间取得良好平衡.

各阶球谐系数具有明确的物理意义: 零阶系数 ($l = 0$) 表示环境光或平均颜色; 一阶系数 ($l = 1$) 对应漫反射光照的基本方向性; 二阶及以上系数则捕获更复杂的照明效应, 包括镜面高光和材质细节. 这种层次化表示使得系统能够以可控的复杂度模拟从粗糙到精细的各种材质外观.

不透明度控制

不透明度参数 $\alpha \in [0, 1]$ 是高斯椭球的另一个关键光学属性, 它控制着该椭球对最终像素颜色的贡献程度. 在混合计算中, 空间位置 $\mathbf{x}$ 处的有效不透明度权重由下式给出:

$$w(\mathbf{x}) = \alpha \cdot G(\mathbf{x}) \tag{6.5}$$

这一设计使得椭球中心区域贡献最大, 边缘区域贡献逐渐衰减为零, 从而产生自然的羽化效果.

6.2.3 空间变换与投影

高斯椭球在仿射变换 $\mathbf{x}' = \mathbf{A}\mathbf{x} + \mathbf{b}$ 下具有明确的变换规律. 中心位置按 $\boldsymbol{\mu}' = \mathbf{A}\boldsymbol{\mu} + \mathbf{b}$ 变换, 而协方差矩阵遵循 $\boldsymbol{\Sigma}' = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top$ 的变换规则. 这一性质使得高斯表示能够自然地适应场景中的刚体运动、非均匀缩放等变换, 为动态场景的渲染奠定了数学基础.

将三维高斯椭球投影到二维屏幕空间是渲染流程中的关键步骤. 这一过程涉及三个主要计算: 首先, 椭球中心通过相机模型投影到图像平面, 得到二维中心坐标. 接着, 计算透视投影变换在当前中心位置处的雅可比矩阵 $\mathbf{J}$, 该矩阵编码了投影引起的局部线性变换. 最后, 三维协方差矩阵通过 $\boldsymbol{\Sigma}'_{2D} = \mathbf{J}\boldsymbol{\Sigma}_{3D}\mathbf{J}^\top$ 转换为二维形式, 得到屏幕空间中的椭圆表示.

6.2.4 混合合成与渲染优化

深度排序策略

由于透明度混合的顺序依赖性, 高斯椭球必须按深度进行排序. 实践中根据性能和质量的不同需求, 可采用多种排序策略: 完全排序对所有椭球进行精确的深度排序, 虽计算成本较高但能保证正确的混合结果; 分块排序将屏幕划分为多个区域, 在各区域内独立排序, 平衡了效率与准确性; 近似排序则采用启发式方法快速获得基本正确的顺序, 适用于对实时性要求极高的应用场景.

Alpha 混合公式

对于按深度排序后的椭球序列, 最终像素颜色通过经典的 over 操作符计算:

$$C_{\text{final}} = \sum_{i=1}^{N} c_i \alpha_i \prod_{j=1}^{i-1} (1 - \alpha_j) \tag{6.6}$$

其中 c_i 是第 i 个椭球的颜色 (可能通过球谐函数计算得到),α_i 是该椭球在当前像素位置的不透明度权重, 乘积项 $\prod_{j=1}^{i-1}(1-\alpha_j)$ 表示前面所有椭球的累积透光率. 这一公式确保了物理正确的透明度混合效果.

参数优化框架

在实际应用中, 高斯椭球的各项参数通常通过可微渲染框架进行端到端优化. 初始化阶段根据输入点云的局部密度分布设置椭球位置和初始尺度; 随后采用基于梯度的优化算法 (如随机梯度下降) 同时优化所有几何和光学参数; 优化过程中还会根据重建质量动态调整椭球分布——在重建不足的区域增加椭球密度, 对冗余椭球进行剪枝, 并根据视角变化自适应调整椭球形状, 从而实现高效且高质量的场景表示.

6.3 高斯椭球的渲染技术

6.3.1 投影变换的数学推导

相机模型与坐标变换

设世界坐标系中的点 $\mathbf{x}_w = (x_w, y_w, z_w)^\top$, 通过相机外参变换到相机坐标系. 相机外参包含旋转矩阵 $\mathbf{R}_c \in \mathbb{R}^{3\times 3}$ 和平移向量 $\mathbf{t}_c \in \mathbb{R}^3$, 变换公式为:

$$\mathbf{x}_c = \mathbf{R}_c \mathbf{x}_w + \mathbf{t}_c \tag{6.7}$$

其中 $\mathbf{x}_c = (x_c, y_c, z_c)^\top$ 是点在相机坐标系中的坐标. 这一线性变换保持了三维空间的度量关系, 为后续投影计算奠定了基础.

协方差矩阵的坐标系变换

高斯椭球的协方差矩阵 $\mathbf{\Sigma}_w$ 定义在世界坐标系中. 当椭球从世界坐标系变换到相机坐标系时, 其协方差矩阵遵循仿射变换规则:

$$\mathbf{\Sigma}_c = \mathbf{R}_c \mathbf{\Sigma}_w \mathbf{R}_c^\top \tag{6.8}$$

这一变换仅包含旋转部分, 因为协方差矩阵描述的是椭球的形状和方向, 不受平移影响. 变换后的 $\mathbf{\Sigma}_c$ 表示椭球在相机坐标系中的几何特性.

透视投影与雅可比矩阵

不失一般性, 假设相机内参已包含在坐标变换中, 或采用归一化相机坐标系进行讨论. 透视投影将相机坐标系中的点 $\mathbf{x}_c = (x_c, y_c, z_c)^\top$ 映射到归一化设备坐标 (x_n, y_n):

$$x_n = \frac{x_c}{z_c}, \quad y_n = \frac{y_c}{z_c} \tag{6.9}$$

对于高斯椭球中心 $\boldsymbol{\mu}_c$ 在相机坐标系中的投影, 需要计算投影变换的雅可比矩阵 $\mathbf{J} \in \mathbb{R}^{2\times 3}$. 该矩阵描述了三维空间到二维图像平面的局部线性近似. 设投影函数 $\pi : \mathbb{R}^3 \to \mathbb{R}^2$ 定义为:

$$\pi(\mathbf{x}_c) = \begin{pmatrix} x_c/z_c \\ y_c/z_c \end{pmatrix} \tag{6.10}$$

其雅可比矩阵为:

$$\mathbf{J} = \frac{\partial \pi}{\partial \mathbf{x}_c} = \begin{pmatrix} \frac{1}{z_c} & 0 & -\frac{x_c}{z_c^2} \\ 0 & \frac{1}{z_c} & -\frac{y_c}{z_c^2} \end{pmatrix} \tag{6.11}$$

在椭球中心 $\boldsymbol{\mu}_c$ 处求值:

$$\mathbf{J}(\boldsymbol{\mu}_c) = \begin{pmatrix} \frac{1}{\mu_{c,z}} & 0 & -\frac{\mu_{c,x}}{\mu_{c,z}^2} \\ 0 & \frac{1}{\mu_{c,z}} & -\frac{\mu_{c,y}}{\mu_{c,z}^2} \end{pmatrix} \tag{6.12}$$

完整的协方差投影变换

三维协方差矩阵 $\boldsymbol{\Sigma}_c$ 经过投影变换后, 得到二维协方差矩阵 $\boldsymbol{\Sigma}_{2D}$. 完整的变换链为:

$$\boldsymbol{\Sigma}_{2D} = \mathbf{J}\boldsymbol{\Sigma}_c\mathbf{J}^\top = \mathbf{J}\mathbf{R}_c\boldsymbol{\Sigma}_w\mathbf{R}_c^\top\mathbf{J}^\top \tag{6.13}$$

这是一个 2×2 的实对称正定矩阵, 描述了投影后椭圆在图像平面上的形状、大小和方向. 矩阵 $\boldsymbol{\Sigma}_{2D}$ 的特征值的平方根决定了椭圆的长短轴半径, 特征向量决定了椭圆的方向.

6.3.2 二维高斯分布的参数化

椭圆的标准形式

投影得到的二维高斯函数可以表示为:

$$G_{2D}(\mathbf{u}) = \exp\left(-\frac{1}{2}(\mathbf{u} - \boldsymbol{\mu}_{2D})^\top \boldsymbol{\Sigma}_{2D}^{-1}(\mathbf{u} - \boldsymbol{\mu}_{2D})\right) \tag{6.14}$$

其中 $\mathbf{u} = (u, v)^\top$ 是图像平面坐标,$\boldsymbol{\mu}_{2D} = \pi(\boldsymbol{\mu}_c)$ 是投影中心.

椭圆几何参数提取

从 2×2 协方差矩阵 $\boldsymbol{\Sigma}_{2D}$ 可以提取椭圆的几何参数. 对 $\boldsymbol{\Sigma}_{2D}$ 进行特征值分解:

$$\boldsymbol{\Sigma}_{2D} = \mathbf{V}\boldsymbol{\Lambda}\mathbf{V}^\top \tag{6.15}$$

其中 $\mathbf{V} = [\mathbf{v}_1, \mathbf{v}_2]$ 是特征向量矩阵,$\boldsymbol{\Lambda} = \mathrm{diag}(\lambda_1, \lambda_2)$ 是特征值矩阵, 且 $\lambda_1 \geq \lambda_2 > 0$. 椭圆参数为:

长轴半径:$a = \sqrt{\lambda_1}$ 短轴半径:$b = \sqrt{\lambda_2}$ 旋转角度:$\theta = \arctan 2(v_{1,y}, v_{1,x})$, 其中 $\mathbf{v}_1 = (v_{1,x}, v_{1,y})^\top$

边界框计算

为加速光栅化, 需要计算椭圆在图像空间中的轴对齐边界框 (AABB). 对于旋转椭圆, 其边界框可以通过以下方式计算: 设椭圆方程为:

$$\frac{((u-\mu_u)\cos\theta+(v-\mu_v)\sin\theta)^2}{a^2}+\frac{(-(u-\mu_u)\sin\theta+(v-\mu_v)\cos\theta)^2}{b^2}=1 \tag{6.16}$$

边界框的极值点为:

$$u_{\min}=\mu_u-\sqrt{a^2\cos^2\theta+b^2\sin^2\theta} \tag{6.17}$$

$$u_{\max}=\mu_u+\sqrt{a^2\cos^2\theta+b^2\sin^2\theta} \tag{6.18}$$

$$v_{\min}=\mu_v-\sqrt{a^2\sin^2\theta+b^2\cos^2\theta} \tag{6.19}$$

$$v_{\max}=\mu_v+\sqrt{a^2\sin^2\theta+b^2\cos^2\theta} \tag{6.20}$$

在工程实践中, 为减少计算开销, 常利用 $\mathbf{\Sigma}_{2D}$ 的对角线元素结合置信区间直接估计 AABB 范围. 设 $\mathbf{\Sigma}_{2D}=\begin{pmatrix} s_{uu} & s_{uv} \\ s_{uv} & s_{vv} \end{pmatrix}$, 则边界框的半宽可直接由 $\Delta u=3\sqrt{s_{uu}}$ 和 $\Delta v=3\sqrt{s_{vv}}$ 估计, 其中 3 是常用的置信度因子, 对应约 99.7% 的置信区间.

6.4 高斯泼溅示例

6.4.1 问题设定

考虑一个简化场景: 单个高斯椭球在特定视角下的渲染计算. 为聚焦核心数学推导, 我们做如下简化假设:

1. **几何简化**: 椭球位于世界坐标系原点, 且已对齐相机坐标系
   - 中心位置:$\boldsymbol{\mu}_w=(0,0,1)^\top$
   - 旋转矩阵:$\mathbf{R}_c=\mathbf{I}$(单位矩阵)
   - 缩放矩阵:$\mathbf{S}=\mathrm{diag}(0.1,0.1,0.1)$
   - 协方差矩阵:$\mathbf{\Sigma}_w=\mathbf{RSS}^\top\mathbf{R}^\top=\mathbf{S}^2=\mathrm{diag}(0.01,0.01,0.01)$
2. **光学简化**: 使用一阶球谐函数 (4 个系数) 表示颜色
   - 球谐系数:$\mathbf{c}_{\mathrm{sh}}=[c_0^0,c_1^{-1},c_1^0,c_1^1]^\top$
   - 不透明度:$\alpha=0.8$
3. **相机简化**: 相机位于 $(0,0,0)$, 看向 $+z$ 方向
   - 观察方向:$\mathbf{d}=(0,0,1)^\top$
   - 像素位置:$\mathbf{p}=(0.02,0.01)^\top$(归一化设备坐标)

6.4.2 坐标变换计算

考虑世界坐标到相机坐标, 由于 $\mathbf{R}_c = \mathbf{I}$ 且 $\mathbf{t}_c = \mathbf{0}$, 椭球中心在相机坐标系中为:

$$\boldsymbol{\mu}_c = \mathbf{R}_c\boldsymbol{\mu}_w + \mathbf{t}_c = \boldsymbol{\mu}_w = (0, 0, 1)^\top \tag{6.21}$$

协方差矩阵变换:

$$\boldsymbol{\Sigma}_c = \mathbf{R}_c\boldsymbol{\Sigma}_w\mathbf{R}_c^\top = \boldsymbol{\Sigma}_w = \mathrm{diag}(0.01, 0.01, 0.01)$$

计算投影中心:

$$\boldsymbol{\mu}_{2D} = \pi(\boldsymbol{\mu}_c) = \begin{pmatrix} 0/1 \\ 0/1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \tag{6.22}$$

计算雅可比矩阵 $\mathbf{J}$ 在 $\boldsymbol{\mu}_c$ 处的值:

$$\mathbf{J} = \begin{pmatrix} \frac{1}{1} & 0 & -\frac{0}{1^2} \\ 0 & \frac{1}{1} & -\frac{0}{1^2} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \tag{6.23}$$

接下来计算二维协方差矩阵:

$$\boldsymbol{\Sigma}_{2D} = \mathbf{J}\boldsymbol{\Sigma}_c\mathbf{J}^\top = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} 0.01 & 0 & 0 \\ 0 & 0.01 & 0 \\ 0 & 0 & 0.01 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \tag{6.24}$$

逐项计算:

$\mathbf{J}\boldsymbol{\Sigma}_c = \begin{pmatrix} 0.01 & 0 & 0 \\ 0 & 0.01 & 0 \end{pmatrix}$ $(\mathbf{J}\boldsymbol{\Sigma}_c)\mathbf{J}^\top = \begin{pmatrix} 0.01 & 0 \\ 0 & 0.01 \end{pmatrix}$

因此:

$$\boldsymbol{\Sigma}_{2D} = \begin{pmatrix} 0.01 & 0 \\ 0 & 0.01 \end{pmatrix} \tag{6.25}$$

这是一个各向同性的协方差矩阵, 对应圆形高斯分布.

6.4.3 权重计算

二次型计算, 对于像素 $\mathbf{p} = (0.02, 0.01)^\top$:

$$\mathbf{p} - \boldsymbol{\mu}_{2D} = \begin{pmatrix} 0.02 \\ 0.01 \end{pmatrix} \tag{6.26}$$

计算二次型:

$$Q(\mathbf{p}) = (\mathbf{p} - \boldsymbol{\mu}_{2D})^\top \boldsymbol{\Sigma}_{2D}^{-1}(\mathbf{p} - \boldsymbol{\mu}_{2D}) \tag{6.27}$$

展开计算:

$$Q(\mathbf{p}) = \begin{pmatrix} 0.02 & 0.01 \end{pmatrix} \begin{pmatrix} 100 & 0 \\ 0 & 100 \end{pmatrix} \begin{pmatrix} 0.02 \\ 0.01 \end{pmatrix} \tag{6.28}$$

$$= \begin{pmatrix} 0.02 & 0.01 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = 0.02 \times 2 + 0.01 \times 1 = 0.04 + 0.01 = 0.05 \tag{6.29}$$

高斯权重:

$$w(\mathbf{p}) = \exp\left(-\frac{1}{2}Q(\mathbf{p})\right) = \exp\left(-\frac{0.05}{2}\right) = \exp(-0.025) \tag{6.30}$$

计算数值:

$$w(\mathbf{p}) \approx 0.9753 \tag{6.31}$$

有效不透明度:

$$\alpha_{\text{eff}}(\mathbf{p}) = \alpha \cdot w(\mathbf{p}) = 0.8 \times 0.9753 \approx 0.7802 \tag{6.32}$$

6.4.4 颜色计算 (一阶球谐函数)

一阶球谐基函数

对于观察方向 $\mathbf{d} = (0, 0, 1)^\top$, 在球坐标系中对应 $\theta = 0$,ϕ 任意. 一阶球谐基函数值为:

$$Y_0^0(\mathbf{d}) = \frac{1}{2\sqrt{\pi}} \approx 0.2821 \tag{6.33}$$

$$Y_1^{-1}(\mathbf{d}) = \frac{\sqrt{3}}{2\sqrt{\pi}} \cdot \sin\theta \cdot \sin\phi = 0 \quad (\text{因} \sin\theta = 0) \tag{6.34}$$

$$Y_1^0(\mathbf{d}) = \frac{\sqrt{3}}{2\sqrt{\pi}} \cdot \cos\theta = \frac{\sqrt{3}}{2\sqrt{\pi}} \cdot 1 \approx 0.4886 \tag{6.35}$$

$$Y_1^1(\mathbf{d}) = \frac{\sqrt{3}}{2\sqrt{\pi}} \cdot \sin\theta \cdot \cos\phi = 0 \quad (\text{因} \sin\theta = 0) \tag{6.36}$$

因此, 基函数向量为:

$$\mathbf{y}(\mathbf{d}) = \begin{pmatrix} 0.2821 \\ 0 \\ 0.4886 \\ 0 \end{pmatrix} \tag{6.37}$$

球谐系数设定

假设球谐系数为:

$$\mathbf{c}_{\text{sh}} = \begin{pmatrix} c_0^0 \\ c_1^{-1} \\ c_1^0 \\ c_1^1 \end{pmatrix} = \begin{pmatrix} 1.0 & 0.0 & 0.0 \\ (\text{红色})0.2 & 0.0 & 0.0 \\ 0.5 & 0.0 & 0.0 \\ 0.1 & 0.0 & 0.0 \end{pmatrix} \tag{6.38}$$

这里每个系数是 RGB 向量, 为简化只考虑红色通道.

颜色计算

颜色是基函数与系数的线性组合:

$$c(\mathbf{d}) = \sum_{l=0}^{1} \sum_{m=-l}^{l} c_l^m Y_l^m(\mathbf{d}) \tag{6.39}$$

对于红色通道:

$$c_r(\mathbf{d}) = c_0^0 Y_0^0 + c_1^{-1} Y_1^{-1} + c_1^0 Y_1^0 + c_1^1 Y_1^1 \tag{6.40}$$

代入数值:

$$c_r(\mathbf{d}) = 1.0 \times 0.2821 + 0.2 \times 0 + 0.5 \times 0.4886 + 0.1 \times 0 \tag{6.41}$$

$$= 0.2821 + 0.2443 = 0.5264 \tag{6.42}$$

因此, 该像素处的颜色为 $(0.5264, 0, 0)$(深红色).

6.4.5 最终像素颜色

由于只有一个椭球, 混合计算简化为:

$$C_{\text{final}} = \alpha_{\text{eff}}(\mathbf{p}) \cdot c(\mathbf{d}) \tag{6.43}$$

对于红色通道:

$$C_r = 0.7802 \times 0.5264 \approx 0.4107 \tag{6.44}$$

最终像素颜色为 $(0.4107, 0, 0)$.

如果混合第二个高斯椭球: 假设场景中增加第二个绿色高斯椭球, 其在该像素处的有效不透明度 $\alpha_{\text{eff},2} = 0.5$, 颜色 $c_2 = (0, 0.5, 0)$. 我们需要按照深度顺序进行混合. 假设红色椭球离相机较近 (在前), 绿色椭球较远 (在后), 则从前往后混合: 初始化:$C = (0, 0, 0)$, $T = 1$ 第一步 (红色椭球):

$$C \leftarrow C + T \cdot \alpha_{\text{eff},1} \cdot c_1 = (0, 0, 0) + 1 \times 0.7802 \times (0.5264, 0, 0) \approx (0.4107, 0, 0) \tag{6.45}$$

$$T \leftarrow T \cdot (1 - \alpha_{\text{eff},1}) = 1 \times (1 - 0.7802) = 0.2198 \tag{6.46}$$

第二步 (绿色椭球):

$$C \leftarrow C + T \cdot \alpha_{\text{eff},2} \cdot c_2 = (0.4107, 0, 0) + 0.2198 \times 0.5 \times (0, 0.5, 0) \approx (0.4107, 0.05495, 0) \tag{6.47}$$

最终颜色约为 $(0.4107, 0.05495, 0)$, 呈现以红色为主, 略带绿色的混合效果. 如果两个椭球顺序颠倒, 最终颜色会明显不同, 这正是 *alpha* 混合顺序依赖性的体现.

深度学习的微分几何基础（一）：流形、切空间与黎曼度量

April 08, 2026

Die Frage über die Gültigkeit der Voraussetzungen der Geometrie im Unendlichkleinen hängt zusammen mit der Frage nach dem innern Grunde der Massverhältnisse des Raumes.[1]

—*Bernhard Riemann*

7.1 流形的定义与动机

7.1.1 直觉：局部平坦，全局弯曲

想象站在地球表面。脚下的地面看起来是平的——可以用一张平面地图描述周围几公里的区域。但整个地球是弯曲的球面，不可能用一张平面地图无失真地覆盖全球。这就是流形的核心直觉：**局部像欧几里得空间，全局可能有复杂的弯曲结构**。如图7.1。

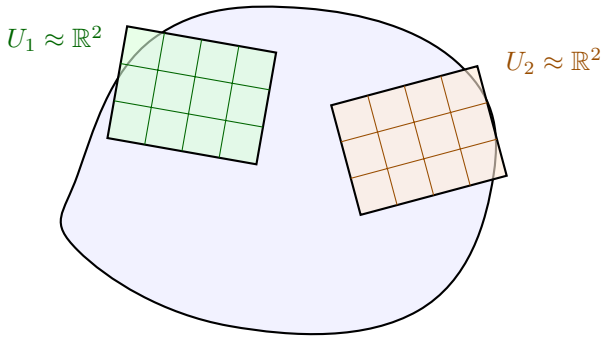

Figure 7.1: 流形 M

[1]关于几何学假设在无穷小范围内的有效性问题，与空间度量关系的内部根据问题紧密相连。

7.1.2 拓扑流形的严格定义

Definition 7.1 (拓扑流形)

一个 n 维**拓扑流形**是拓扑空间 M，满足：

(1) **Hausdorff 性**：对 M 中任意两个不同的点 $p \neq q$，存在开集 $U \ni p$ 和 $V \ni q$，使得 $U \cap V = \varnothing$。

(2) **第二可数性**：M 的拓扑有一个可数基。

(3) **局部同胚于 $\mathbb{R}^n$**：对每一个点 $p \in M$，存在包含 p 的开集 $U \subset M$，$\mathbb{R}^n$ 中的开集 $V \subset \mathbb{R}^n$，以及同胚映射 $\varphi : U \to V$。

条件 (1) 排除病态空间，保证极限的唯一性。条件 (2) 保证流形不会 “太大”。条件 (3) 是核心——它说流形在每一小块上都长得像 $\mathbb{R}^n$。

Definition 7.2 (坐标卡与图册)

二元组 (U, φ) 称为一个**坐标卡 (chart)**，其中 $U \subset M$ 是开集，$\varphi : U \to V \subset \mathbb{R}^n$ 是同胚。一族坐标卡 $\{(U_\alpha, \varphi_\alpha)\}_{\alpha \in A}$ 称为一个**图册 (atlas)**，如果

$$\bigcup_{\alpha \in A} U_\alpha = M. \tag{7.1}$$

7.1.3 非 Hausdorff 空间的反例：带两个原点的实数轴

取两条实数轴 $\mathbb{R}_1$ 和 $\mathbb{R}_2$，在所有非零点处粘合：$\mathbb{R}_1$ 中的 x 与 $\mathbb{R}_2$ 中的 x 等同（$x \neq 0$），但 0_1 和 0_2 保持为不同的点。如图7.2所示。

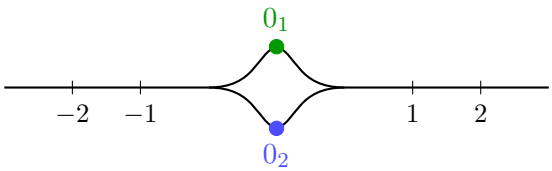

Figure 7.2: 非 Hausdorff 空间的反例

这个空间局部同胚于 $\mathbb{R}^1$，但不是 Hausdorff 的：0_1 的任何开邻域和 0_2 的任何开邻域都包含公共的非零点，无法用不相交的开集分离。没有 Hausdorff 条件，极限不唯一，微积分的基本定理会崩塌。

7.2 转移函数与光滑结构

7.2.1 转移函数的定义

Definition 7.3 (转移函数)

设 $(U_\alpha, \varphi_\alpha)$ 和 (U_β, φ_β) 是两个坐标卡，且 $U_\alpha \cap U_\beta \neq \varnothing$。**转移函数 (transition map)** 定义为

$$\tau_{\beta\alpha} = \varphi_\beta \circ \varphi_\alpha^{-1} : \varphi_\alpha(U_\alpha \cap U_\beta) \to \varphi_\beta(U_\alpha \cap U_\beta). \tag{7.2}$$

这是 $\mathbb{R}^n$ 的开子集之间的映射。

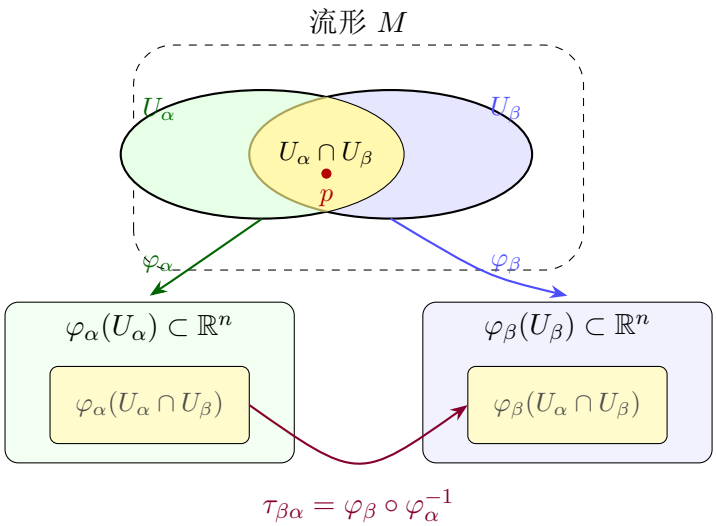

Figure 7.3: 转移函数

Definition 7.4 (光滑流形)

如果图册中所有转移函数 $\tau_{\beta\alpha}$ 都是 C^∞ 光滑映射，则称 M 连同这个图册为**光滑流形 (smooth manifold)**。

7.2.2 完整的例子：S^1 是 1 维光滑流形

为什么一个坐标卡不够。用角度 $\theta \in [0, 2\pi)$ 标记整个圆，从 $\theta = 0.01$ 到 $\theta \approx 2\pi$ 在圆上只隔一小步，但坐标值跳了将近 2π，映射在顶点处不连续。必须用至少两个坐标卡。

构造两个坐标卡。

- (U_1, φ_1)：$U_1 = S^1 \setminus \{(1, 0)\}$（去掉点 $(1, 0)$），$\varphi_1 : U_1 \to (0, 2\pi)$。
- (U_2, φ_2)：$U_2 = S^1 \setminus \{(0, -1)\}$（去掉点 $(0, -1)$），$\varphi_2 : U_2 \to (-\pi, \pi)$。

$U_1 \cup U_2 = S^1$，φ_1, φ_2 都是同胚。

转移函数。重叠区域 $U_1 \cap U_2 = S^1 \setminus \{(1,0), (0,-1)\}$ 分成两段弧。$\tau_{21} = \varphi_2 \circ \varphi_1^{-1}$：

$$\tau_{21}(t) = t, \qquad t \in (0, \pi) \quad \text{（上半圆）} \tag{7.3}$$

$$\tau_{21}(t) = t - 2\pi, \qquad t \in (\pi, 2\pi) \quad \text{（下半圆）} \tag{7.4}$$

两段都是 C^∞ 的。因此 S^1 是 1 维光滑流形。

Remark (与深度学习的联系)

自编码器学到的隐空间表示对应数据流形上的一个坐标卡。不同的训练得到不同的坐标系，但描述同一个底层流形。转移函数对应两个模型隐空间之间的映射。

7.3 切空间

7.3.1 动机：如何在流形上定义方向

流形 M 不是向量空间，不能直接谈 “方向”。切空间在每个点 p 处构造一个向量空间 T_pM，元素代表从 p 出发的所有可能方向。

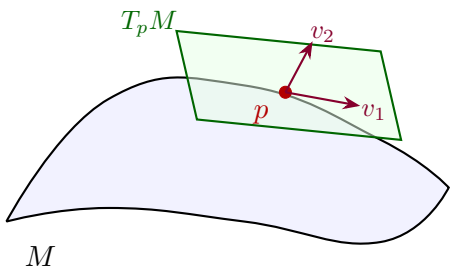

Figure 7.4: 切空间

7.3.2 定义一：通过曲线的速度向量

Definition 7.5 (切空间——曲线速度向量的等价类)

设 M 是 n 维光滑流形，$p \in M$。光滑曲线 $\gamma : (-\varepsilon, \varepsilon) \to M$ 满足 $\gamma(0) = p$。取坐标卡 (U, φ)，定义速度向量：

$$\dot{\gamma}(0) := \frac{d}{dt}\bigg|_{t=0} (\varphi \circ \gamma)(t) \in \mathbb{R}^n. \tag{7.5}$$

两条曲线 γ_1, γ_2 等价，若在某个坐标卡下

$$\frac{d}{dt}\bigg|_{t=0} (\varphi \circ \gamma_1)(t) = \frac{d}{dt}\bigg|_{t=0} (\varphi \circ \gamma_2)(t). \tag{7.6}$$

切空间 T_pM 是所有过 p 的光滑曲线在此等价关系下的**等价类**的集合。

7.3.3 定义二：导子

Definition 7.6 (切空间——导子)

设 $C^\infty(M)$ 是 M 上所有光滑实值函数的集合。p 处的**导子 (derivation)** 是线性映射 $v : C^\infty(M) \to \mathbb{R}$，满足莱布尼兹法则：

$$v(fg) = f(p)\,v(g) + g(p)\,v(f), \quad \forall f, g \in C^\infty(M). \tag{7.7}$$

T_pM 定义为 p 处所有导子的集合。

Example (验证方向导数是导子)

设 $M = \mathbb{R}^2$，$p = (1, 2)$。考虑函数 $f(x, y) = x^2y$。
定义映射 $v : C^\infty(\mathbb{R}^2) \to \mathbb{R}$：

$$v(f) = 3\frac{\partial f}{\partial x}\bigg|_{(1,2)} + 5\frac{\partial f}{\partial y}\bigg|_{(1,2)} \tag{7.8}$$

即沿方向 $(3, 5)$ 的方向导数。验证 v 是一个导子：
线性：显然成立（偏导数的线性性）。
莱布尼兹法则：取 $f(x, y) = x^2$，$g(x, y) = y$。则 $fg = x^2y$，

$$v(fg) = 3 \cdot 2xy\big|_{(1,2)} + 5 \cdot x^2\big|_{(1,2)} = 3 \cdot 4 + 5 \cdot 1 = 17 \tag{7.9}$$

$$f(p)\,v(g) + g(p)\,v(f) = 1 \cdot (3 \cdot 0 + 5 \cdot 1) + 2 \cdot (3 \cdot 2 + 5 \cdot 0) \tag{7.10}$$

$$= 1 \cdot 5 + 2 \cdot 6 = 17 \quad \checkmark \tag{7.11}$$

因此 $v = 3\,\dfrac{\partial}{\partial x}\bigg|_{(1,2)} + 5\,\dfrac{\partial}{\partial y}\bigg|_{(1,2)}$ 是 $T_{(1,2)}\mathbb{R}^2$ 中的一个切向量，对应方向 $(3, 5)$。

联系：给定曲线 γ（$\gamma(0) = p$），定义导子 $v_\gamma(f) = \dfrac{d}{dt}\big|_{t=0} f(\gamma(t))$，莱布尼兹法则由乘积求导法则保证。

7.3.4 坐标基底与分量

在坐标卡 (U, φ) 下，坐标函数 $\varphi = (x^1, \ldots, x^n)$，定义 n 个导子：

$$\frac{\partial}{\partial x^i}\bigg|_p (f) := \frac{\partial(f \circ \varphi^{-1})}{\partial r^i}\bigg|_{\varphi(p)} \tag{7.12}$$

其中 r^i 是 $\mathbb{R}^n$ 的标准坐标。

Theorem 7.7 (坐标基底构成切空间的基)

$\left\{ \left.\frac{\partial}{\partial x^1}\right|_p, \left.\frac{\partial}{\partial x^2}\right|_p, \ldots, \left.\frac{\partial}{\partial x^n}\right|_p \right\}$ 构成 T_pM 的一组基底。$\dim T_pM = n = \dim M$。

任意切向量 $v \in T_pM$ 唯一展开为

$$v = \sum_{i=1}^{n} v^i \left.\frac{\partial}{\partial x^i}\right|_p \tag{7.13}$$

其中 $v^1, \ldots, v^n \in \mathbb{R}$ 是分量（上标是指标，不是幂次）。

Remark (切向量展开的直观理解)

在 $\mathbb{R}^3$ 中，普通向量 $v = (4, -1, 7)$ 写作 $v = 4\,\mathbf{e}_1 + (-1)\,\mathbf{e}_2 + 7\,\mathbf{e}_3$。流形上的写法完全对应：

$$v = 4 \left.\frac{\partial}{\partial x^1}\right|_p + (-1) \left.\frac{\partial}{\partial x^2}\right|_p + 7 \left.\frac{\partial}{\partial x^3}\right|_p \tag{7.14}$$

只是把基底从单位向量 $\mathbf{e}_i$ 换成了偏导算子 $\left.\frac{\partial}{\partial x^i}\right|_p$。在 $\mathbb{R}^n$ 中二者完全等价。之所以用偏导算子，是因为弯曲流形上没有全局统一的“单位向量”，但“对函数求偏导”在任何流形上都有意义，从而使定义同时适用于平坦空间和弯曲流形。

7.4 坐标变换与切向量

7.4.1 推前映射

$\varphi^{-1} : V \subset \mathbb{R}^n \to U \subset M$ 的导数

$$d(\varphi^{-1})_{\varphi(p)} : T_{\varphi(p)}\mathbb{R}^n \cong \mathbb{R}^n \to T_pM \tag{7.15}$$

把标准基底 e_i 映成坐标基底：$d(\varphi^{-1})_{\varphi(p)}(e_i) = \left.\frac{\partial}{\partial x^i}\right|_p$。反过来，$d\varphi_p : T_pM \to \mathbb{R}^n$ 把坐标基底映回标准基底。二者互为逆映射。

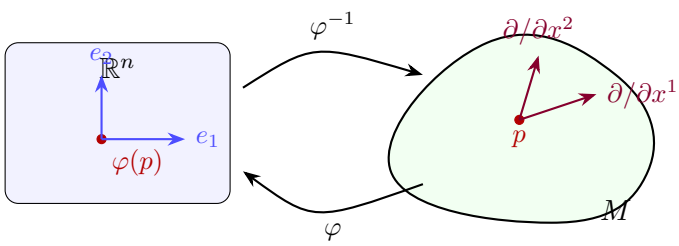

Figure 7.5: 推前映射

7.4.2 分量变换法则

两个坐标卡 (U,φ)、(V,ψ)，坐标 (x^i)、(y^j)。同一切向量：

$$v = \sum_i v^i \left.\frac{\partial}{\partial x^i}\right|_p = \sum_j \tilde{v}^j \left.\frac{\partial}{\partial y^j}\right|_p \tag{7.16}$$

Proposition 7.8 (切向量的分量变换法则)

$$\tilde{v}^j = \sum_{i=1}^n \left.\frac{\partial y^j}{\partial x^i}\right|_p v^i \tag{7.17}$$

其中 $\dfrac{\partial y^j}{\partial x^i}$ 是转移函数 $\tau = \psi \circ \varphi^{-1}$ 的 Jacobian 的第 (j,i) 元素。

7.4.3 转移函数导数的分解

由链式法则：

$$d\tau_{\varphi(p)} = d\psi_p \circ d(\varphi^{-1})_{\varphi(p)} \qquad \Longleftrightarrow \qquad \mathbb{R}^n \xrightarrow{d(\varphi^{-1})} T_pM \xrightarrow{d\psi} \mathbb{R}^n \tag{7.18}$$

Remark (关于符号 d)

此处 d 表示光滑映射的**微分**（又称导数映射、推前映射），不是“微小增量”。对于光滑映射 $F: A \to B$，dF_p 是 F 在点 p 处的线性近似，将 T_pA 中的切向量映到 $T_{F(p)}B$ 中的切向量。当 A, B 都是 $\mathbb{R}^n$（的开子集）时，dF_p 就是熟悉的 Jacobian 矩阵。因此上式

$$d\tau_{\varphi(p)} = d\psi_p \circ d(\varphi^{-1})_{\varphi(p)} \tag{7.19}$$

等价于 Jacobian 的矩阵乘法 $J_\tau = J_\psi \cdot J_{\varphi^{-1}}$，即链式法则。

第一步把方向贴到流形上，第二步用另一个坐标卡拍平回 $\mathbb{R}^n$。切向量 $v \in T_pM$ 是中间不变的对象。

7.4.4 基底与分量的反向变换

基底变换：

$$\left.\frac{\partial}{\partial x^i}\right|_p = \sum_j \left.\frac{\partial y^j}{\partial x^i}\right|_p \left.\frac{\partial}{\partial y^j}\right|_p \tag{7.20}$$

分量变换：

$$\tilde{v}^j = \sum_i \left.\frac{\partial y^j}{\partial x^i}\right|_p v^i \tag{7.21}$$

记 $J = \left(\dfrac{\partial y^j}{\partial x^i}\right)$，矩阵形式：

$$\tilde{\mathbf{v}} = J\,\mathbf{v}, \qquad \mathbf{e}_x = J^T\,\mathbf{e}_y \tag{7.22}$$

一个乘 J，一个乘 J^T，保证 $v = \mathbf{v}^T \mathbf{e}_x = \tilde{\mathbf{v}}^T \mathbf{e}_y$ 不变。

Table 7.1: 映射关系

映射	方向	公式
$\tau = \psi \circ \varphi^{-1}$	x 坐标值 $\to$ y 坐标值	$y = \tau(x)$
J_τ 作用在分量上	x 分量 $\to$ y 分量	$\tilde{v}^j = \dfrac{\partial y^j}{\partial x^i} v^i$
J_τ 作用在基底上	x 基底用 y 基底表示	$\left.\dfrac{\partial}{\partial x^i}\right\vert = \dfrac{\partial y^j}{\partial x^i} \left.\dfrac{\partial}{\partial y^j}\right\vert$

7.5 黎曼度量

7.5.1 定义

下面给出黎曼度量的定义：

Definition 7.9 (黎曼度量)

光滑流形 M 上的**黎曼度量** g 在每个点 $p \in M$ 上给出 T_pM 上的内积

$$g_p : T_pM \times T_pM \to \mathbb{R} \tag{7.23}$$

满足以下条件：

(1) **双线性**：对任意 $u, v, w \in T_pM$ 和 $a, b \in \mathbb{R}$，

$$\begin{aligned} g_p(au + bv,\ w) &= a\, g_p(u, w) + b\, g_p(v, w) \\ g_p(w,\ au + bv) &= a\, g_p(w, u) + b\, g_p(w, v) \end{aligned} \tag{7.24}$$

即对两个自变量分别是线性的。

(2) **对称性**：对任意 $u, v \in T_pM$，

$$g_p(u, v) = g_p(v, u) \tag{7.25}$$

即交换两个输入不改变结果。

(3) **正定性**：对任意 $v \in T_pM$，

$$g_p(v, v) \geq 0, \qquad \text{且} \quad g_p(v, v) = 0 \iff v = 0 \tag{7.26}$$

即非零向量与自身的内积严格为正。

(4) **光滑性**：对任意坐标卡 (U, φ)，分量函数 $g_{ij}(p) = g_p\left(\left.\dfrac{\partial}{\partial x^i}\right\vert_p, \left.\dfrac{\partial}{\partial x^j}\right\vert_p \right)$ 是坐标的 C^∞ 函数。

> 条件 (1)–(3) 说明 g_p 是 T_pM 上的内积，与欧几里得空间中的点积类似。条件 (4) 保证度量在点与点之间平滑过渡，不会出现突变。

7.5.2 度量矩阵与各符号的含义

在坐标卡 (U, φ) 下，坐标 $(x^1, \ldots, x^n)$，度量矩阵分量为

$$g_{ij}(p) = g_p\left(\left.\frac{\partial}{\partial x^i}\right|_p, \left.\frac{\partial}{\partial x^j}\right|_p\right) \tag{7.27}$$

设 $u, v \in T_pM$，展开为

$$u = \sum_{i=1}^{n} u^i \left.\frac{\partial}{\partial x^i}\right|_p, \qquad v = \sum_{j=1}^{n} v^j \left.\frac{\partial}{\partial x^j}\right|_p \tag{7.28}$$

其中 $u^i, v^j \in \mathbb{R}$ 是分量。由双线性性：

$$g_p(u, v) = \sum_{i,j} g_{ij}(p)\, u^i v^j \tag{7.29}$$

以 $n = 2$ 为例的矩阵形式：

$$g_p(u, v) = \begin{pmatrix} u^1 & u^2 \end{pmatrix} \begin{pmatrix} g_{11} & g_{12} \\ g_{21} & g_{22} \end{pmatrix} \begin{pmatrix} v^1 \\ v^2 \end{pmatrix} \tag{7.30}$$

“光滑变化” 指每个 $g_{ij}(p)$ 作为坐标的函数是 C^∞ 的。

Table 7.2: 符号含义

符号	含义	类型
u, v	T_pM 中的切向量	流形上的内在对象
u^i, v^j	切向量在坐标基底下的分量	实数，依赖坐标卡
$\left.\frac{\partial}{\partial x^i}\right\|_p$	坐标基底向量（导子）	T_pM 的一组基
$g_{ij}(p)$	度量对两个基底向量的值	实数，$n \times n$ 矩阵
$g_p(u, v)$	两个切向量的内积	实数，坐标无关

7.5.3 度量给出的几何量

长度： $\|v\| = \sqrt{\sum_{i,j} g_{ij}\, v^i v^j}$

角度： $\cos\alpha = \dfrac{\sum_{i,j} g_{ij}\, u^i v^j}{\|u\|\,\|v\|}$

曲线长度： $L(\gamma) = \displaystyle\int_a^b \sqrt{\sum_{i,j} g_{ij}(\gamma(t))\,\dot\gamma^i(t)\,\dot\gamma^j(t)}\,dt$

两点间最短曲线是**测地线 (geodesic)**。

7.5.4 拉回度量与 $G = J^T J$

设 $F : M \to \mathbb{R}^N$ 是嵌入映射。拉回度量定义为

$$g_p(u,v) := \langle dF_p(u),\ dF_p(v)\rangle_{\mathbb{R}^N} \tag{7.31}$$

在坐标下 $dF_p(u) = J\mathbf{u}$，$dF_p(v) = J\mathbf{v}$（J 是 $N \times n$ 的 Jacobian）。代入：

$$g_p(u,v) = (J\mathbf{u})^T(J\mathbf{v}) = \mathbf{u}^T J^T J\,\mathbf{v} \qquad \Longrightarrow \qquad \boxed{G = J^T J} \tag{7.32}$$

逐元素：$G_{ij} = \displaystyle\sum_{k=1}^{N} \frac{\partial F^k}{\partial x^i}\frac{\partial F^k}{\partial x^j}$，即两个 Jacobian 列向量在 $\mathbb{R}^N$ 中的点积。

Example (一维曲线的拉回度量)

取曲线 M（1 维流形）嵌入 $\mathbb{R}^2$，嵌入映射为 $F(t) = (2t,\ t^2)$。此时 $n = 1$，$N = 2$。
Jacobian 为 2×1 矩阵：

$$J = \begin{pmatrix} 2 \\ 2t \end{pmatrix} \tag{7.33}$$

dF_p 把流形上的切向量（一个实数 u）推到 $\mathbb{R}^2$ 中：

$$dF_p(u) = Ju = \begin{pmatrix} 2u \\ 2tu \end{pmatrix} \tag{7.34}$$

拉回度量即把两个切向量推到 $\mathbb{R}^2$ 后做普通点积：

$$g_p(u,v) = (Ju)^T(Jv) = \begin{pmatrix} 2u & 2tu \end{pmatrix}\begin{pmatrix} 2v \\ 2tv \end{pmatrix} = (4 + 4t^2)\,uv \tag{7.35}$$

因此 $G = J^T J = 4 + 4t^2$（1×1 矩阵，即一个数）。
物理含义：在 $t = 0$ 处 $G = 4$，流形上走一步 dt，实际距离为 $\sqrt{4}\,dt = 2\,dt$；在 $t = 1$ 处 $G = 8$，同样走 dt，实际距离为 $\sqrt{8}\,dt$。曲线越陡，同样的参数变化对应越长的实际距离。

7.5.5 S^2 球坐标度量的推导

嵌入映射： $F(\theta,\phi) = (\sin\theta\cos\phi,\ \sin\theta\sin\phi,\ \cos\theta)$。

Remark (嵌入映射的来源)

此处的嵌入映射即球坐标参数化。一般的球坐标公式为 $F(r,\theta,\phi) = (r\sin\theta\cos\phi,\ r\sin\theta\sin\phi,\ r\cos\theta)$，但 S^2 是**单位球面**（$r = 1$），半径被固定，不再是自由参数。剩下的两个自由坐标为：天顶角 θ（从北极量起，$\theta = 0$ 为北极，$\theta = \pi$ 为南极）和方位角 ϕ（赤道平面上的转角）。球面上的点在 $\mathbb{R}^3$ 中的高度为 $z = \cos\theta$，投影到赤道平面的长度为 $\sin\theta$，再由 ϕ 分解为 $x = \sin\theta\cos\phi$，$y = \sin\theta\sin\phi$，从而给出嵌入映射 $F(\theta,\phi) = (\sin\theta\cos\phi,\ \sin\theta\sin\phi,\ \cos\theta)$。

Jacobian：

$$J = \begin{pmatrix} \cos\theta\cos\phi & -\sin\theta\sin\phi \\ \cos\theta\sin\phi & \sin\theta\cos\phi \\ -\sin\theta & 0 \end{pmatrix} \tag{7.36}$$

逐个计算 g_{ij}（第 i 列与第 j 列的点积）：

$g_{\theta\theta}$：

$$g_{\theta\theta} = \cos^2\theta\cos^2\phi + \cos^2\theta\sin^2\phi + \sin^2\theta \tag{7.37}$$

$$= \cos^2\theta + \sin^2\theta = 1 \tag{7.38}$$

$g_{\phi\phi}$：

$$g_{\phi\phi} = \sin^2\theta\sin^2\phi + \sin^2\theta\cos^2\phi \tag{7.39}$$

$$= \sin^2\theta \tag{7.40}$$

$g_{\theta\phi}$：

$$g_{\theta\phi} = -\cos\theta\sin\theta\cos\phi\sin\phi + \cos\theta\sin\theta\sin\phi\cos\phi = 0 \tag{7.41}$$

将度量矩阵 G 写成**线元素 (line element)**[2] 的形式：$ds^2 = \sum_{i,j} g_{ij}\,dx^i\,dx^j$ 表示流形上无穷小距离的平方，其中 dx^i 对应坐标的无穷小变化。代入 $g_{\theta\theta} = 1$，$g_{\phi\phi} = \sin^2\theta$，$g_{\theta\phi} = 0$，得到 **结果：**

$$\boxed{G = \begin{pmatrix} 1 & 0 \\ 0 & \sin^2\theta \end{pmatrix}}, \qquad ds^2 = d\theta^2 + \sin^2\theta\,d\phi^2 \tag{7.42}$$

物理含义：沿 θ 走 $d\theta$，实际距离为 $d\theta$。沿 ϕ 走 $d\phi$，实际距离为 $\sin\theta\,d\phi$（赤道最大，极点趋于零）。

7.5.6 与深度学习的联系：Fisher 信息矩阵

参数化分布族 $p(x|\theta)$ 的 Fisher 信息矩阵

$$F_{ij}(\theta) = \mathbb{E}\left[\frac{\partial \log p(x|\theta)}{\partial\theta^i}\frac{\partial \log p(x|\theta)}{\partial\theta^j}\right] \tag{7.43}$$

[2]线元素就是流形上两个无穷接近的点之间的距离公式。

是参数空间上的黎曼度量。局部 KL 散度

$$D_{\mathrm{KL}}(p_\theta \| p_{\theta+d\theta}) \approx \frac{1}{2} \sum_{i,j} F_{ij}\, d\theta^i\, d\theta^j \tag{7.44}$$

与 $ds^2 = \sum_{i,j} g_{ij}\, dx^i\, dx^j$ 形式一致。自然梯度 $\tilde{\nabla} L = F^{-1} \nabla L$ 是在此度量下的正确梯度方向。

深度学习的微分几何基础（二）：联络、测地线、曲率与微分形式

April 09, 2026

Die allgemeinen Naturgesetze sind durch Gleichungen auszudrücken, die für alle Koordinatensysteme gelten, d. h. gegen beliebige Substitutionen kovariant (allgemein kovariant) sind.[1]

—*Albert Einstein*

8.1 联络与协变导数

8.1.1 动机：为什么需要联络

在 $\mathbb{R}^n$ 中，对向量场 Y 沿方向 X 求导很自然：

$$(\nabla_X Y)(p) = \lim_{t\to 0} \frac{Y(p+tX) - Y(p)}{t} \tag{8.1}$$

分子中两个向量都住在 $\mathbb{R}^n$ 中，可以直接相减。

但在流形 M 上，$Y(p) \in T_pM$，$Y(q) \in T_qM$，它们属于不同的向量空间，减法没有定义。联络的作用就是解决这个问题——定义弯曲空间中向量场的“真正导数”。

8.1.2 偏导数为什么不够：极坐标中的例子

平面 $\mathbb{R}^2$ 用极坐标 (r,θ)，基底向量是 $\dfrac{\partial}{\partial r}$（径向向外）和 $\dfrac{\partial}{\partial \theta}$（绕原点旋转方向）。

考虑向量场 $Y = 1\cdot\dfrac{\partial}{\partial r} + 0\cdot\dfrac{\partial}{\partial \theta}$，即每个点都有一个径向向外的箭头。分量 $(Y^r, Y^\theta) = (1,0)$ 到处不变，偏导数 $\dfrac{\partial Y^r}{\partial \theta} = 0$，$\dfrac{\partial Y^\theta}{\partial \theta} = 0$，似乎变化率为零。

[1] 普遍的自然定律应当由对一切坐标系都成立的方程式来表达，也就是说，这些方程式对于任意的代换是协变的（普遍协变的）。

但这个向量场在不同位置实际指向不同的方向：在 $\theta = 0$ 指向右，在 $\theta = \pi/2$ 指向上。分量相同，方向却不同——原因是基底 $\dfrac{\partial}{\partial r}$ 本身的方向随 θ 在转动。偏导数只看分量，看不到基底的变化，因此给出了错误的“零变化率”。

8.1.3 协变导数的直觉

协变导数把两个变化都考虑进去（其中 Γ^k_{ij} 称为 Christoffel 符号，将在 8.1.5 节严格定义，这里只需知道它编码了基底随位置扭曲的方式）：

$$\underbrace{(\nabla_{\dot\gamma} Y)^k}_{\text{真正的变化率}} = \underbrace{\frac{dY^k}{dt}}_{\text{分量的变化}} + \underbrace{\sum_{i,j} \Gamma^k_{ij}\, \dot\gamma^i\, Y^j}_{\text{基底扭曲的修正}} \tag{8.2}$$

第一项是坐标分量的普通导数——偏导数能看到的部分。第二项是修正——补偿基底本身随位置的变化，偏导数看不到的部分。

8.1.4 仿射联络的严格定义

Definition 8.1 (仿射联络)

设 $\mathfrak{X}(M)$ 是 M 上所有光滑向量场的集合。一个**仿射联络**是映射

$$\nabla : \mathfrak{X}(M) \times \mathfrak{X}(M) \to \mathfrak{X}(M), \quad (X, Y) \mapsto \nabla_X Y \tag{8.3}$$

满足（$f \in C^\infty(M)$，$X, Y, Z \in \mathfrak{X}(M)$）：

(1) $C^\infty(M)$-线性于 X：$\nabla_{fX+Z} Y = f\nabla_X Y + \nabla_Z Y$

方向加倍则变化率加倍，方向叠加则变化率叠加。类比方向导数 $D_{cv} f = c\, D_v f$。

(2) $\mathbb{R}$-线性于 Y：$\nabla_X (Y + Z) = \nabla_X Y + \nabla_X Z$

两个向量场之和的变化率等于各自变化率之和。类比 $(f + g)' = f' + g'$。

(3) 莱布尼兹法则：$\nabla_X (fY) = (Xf)Y + f\nabla_X Y$

函数乘向量场的乘积法则。类比 $(fg)' = f'g + fg'$，其中 Xf 是 f 沿 X 的方向导数[a]。

[a] Xf 是微分几何中“向量场作用于函数”的标准记号，坐标下即 $Xf = \sum_i X^i \dfrac{\partial f}{\partial x^i}$，就是方向导数。

公理 (1) 说变化率和你走多快成正比。公理 (3) 说它满足乘积法则。对 X 是 C^∞-线性（可以提出函数），对 Y 只是 $\mathbb{R}$-线性（因为莱布尼兹法则多了修正项 $(Xf)Y$）。

Remark ($\mathfrak{X}(M)$ 的含义)

$\mathfrak{X}(M)$ 是 M 上所有光滑向量场的集合。一个光滑向量场是给流形上每个点 p 分配一个切向量 $Y(p) \in T_pM$，且分配方式是光滑的（坐标分量都是 C^∞ 函数）。所有这样的向量场放在一起，构成 $\mathfrak{X}(M)$。

8.1.5 Christoffel 符号

在坐标卡下，联络由 n^3 个函数完全决定。我们需要回答一个基本问题：坐标基底向量 $\dfrac{\partial}{\partial x^j}$ 沿另一个坐标方向 $\dfrac{\partial}{\partial x^i}$ 走一点，会怎么变？

变化的结果仍然是一个向量，可以用基底展开。展开系数就定义为 **Christoffel 符号** Γ^k_{ij}：

$$\nabla_{\frac{\partial}{\partial x^i}} \frac{\partial}{\partial x^j} = \sum_{k=1}^{n} \Gamma^k_{ij} \frac{\partial}{\partial x^k} \tag{8.4}$$

三个指标的含义：i = 沿哪个方向走，j = 哪个基底在变，k = 变化在哪个方向上的分量。

Example (极坐标中的 Christoffel 符号)

极坐标 (r, θ) 的基底是 $\dfrac{\partial}{\partial r}$（径向向外）和 $\dfrac{\partial}{\partial \theta}$（绕原点旋转）。在笛卡尔坐标 (x, y) 中，基底 $\dfrac{\partial}{\partial x}$、$\dfrac{\partial}{\partial y}$ 的方向到处不变，所有 $\Gamma^k_{ij} = 0$。但在极坐标中，基底方向随位置转动，Γ^k_{ij} 不为零。

考虑 $\nabla_{\frac{\partial}{\partial \theta}} \dfrac{\partial}{\partial r}$：径向基底 $\dfrac{\partial}{\partial r}$ 沿 θ 方向走一点会怎么变？在 $\theta = 0$ 它指向右，在 $\theta = \pi/2$ 它指向上——沿 θ 走时，径向基底在偏转，偏转方向是 $\dfrac{\partial}{\partial \theta}$，偏转量为 $\dfrac{1}{r}$（r 越小、绕的圈越紧、偏转越剧烈）。写成定义式：

$$\nabla_{\frac{\partial}{\partial \theta}} \frac{\partial}{\partial r} = \frac{1}{r} \frac{\partial}{\partial \theta} \tag{8.5}$$

读出 Christoffel 符号：$\Gamma^\theta_{\theta r} = \dfrac{1}{r}$，其余分量为零。意思是：沿 θ 方向（$i = \theta$）走时，径向基底（$j = r$）在 θ 方向（$k = \theta$）上偏转了 $\dfrac{1}{r}$。

知道了所有基底向量的变化方式，就能算出任意向量场的协变导数。任意向量场 $Y = \sum_k Y^k \dfrac{\partial}{\partial x^k}$ 沿 $X = \sum_i X^i \dfrac{\partial}{\partial x^i}$ 的协变导数为：

$$(\nabla_X Y)^k = \sum_i X^i \left(\frac{\partial Y^k}{\partial x^i} + \sum_j \Gamma^k_{ij} Y^j \right) \tag{8.6}$$

括号中第一项 $\dfrac{\partial Y^k}{\partial x^i}$ 是分量本身的变化，第二项 $\sum_j \Gamma^k_{ij} Y^j$ 是基底偏转带来的修正——这正是之前“协变导数的直觉”中那个公式，现在 Γ^k_{ij} 有了明确的定义。

8.1.6 极坐标中的验证

极坐标度量 $ds^2 = dr^2 + r^2\, d\theta^2$，非零 Christoffel 符号：

$$\Gamma^r_{\theta\theta} = -r, \qquad \Gamma^\theta_{r\theta} = \Gamma^\theta_{\theta r} = \frac{1}{r} \tag{8.7}$$

例 1：向量场 $Y = \dfrac{\partial}{\partial r}$（径向向外），分量 $(Y^r, Y^\theta) = (1, 0)$。沿 $\dfrac{\partial}{\partial \theta}$ 求协变导数：

$$(\nabla_{\partial/\partial\theta} Y)^r = \frac{\partial Y^r}{\partial \theta} + \Gamma^r_{\theta r} \cdot 1 + \Gamma^r_{\theta\theta} \cdot 0 = 0 + 0 + 0 = 0 \tag{8.8}$$

$$(\nabla_{\partial/\partial\theta} Y)^\theta = \frac{\partial Y^\theta}{\partial \theta} + \Gamma^\theta_{\theta r} \cdot 1 + \Gamma^\theta_{\theta\theta} \cdot 0 = 0 + \frac{1}{r} + 0 = \frac{1}{r} \tag{8.9}$$

结果：$\nabla_{\partial/\partial\theta} Y = \dfrac{1}{r}\dfrac{\partial}{\partial\theta}$。偏导数说没变（分量恒定），协变导数说在变——基底 $\dfrac{\partial}{\partial r}$ 随 θ 转动，协变导数捕捉到了这一点。r 越小偏转越大（绕小圈方向变化更剧烈）。

例 2：向量场 Z，分量 $(Z^r, Z^\theta) = (\cos\theta, -\sin\theta/r)$，即到处指向 x 轴正方向的常向量场。分量在变（随 θ 变），但向量本身不变。验证 θ 分量：

$$(\nabla_{\partial/\partial\theta} Z)^\theta = \frac{\partial Z^\theta}{\partial \theta} + \Gamma^\theta_{\theta r} Z^r = \frac{-\cos\theta}{r} + \frac{1}{r}\cos\theta = 0 \tag{8.10}$$

分量变化和修正项恰好抵消——向量确实没变，协变导数正确地给出零。

8.1.7 Levi-Civita 联络

Definition 8.2 (Levi-Civita 联络)

给定黎曼度量 g，**Levi-Civita 联络**是唯一满足以下条件的联络：

(1) 与度量相容：$X(g(Y,Z)) = g(\nabla_X Y, Z) + g(Y, \nabla_X Z)$

内积的乘积法则。左边是内积 $g(Y,Z)$ 沿 X 方向的变化率，右边拆成 Y 变化的贡献和 Z 变化的贡献。推论：若 Y, Z 都在平行移动（$\nabla_X Y = \nabla_X Z = 0$），右边为零，内积不变——平行移动保持向量的长度和夹角。

(2) 无挠：$\nabla_X Y - \nabla_Y X = [X, Y]$

$[X,Y]$ 是李括号[a]，度量两个方向流动的天然不对易性。这个条件要求协变导数的不对称性完全来自李括号，没有额外的扭转——先沿 X 再沿 Y 与先沿 Y 再沿 X，差别仅来自方向本身的不兼容，不会多出“拧转”。

[a] 李括号度量两个向量场流动方向的不兼容性。坐标下 $[X,Y]^k = \sum_i \left(X^i \dfrac{\partial Y^k}{\partial x^i} - Y^i \dfrac{\partial X^k}{\partial x^i} \right)$。对坐标基底 $\left[\dfrac{\partial}{\partial x^i}, \dfrac{\partial}{\partial x^j}\right] = 0$（分量为常数，互相求导为零），此时无挠条件简化为 $\Gamma^k_{ij} = \Gamma^k_{ji}$，即 Christoffel 符号关于下两个指标对称。

两个条件合在一起说：Levi-Civita 联络是与度量 g 完全适配且无额外自由度的联络——条件 (1) 保证平行移动是等距变换（保持 $g(Y,Z)$ 不变），条件 (2) 消除了挠率张量 $T(X,Y) = \nabla_X Y - \nabla_Y X - [X,Y]$ 这一自由度。两个约束恰好用尽了联络的全部自由度，因此给定度量后 Levi-Civita 联络唯一确定。

其 Christoffel 符号完全由度量决定：

$$\Gamma^k_{ij} = \frac{1}{2} \sum_l g^{kl} \left(\frac{\partial g_{jl}}{\partial x^i} + \frac{\partial g_{il}}{\partial x^j} - \frac{\partial g_{ij}}{\partial x^l} \right) \tag{8.11}$$

其中 g^{kl} 是度量矩阵的逆。一旦有度量，联络自动确定。

8.1.8 S^2 上的 Christoffel 符号

坐标 (θ, ϕ)，度量 $g_{\theta\theta} = 1$，$g_{\phi\phi} = \sin^2\theta$，$g_{\theta\phi} = 0$。逆矩阵 $g^{\theta\theta} = 1$，$g^{\phi\phi} = 1/\sin^2\theta$。

唯一随坐标变化的分量是 $g_{\phi\phi} = \sin^2\theta$，$\dfrac{\partial g_{\phi\phi}}{\partial\theta} = 2\sin\theta\cos\theta$。非零的 Christoffel 符号：

$$\Gamma^{\theta}_{\phi\phi} = \frac{1}{2}g^{\theta\theta}\left(-\frac{\partial g_{\phi\phi}}{\partial\theta}\right) = -\sin\theta\cos\theta \tag{8.12}$$

$$\Gamma^{\phi}_{\theta\phi} = \Gamma^{\phi}_{\phi\theta} = \frac{1}{2}g^{\phi\phi}\frac{\partial g_{\phi\phi}}{\partial\theta} = \frac{\cos\theta}{\sin\theta} = \cot\theta \tag{8.13}$$

物理含义：$\Gamma^{\theta}_{\phi\phi} = -\sin\theta\cos\theta$ 说沿纬线走会被拉向极点方向。$\Gamma^{\phi}_{\theta\phi} = \cot\theta$ 说沿经线走时东西方向的基底在偏转，靠近极点偏转越剧烈。

8.1.9 平行移动

Definition 8.3 (平行移动)

向量场 Y 沿曲线 $\gamma(t)$ **平行移动**，当且仅当

$$\nabla_{\dot\gamma} Y = 0 \tag{8.14}$$

即 Y 沿曲线方向 $\dot\gamma$ 的协变导数（Definition 8.1 中定义的 ∇）为零——Y 沿这条路径的“真正变化率”为零，向量在搬运过程中不转动。

坐标下展开为 ODE：

$$\frac{dY^k}{dt} = -\sum_{i,j}\Gamma^k_{ij}\,\dot\gamma^i\,Y^j \tag{8.15}$$

左边是分量的变化率，右边是基底扭曲量的负值。等式要求分量必须主动变化，恰好抵消基底随位置的扭曲，使向量整体不转动——就像站在旋转木马上，身体必须反向旋转才能始终面朝同一个方向。

在极坐标中，沿 θ 方向走时基底 $\dfrac{\partial}{\partial r}$ 在转动（$\Gamma^{\theta}_{\theta r} = \dfrac{1}{r}$）。要平行移动一个径向向量，它的 θ 分量就必须主动变化来补偿这个转动。分量在变，但向量本身没转。

这是一阶线性 ODE，给定曲线 $\gamma(t)$ 和初始向量 $Y(0) \in T_{\gamma(0)}M$，平行移动的结果唯一确定——这在 $T_{\gamma(0)}M$ 和 $T_{\gamma(1)}M$ 之间建立了线性映射，把不同点的切空间联系起来。

关键的一点：在弯曲空间中，这个映射依赖路径。同一个向量从 p 搬到 q，走不同的路，结果一般不同。旋转角的差异正是曲率的体现。

球面上的直觉：在球面上拿着一个箭头，沿一条路径走，全程不主动转动它（平行移动）。走一个闭合三角形回到起点后，箭头偏转了——旋转角等于三角形围成的球面面积。这是弯曲空间的本质效应。如图8.1所示。

8.2 测地线

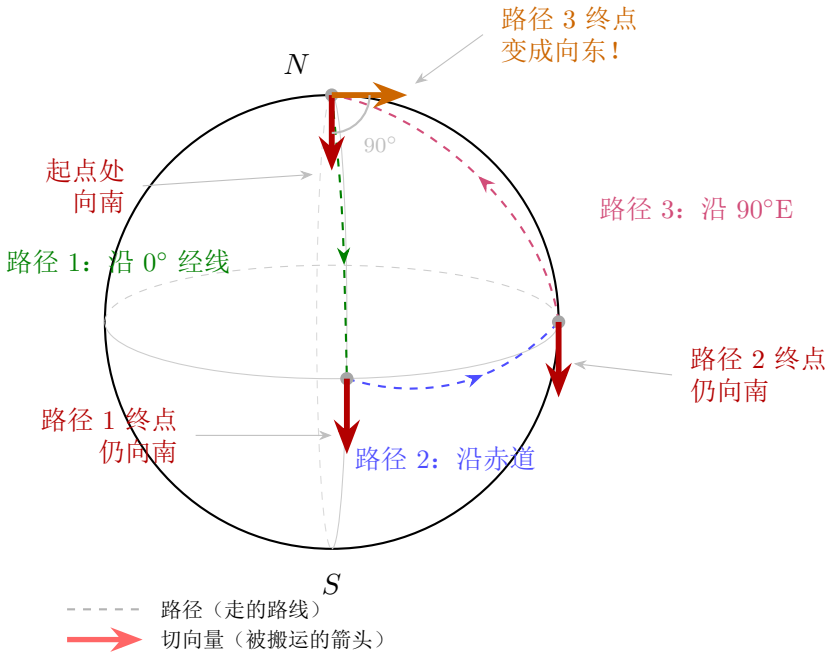

Figure 8.1: 平行移动

8.2.1 定义：弯曲空间中的“直线”

在 $\mathbb{R}^n$ 中，直线的速度向量不变——速度沿路径平行移动。测地线把这个性质推广到流形：

Definition 8.4 (测地线)

曲线 $\gamma(t)$ 是**测地线**，如果其速度向量沿自身平行移动：

$$\nabla_{\dot\gamma}\dot\gamma = 0 \tag{8.16}$$

8.2.2 测地线方程

代入协变导数的坐标公式，得到**测地线方程**：

$$\frac{d^2\gamma^k}{dt^2} + \sum_{i,j}\Gamma^k_{ij}\,\dot\gamma^i\,\dot\gamma^j = 0 \tag{8.17}$$

这是关于 $\gamma^k(t)$ 的二阶 ODE。给定初始位置 $\gamma(0) = p$ 和初始速度 $\dot\gamma(0) = v \in T_pM$，唯一确定一条测地线。

第一项 $\ddot\gamma^k$ 是坐标加速度。第二项是弯曲空间的修正。“笔直走”意味着坐标加速度恰好抵消空间弯曲的效应。

8.2.3 在 S^2 上验证

测地线方程展开为：

$$\ddot{\theta} - \sin\theta\cos\theta\,\dot{\phi}^2 = 0 \tag{8.18}$$

$$\ddot{\phi} + 2\cot\theta\,\dot{\theta}\,\dot{\phi} = 0 \tag{8.19}$$

经线：$\phi(t) = \phi_0$（常数），$\theta(t) = t$。则 $\dot{\phi} = 0$，$\ddot{\theta} = 0$，代入两个方程都得零。经线满足测地线方程——经线是大圆。

赤道：$\theta(t) = \pi/2$（常数），$\phi(t) = t$。则 $\dot{\theta} = 0$，$\ddot{\phi} = 0$，$\cos(\pi/2) = 0$。两个方程都满足。赤道也是测地线——赤道也是大圆。

一般纬线（如 $\theta = \pi/4$）：$\cos(\pi/4) \neq 0$，第一个方程的修正项 $-\sin\theta\cos\theta\,\dot{\phi}^2 \neq 0$，不满足测地线方程。纬线不是 “直线”——沿纬线走其实在拐弯。这就是飞机走大圆航线而不沿纬线飞的原因。

8.2.4 测地线的等价定义：最短路径

曲线长度 $L(\gamma) = \int_a^b \sqrt{\sum_{i,j} g_{ij}\,\dot{\gamma}^i\dot{\gamma}^j}\,dt$。对 L 做变分 $\delta L = 0$，得到的 Euler-Lagrange 方程恰好是测地线方程。因此两个定义等价：

- 速度沿自身平行移动：$\nabla_{\dot{\gamma}}\dot{\gamma} = 0$
- 曲线长度取极值：$\delta L = 0$

在 $\mathbb{R}^n$ 中都给出直线，在 S^2 上都给出大圆。

8.2.5 指数映射

Definition 8.5 (指数映射)

给定 $p \in M$ 和 $v \in T_pM$，设 $\gamma(t)$ 是满足 $\gamma(0) = p$、$\dot{\gamma}(0) = v$ 的测地线。**指数映射**定义为

$$\exp_p(v) = \gamma(1) \tag{8.20}$$

即从 p 出发，沿 v 方向笔直走单位时间到达的点。

指数映射把切空间（平坦的 $\mathbb{R}^n$）映到流形上。在 v 很小时接近恒等——切空间是流形在 p 附近的线性近似。

Remark (与深度学习的联系)

流形优化中，参数 θ 在流形 M 上，梯度 $g \in T_\theta M$ 是切向量。更新参数时用 $\theta_{\text{new}} = \exp_\theta(-\eta g)$，保证结果仍在流形上。实际中常用 retraction（指数映射的一阶近似）代替精确的 exp。

8.3 曲率

8.3.1 动机：平行移动的路径依赖性

在 $\mathbb{R}^n$ 中，平行移动不依赖路径。在弯曲空间中，走不同的路到同一个终点，搬运的向量方向会不同。曲率量化的就是这件事：走一个无穷小闭合回路，向量偏转了多少。

8.3.2 曲率张量的定义

Definition 8.6 (黎曼曲率张量)

$$R(X,Y)Z = \nabla_X \nabla_Y Z - \nabla_Y \nabla_X Z - \nabla_{[X,Y]} Z \tag{8.21}$$

逐项含义：

$\nabla_X \nabla_Y Z$：对 Z 先沿 Y 求协变导数，再沿 X 求一次。对向量场做了两次“求导”，先 Y 后 X。

$\nabla_Y \nabla_X Z$：顺序反过来，先沿 X 再沿 Y。

$\nabla_X \nabla_Y Z - \nabla_Y \nabla_X Z$：两次协变导数交换顺序的差。在平坦空间中为零（类比偏导数交换 $\partial_x \partial_y = \partial_y \partial_x$），在弯曲空间中不为零。

$\nabla_{[X,Y]} Z$：修正项。$[X,Y]$ 是李括号，度量两个方向的“不兼容性”。在坐标基底下 $\left[\frac{\partial}{\partial x^i}, \frac{\partial}{\partial x^j}\right] = 0$，所以此项消失，曲率简化为

$$R(\partial_i, \partial_j)\partial_k = \nabla_{\partial_i} \nabla_{\partial_j} \partial_k - \nabla_{\partial_j} \nabla_{\partial_i} \partial_k \tag{8.22}$$

减去 $\nabla_{[X,Y]} Z$ 是为了让 R 成为张量——只依赖 X, Y, Z 在那一点的值。

也就是说：**曲率 = 协变导数交换顺序的差**。

Remark (与广义相对论的联系)

本章的微分几何正是广义相对论的数学语言。开篇爱因斯坦的引言——“自然定律应当由对一切坐标系都成立的方程来表达”——是广义相对论的核心原则（广义协变性）。本章每个概念在广义相对论中都有直接的物理对应：度量 g_{ij} 描述时空的几何，即引力场本身；Christoffel 符号 Γ^k_{ij} 对应引力效应——自由下落的物体走测地线，测地线方程中的 Γ^k_{ij} 项就是引力“加速度”；黎曼曲率张量 $R^l{}_{kij}$ 描述时空弯曲，即潮汐力。对黎曼曲率缩并一次得到 Ricci 曲率 $R_{ij} = \sum_l R^l{}_{ilj}$，它出现在爱因斯坦场方程中：

$$R_{ij} - \frac{1}{2} R g_{ij} = 8\pi G T_{ij} \tag{8.23}$$

左边由曲率构成，右边 T_{ij} 是物质能量——质能决定时空如何弯曲，弯曲决定物质如何运动。本章与广义相对论的数学完全一致，只是应用场景不同：一个用在时空几何上，一个用在参数空间和数据流形上。

8.3.3 坐标公式

$$R\left(\frac{\partial}{\partial x^i}, \frac{\partial}{\partial x^j}\right) \frac{\partial}{\partial x^k} = \sum_l R^l{}_{kij} \frac{\partial}{\partial x^l} \tag{8.24}$$

其中

$$R^l{}_{kij} = \frac{\partial \Gamma^l_{jk}}{\partial x^i} - \frac{\partial \Gamma^l_{ik}}{\partial x^j} + \sum_m \left(\Gamma^l_{im}\Gamma^m_{jk} - \Gamma^l_{jm}\Gamma^m_{ik}\right) \tag{8.25}$$

前两项是 Christoffel 符号的偏导之差，后两项是 Christoffel 符号的二次项之差。

Proof. 从坐标基底下的曲率定义 $R(\partial_i, \partial_j)\partial_k = \nabla_{\partial_i}\nabla_{\partial_j}\partial_k - \nabla_{\partial_j}\nabla_{\partial_i}\partial_k$ 出发（李括号项 $\nabla_{[\partial_i,\partial_j]}\partial_k = 0$）。

先算 $\nabla_{\partial_i}\nabla_{\partial_j}\partial_k$。内层由 Christoffel 符号的定义得

$$\nabla_{\partial_j}\partial_k = \sum_m \Gamma^m_{jk}\,\partial_m \tag{8.26}$$

外层对此再求协变导数，由莱布尼兹法则（Γ^m_{jk} 是函数，∂_m 是向量场）：

$$\nabla_{\partial_i}\left(\sum_m \Gamma^m_{jk}\,\partial_m\right) = \sum_m \left(\frac{\partial \Gamma^m_{jk}}{\partial x^i}\,\partial_m + \Gamma^m_{jk}\,\nabla_{\partial_i}\partial_m\right) \tag{8.27}$$

$$= \sum_l \frac{\partial \Gamma^l_{jk}}{\partial x^i}\,\partial_l + \sum_{l,m} \Gamma^l_{im}\Gamma^m_{jk}\,\partial_l \tag{8.28}$$

其中第二步将 $\nabla_{\partial_i}\partial_m = \sum_l \Gamma^l_{im}\,\partial_l$ 代入，并将求和哑指标统一为 l。

$\nabla_{\partial_j}\nabla_{\partial_i}\partial_k$ 的计算完全相同，只需交换 i, j：

$$\nabla_{\partial_j}\nabla_{\partial_i}\partial_k = \sum_l \frac{\partial \Gamma^l_{ik}}{\partial x^j}\,\partial_l + \sum_{l,m} \Gamma^l_{jm}\Gamma^m_{ik}\,\partial_l \tag{8.29}$$

两式相减，提取 ∂_l 前的系数即得

$$R^l{}_{kij} = \frac{\partial \Gamma^l_{jk}}{\partial x^i} - \frac{\partial \Gamma^l_{ik}}{\partial x^j} + \sum_m \left(\Gamma^l_{im}\Gamma^m_{jk} - \Gamma^l_{jm}\Gamma^m_{ik}\right) \tag{8.30}$$

■

四个指标的含义：i = 第一个求导方向，j = 第二个求导方向，k = 被操作的向量，l = 结果的分量方向。

8.3.4 在 S^2 上计算

计算 $R^\theta{}_{\phi\theta\phi}$（$l = \theta$，$k = \phi$，$i = \theta$，$j = \phi$）：

$$R^\theta{}_{\phi\theta\phi} = \frac{\partial \Gamma^\theta_{\phi\phi}}{\partial \theta} - \frac{\partial \Gamma^\theta_{\theta\phi}}{\partial \phi} + \sum_m \left(\Gamma^\theta_{\theta m}\Gamma^m_{\phi\phi} - \Gamma^\theta_{\phi m}\Gamma^m_{\theta\phi}\right) \tag{8.31}$$

$$= \frac{\partial(-\sin\theta\cos\theta)}{\partial\theta} - 0 + (0 - (-\sin\theta\cos\theta)\cot\theta) \tag{8.32}$$

$$= (-\cos^2\theta + \sin^2\theta) + \cos^2\theta = \sin^2\theta \tag{8.33}$$

Remark (曲率张量的分量数目)

$R^l{}_{kij}$ 有四个指标，在 n 维流形上共 n^4 个分量。但曲率张量具有反对称性 $R^l{}_{kij} = -R^l{}_{kji}$（交换两个求导方向变号）等对称性，独立分量数大幅减少，为 $\dfrac{n^2(n^2-1)}{12}$。在 S^2 上 $n=2$，独立分量仅 1 个——二维曲面只有一个二维平面可选，一个数足以描述弯曲程度。在四维时空中 $n=4$，独立分量为 20 个。

8.3.5 截面曲率

曲率张量 $R^l{}_{kij}$ 的上标 l 是分量指标。用度量 g 把它“降下来”，定义全下标版本：

$$R_{lkij} = \sum_s g_{ls}\, R^s{}_{kij} \tag{8.34}$$

这类似于向量 v^i 和 $v_i = \sum_j g_{ij} v^j$ 的关系——度量把上标（逆变）转换为下标（协变），不改变几何内容，只是换一种记法，使所有指标处于对等的位置。

Definition 8.7 (截面曲率)

在点 p 处选一个由切向量 u, v 张成的二维平面 $\sigma \subset T_pM$，**截面曲率**定义为

$$K(\sigma) = \frac{R_{lkij}\, u^l v^k u^i v^j}{g(u,u)\, g(v,v) - g(u,v)^2} \tag{8.35}$$

分子是曲率张量在该平面上的取值，分母是 u, v 张成的平行四边形的面积平方，起归一化作用——使结果只依赖 u, v 张成的平面，不依赖 u, v 本身的选取。截面曲率度量空间沿该二维平面方向的弯曲程度：正值表示测地线聚拢（如球面），负值表示测地线发散（如马鞍面），零表示该方向平坦。

在 S^2 上取 $u = \dfrac{\partial}{\partial\theta}$，$v = \dfrac{\partial}{\partial\phi}$。降指标得

$$R_{\theta\phi\theta\phi} = g_{\theta\theta}\, R^\theta{}_{\phi\theta\phi} = 1 \cdot \sin^2\theta = \sin^2\theta \tag{8.36}$$

截面曲率：

$$K = \frac{R_{\theta\phi\theta\phi}}{g_{\theta\theta} g_{\phi\phi} - g_{\theta\phi}^2} = \frac{\sin^2\theta}{\sin^2\theta} = 1 \tag{8.37}$$

单位球面的截面曲率处处为 1——常曲率空间。半径 r 的球面截面曲率为 $1/r^2$。

8.3.6 曲率的不同层次

黎曼曲率张量 $R^l{}_{kij}$ 包含了弯曲的全部信息，但有四个指标，不容易直接解读。通过逐步缩并（求和掉指标），可以提取出越来越粗糙但更直观的曲率信息。

截面曲率 $K(\sigma)$：取 T_pM 中一个二维平面 σ，度量沿此平面方向的弯曲程度。这是最细致的曲率信息——在不同二维平面上截面曲率可以不同。在单位球面 S^2 上，切空间是二维的，只有一个二维

平面可选（切空间本身），所以截面曲率只有一个值。由前面的计算 $K = \dfrac{\sin^2\theta}{\sin^2\theta} = 1$，这一个数就包含了单位球面全部的曲率信息。

Ricci 曲率：对曲率张量的第一个和第三个指标缩并，$\mathrm{Ric}_{kj} = \sum_l R^l{}_{klj}$。几何含义：从点 p 沿方向 v 发射一束测地线，Ricci 曲率度量这束测地线的体积变化率。$\mathrm{Ric}(v,v) > 0$ 表示测地线聚拢（体积缩小，如球面），$\mathrm{Ric}(v,v) < 0$ 表示测地线发散（体积增大，如马鞍面）。截面曲率描述一个二维平面方向的弯曲，Ricci 曲率则是对一个方向上所有二维平面取平均。

标量曲率：对 Ricci 曲率再缩并一次，$S = \sum_{i,j} g^{ij}\mathrm{Ric}_{ij}$。这是对所有方向的 Ricci 曲率再取平均，得到一个数。它是最粗糙的曲率信息，只告诉你点 p 附近的空间“总体上”是正弯（像球）、负弯（像马鞍）还是平的。在 S^2 上，$S = 2K = 2$。

8.3.7 曲率与平行移动旋转

对常曲率 K 的曲面，平行移动绕闭合回路后的旋转角等于

$$\Delta\alpha = K \cdot A \tag{8.38}$$

其中 A 是回路围成的面积。单位球上 $K = 1$，球面三角形面积 $A = \pi/2$，旋转角 $= \pi/2 = 90°$。这是高斯-博内定理的局部版本。

Remark (与深度学习的联系)

损失曲面的几何：Hessian 矩阵 $H_{ij} = \dfrac{\partial^2 L}{\partial\theta^i\partial\theta^j}$ 描述损失曲面的局部弯曲。正特征值对应碗底方向，负特征值对应鞍点的逃逸方向。

双曲嵌入：树状结构的数据适合嵌入负曲率空间（双曲空间），因为双曲空间的体积随半径指数增长，天然匹配指数增长的树状结构。

8.4 流形上的微积分：微分形式

8.4.1 动机

度量中的 $d\theta$、$d\phi$ 到底是什么？多元微积分中的线积分 $\int_C P\,dx + Q\,dy$ 和面积分 $\iint f\,dx\,dy$ 中的 dx、dy 是什么？微分形式给这些符号严格的定义，并统一所有积分定理。

8.4.2 1-形式：切向量的对偶

Definition 8.8 (1-形式)

p 点处的一个 **1-形式** ω_p 是线性映射 $\omega_p : T_pM \to \mathbb{R}$。所有这样的线性映射构成**余切空间** T_p^*M，它是切空间 T_pM 的对偶空间。切向量吃一个函数返回实数（方向导数），1-形式吃一个切向量返回实数——两者互为对偶。

坐标函数的微分 dx^i 是最基本的 1-形式：

$$dx^i\left(\frac{\partial}{\partial x^j}\right)=\delta^i_j=\begin{cases}1 & i=j\\ 0 & i\neq j\end{cases} \tag{8.39}$$

dx^i 吃进一个向量，返回它在第 i 个方向上的分量。

对切向量 $v=v^1\dfrac{\partial}{\partial x^1}+v^2\dfrac{\partial}{\partial x^2}$：

$$dx^1(v)=v^1,\qquad dx^2(v)=v^2 \tag{8.40}$$

一般的 1-形式：$\omega=\sum_i f_i\,dx^i$，其中 f_i 是光滑函数。

Example

在 $\mathbb{R}^2$ 中，$\omega=y\,dx-x\,dy$。在点 $(3,2)$ 对向量 $v=(1,4)$ 求值：

$$\omega(v)=2\cdot 1-3\cdot 4=-10 \tag{8.41}$$

Remark (对偶基底)

坐标 $(x^1,x^2,\ldots,x^n)$ 同时给出两组基底：

- 切空间 T_pM 的基底：$\left\{\dfrac{\partial}{\partial x^1},\dfrac{\partial}{\partial x^2},\ldots,\dfrac{\partial}{\partial x^n}\right\}$，用于展开切向量。
- 余切空间 T_p^*M 的基底：$\{dx^1,dx^2,\ldots,dx^n\}$，用于展开 1-形式。

两组基底互为对偶：$dx^i\left(\dfrac{\partial}{\partial x^j}\right)=\delta^i_j$，即第 i 个余切基底作用在第 j 个切基底上，同方向得 1，不同方向得 0。这意味着 dx^i 的作用就是提取切向量的第 i 个分量：对 $v=\sum_k v^k\dfrac{\partial}{\partial x^k}$，有 $dx^i(v)=v^i$。

8.4.3 函数的微分

光滑函数 $f:M\to\mathbb{R}$ 的微分 df 是 1-形式：$df(v)=v(f)$（f 沿 v 方向的方向导数）。坐标下：

$$df=\sum_i\frac{\partial f}{\partial x^i}\,dx^i \tag{8.42}$$

这就是多元微积分的全微分。坐标函数 x^i 的微分就是 dx^i——基底 1-形式的名字由此而来。

Example

在 $\mathbb{R}^2$ 中取 $f(x,y)=x^2+y$，切向量 $v=3\dfrac{\partial}{\partial x}+2\dfrac{\partial}{\partial y}$，在点 $(1,0)$ 处验证 $df(v)=v(f)$。

一方面，$df=2x\,dx+dy$，对 v 求值：

$$df(v)=2\cdot 1\cdot 3+1\cdot 2=8 \tag{8.43}$$

另一方面，f 沿 v 的方向导数：

$$v(f) = 3\frac{\partial f}{\partial x} + 2\frac{\partial f}{\partial y} = 3 \cdot 2 \cdot 1 + 2 \cdot 1 = 8 \tag{8.44}$$

两者相等：函数的微分作用在向量上，就是函数沿该向量的方向导数。

8.4.4 楔积与 2-形式

1-形式吃一个切向量返回实数，测量 “沿一个方向走了多少”。自然的问题是：如何测量 “两个方向张成的面积”？这就需要 2-形式——吃两个切向量返回实数的线性映射。

楔积是从 1-形式构造 2-形式的工具：把两个基底 1-形式 dx^i 和 dx^j “楔” 在一起，得到一个基底 2-形式 $dx^i \wedge dx^j$。

Definition 8.9 (楔积)

$$dx^i \wedge dx^j(u, v) = dx^i(u)\, dx^j(v) - dx^i(v)\, dx^j(u) = u^i v^j - u^j v^i \tag{8.45}$$

结果 $u^i v^j - u^j v^i$ 正是 u, v 投影到 x^i-x^j 平面后的有符号面积（2×2 行列式）。

关键性质——**反对称**：

$$dx^i \wedge dx^j = -dx^j \wedge dx^i, \qquad dx^i \wedge dx^i = 0 \tag{8.46}$$

交换 u, v 相当于翻转平行四边形的朝向，面积变号；一个方向和自己张不出面积。

在 n 维流形上，基底 2-形式为 $dx^i \wedge dx^j$（$i < j$），共 $\binom{n}{2}$ 个。一般的 2-形式是它们的线性组合。

Example

$\mathbb{R}^3$ 中，基底 2-形式有 $\binom{3}{2} = 3$ 个：$dx \wedge dy$、$dy \wedge dz$、$dz \wedge dx$。$dx \wedge dy(u, v) = u^1 v^2 - u^2 v^1$，即投影到 xy 平面后的面积。一般的 2-形式：$\omega = f\, dx \wedge dy + g\, dy \wedge dz + h\, dz \wedge dx$。

8.4.5 k-形式与体积形式

k-形式吃 k 个切向量，返回一个实数，完全反对称。在 n 维流形上，k-形式的基底是 $dx^{i_1} \wedge \cdots \wedge dx^{i_k}$（$i_1 < \cdots < i_k$），共 $\binom{n}{k}$ 个。

特别地，n-形式只有一个基底 $dx^1 \wedge dx^2 \wedge \cdots \wedge dx^n$，在每个点由一个数决定。这就是**体积形式**——流形上定义积分的基础。

8.4.6 外导数

外导数 d 是微分形式的 “求导” 运算。普通导数把函数变成函数，外导数把 k-形式变成 $(k+1)$-形式——每求一次导，形式的阶数升一。

对 0-形式（函数）：

$$df = \sum_i \frac{\partial f}{\partial x^i}\, dx^i \tag{8.47}$$

这就是多元微积分中的全微分，把一个函数（0-形式）变成一个 1-形式。前面定义过的 $df(v) = v(f)$ 就是这个。

对 1-形式 $\omega = \sum_i f_i\, dx^i$：

$$d\omega = \sum_i df_i \wedge dx^i \tag{8.48}$$

操作很机械——对每个系数函数 f_i 求全微分 df_i，再和对应的 dx^i 做楔积。结果是一个 2-形式。

本质上，外导数对形式的系数函数求微分，再用楔积升阶。0-形式求导得 1-形式（全微分，对应梯度），1-形式求导得 2-形式（对应旋度），2-形式求导得 3-形式（对应散度）。这就是为什么外导数能统一梯度、旋度、散度——都是 d 在不同阶数上的表现。

Example

在 $\mathbb{R}^2$ 中，$\omega = P\,dx + Q\,dy$：

$$d\omega = dP \wedge dx + dQ \wedge dy \tag{8.49}$$

$$= \frac{\partial P}{\partial y} dy \wedge dx + \frac{\partial Q}{\partial x} dx \wedge dy \tag{8.50}$$

$$= \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y}\right) dx \wedge dy \tag{8.51}$$

其中利用了 $dx \wedge dx = 0$，$dy \wedge dx = -dx \wedge dy$。括号中就是旋度。

最重要的性质：

$$d(d\omega) = 0 \tag{8.52}$$

对任何形式成立，等价于混合偏导可交换。在 $\mathbb{R}^3$ 中对应 $\operatorname{curl}(\operatorname{grad} f) = 0$ 和 $\operatorname{div}(\operatorname{curl} \vec{F}) = 0$。

8.4.7 斯托克斯定理

Theorem 8.10 (广义斯托克斯定理)

设 Ω 是带边界的定向流形，ω 是 $(\dim \Omega - 1)$-形式，则

$$\int_{\partial\Omega} \omega = \int_{\Omega} d\omega \tag{8.53}$$

一个公式统一了下表内容：

Table 8.1: 广义斯托克斯定理的特例

k	维度	定理
0	$n=1$	微积分基本定理 $\int_a^b f'dx = f(b)-f(a)$
1	$n=2$	格林公式
1	$n=3$	经典斯托克斯公式（旋度定理）
2	$n=3$	高斯散度定理

而且它在任意流形上成立——即不需要坐标系，也不需要嵌入环境空间。

Remark (与深度学习的联系)

Normalizing flows 的核心是变量替换公式。设 $\varphi:\mathbb{R}^n\to\mathbb{R}^n$ 是微分同胚，概率密度的变换为

$$p_Y(y) = p_X(\varphi^{-1}(y))\left|\det\frac{\partial\varphi^{-1}}{\partial y}\right| \tag{8.54}$$

用微分形式语言，这是体积形式的拉回。n-形式 $p(x)\,dx^1\wedge\cdots\wedge dx^n$ 经坐标变换后，楔积的反对称性自动产生 Jacobian 行列式。流形上的概率分布定义为体积形式，保证积分不依赖坐标选择。

8.5 总结：概念链条

从度量出发，整个微分几何大厦层层推出：

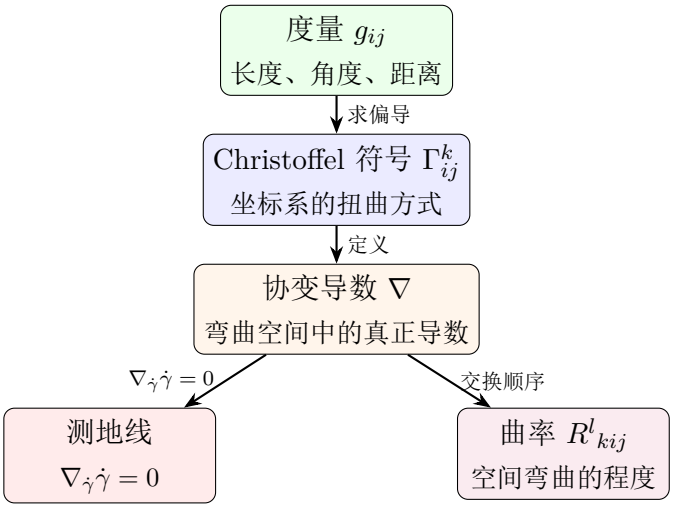

Figure 8.2: 总结：概念链条

微分形式提供了另一套平行的语言：1-形式是切向量的对偶，楔积和外导数把微积分（线积分、面积分、斯托克斯定理）推广到任意流形上。

每一层都从前一层自然推出，不需要额外输入。整个大厦建在度量这一个基础上。

深度学习的微分几何基础（三）：信息几何、流形优化、生成模型与几何深度学习

April 13, 2026

Only the genius of Riemann, solitary and uncomprehended, had already won its way by the middle of the last century to a new conception of space, in which space was deprived of its rigidity, and in which its power to take part in physical events was recognized as possible.

—*Albert Einstein*

9.1 信息几何与自然梯度

9.1.1 动机

训练神经网络时，我们在参数空间 $\theta \in \mathbb{R}^d$ 中做梯度下降：$\theta \leftarrow \theta - \eta \nabla L$。这个更新规则隐含了一个假设——参数空间是平坦的欧几里得空间，沿任何方向走“一步”的代价都相同。

但这个假设是错的。考虑一个简单的例子：改变某个参数可能让网络的输出分布剧烈变化，而改变另一个参数却几乎毫无影响。对于优化来说，前者应该走小步（敏感方向），后者应该走大步（迟钝方向）。然而欧几里得度量对这种差异一无所知——它只看参数本身移动了多远，不关心输出分布变了多少。

信息几何提供了解决思路：不要用欧几里得度量衡量参数空间的距离，而是用一个能反映“参数变化对输出分布影响大小”的度量。这个度量就是 Fisher 信息矩阵。在这个度量下，敏感方向自动变“长”（走一小步代价大），迟钝方向自动变“短”（走一大步代价小），梯度下降就能自适应地调整各方向的步长。

9.1.2 统计流形

Definition 9.1 (统计流形)

设 $\mathcal{X}$ 是样本空间，$\Theta \subset \mathbb{R}^n$ 是开集。参数化概率分布族

$$\mathcal{S} = \{p(x|\theta) : \theta \in \Theta\} \tag{9.1}$$

构成 n 维**统计流形**，如果满足：

(1) $\theta \mapsto p(x|\theta)$ 对每个 x 是 C^∞ 的

(2) 不同参数给出不同分布（单射）

(3) $p(x|\theta) > 0$ 对所有 x, θ（支撑集不随参数变化）

(4) 可在积分号下对 θ 求导（正则性条件）

Θ 本身是 $\mathbb{R}^n$ 的开集，天然具有光滑流形结构。但光有流形还不够——我们需要在上面定义一个有统计意义的黎曼度量，使得 “距离” 反映分布之间的差异而非参数数值的差异。

Example (一维高斯族)

$p(x|\mu, \sigma^2) = \dfrac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\dfrac{(x-\mu)^2}{2\sigma^2}\right)$，参数 $\theta = (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_{>0}$。每个 θ 对应一个高斯分布，这族分布构成 2 维统计流形。
$(\mu, \sigma^2) = (0, 1)$ 和 $(0.1, 1)$ 之间欧几里得距离为 0.1。$(0, 100)$ 和 $(0.1, 100)$ 之间也是 0.1。但后者的两个分布几乎一模一样（$\sigma = 10$ 的高斯下 μ 差 0.1 根本看不出来），前者差别明显。欧几里得距离忽略了参数对分布的影响大小。

9.1.3 Fisher 信息矩阵的定义

Definition 9.2 (Fisher 信息矩阵)

$$F_{ij}(\theta) = \mathbb{E}_{x \sim p(\cdot|\theta)} \left[\frac{\partial \log p(x|\theta)}{\partial \theta^i} \frac{\partial \log p(x|\theta)}{\partial \theta^j} \right] \tag{9.2}$$

逐个符号：

- $\log p(x|\theta)$：对数似然函数
- $\dfrac{\partial \log p(x|\theta)}{\partial \theta^i}$：对数似然对第 i 个参数的偏导，叫 **score function** 的第 i 个分量
- 记 score 向量 $s(\theta, x) = \nabla_\theta \log p(x|\theta)$，则 $F_{ij} = \mathbb{E}[s_i\, s_j]$
- $\mathbb{E}_{x \sim p(\cdot|\theta)}$：对 x 在当前参数 θ 对应的分布下取期望

F 是 $n \times n$ 矩阵，随 θ 变化。各分量含义：F_{ii} 度量沿 θ^i 方向走一小步分布变化多大，F_{ij}（$i \neq j$）度量两个方向的耦合，$F_{ij} = 0$ 表示正交。

9.1.4 验证 Fisher 矩阵是黎曼度量

要使 $F(\theta)$ 成为合法的黎曼度量，需要验证它在每个 θ 处是光滑的、对称的、正定的二次型。

对称性：直接由定义得出。$F_{ij} = \mathbb{E}[s_i\, s_j] = \mathbb{E}[s_j\, s_i] = F_{ji}$，乘法交换律即可。

正半定性：对任意 $v \in \mathbb{R}^n$，

$$\sum_{i,j} F_{ij}\, v^i v^j = \mathbb{E}\left[\left(\sum_i v^i s_i\right)^2\right] \geq 0 \tag{9.3}$$

右边是一个随机变量的平方的期望，非负。

正定性：上式等号成立当且仅当 $\sum_i v^i s_i(x) = 0$ 对几乎所有 x 成立。在统计流形的正则条件下，这意味着 v^i 的线性组合 $\sum_i v^i\, \partial_i \log p(x|\theta)$ 几乎处处为零。由于不同参数方向对 $\log p$ 的偏导是线性无关的（否则某些参数就是冗余的，违反定义中的单射条件 (2)），所以必须 $v = 0$。因此 F 正定。

光滑性：$F_{ij}(\theta) = \mathbb{E}_{x\sim p(\cdot|\theta)}[s_i\, s_j]$ 是关于 θ 的光滑函数。统计流形定义中的条件 (1) 保证 $\theta \mapsto p(x|\theta)$ 光滑，从而 $s_i(\theta, x) = \partial_i \log p(x|\theta)$ 及其乘积对 θ 光滑；条件 (4) 允许对 θ 的求导穿过期望的积分号，因此 $F_{ij}(\theta)$ 继承了被积函数的光滑性。

9.1.5 等价定义：用 Hessian 表示

Proposition 9.3

在正则条件下：$F_{ij}(\theta) = -\mathbb{E}_{x\sim p(\cdot|\theta)}\left[\dfrac{\partial^2 \log p(x|\theta)}{\partial\theta^i \partial\theta^j}\right]$

Proof. 从归一化条件 $\int p(x|\theta)\, dx = 1$ 出发。对 θ^i 求导：

$$\int \frac{\partial p}{\partial \theta^i}\, dx = 0 \tag{9.4}$$

利用恒等式 $\dfrac{\partial p}{\partial \theta^i} = p \cdot \dfrac{\partial \log p}{\partial \theta^i} = p \cdot s_i$，上式化为：

$$\mathbb{E}[s_i] = \int p\, s_i\, dx = 0 \tag{9.5}$$

即 score 函数的期望为零。

再对 θ^j 求导（利用条件 (4) 将求导穿过积分号）：

$$\int \frac{\partial^2 p}{\partial \theta^i \partial \theta^j}\, dx = 0 \tag{9.6}$$

展开左边的被积函数：

$$\frac{\partial^2 p}{\partial \theta^i \partial \theta^j} = \frac{\partial}{\partial \theta^j}(p\, s_i) = p\, s_i\, s_j + p\, \frac{\partial^2 \log p}{\partial \theta^i \partial \theta^j} \tag{9.7}$$

代入积分等式，两项分别取期望：

$$\mathbb{E}[s_i\, s_j] + \mathbb{E}\left[\frac{\partial^2 \log p}{\partial \theta^i \partial \theta^j}\right] = 0 \tag{9.8}$$

第一项正是 F_{ij}，移项即得 $F_{ij} = -\mathbb{E}\left[\frac{\partial^2 \log p}{\partial\theta^i \partial\theta^j}\right]$。 ■

9.1.6 高斯族的 Fisher 度量：完整计算

以一维高斯族为例，参数 $\theta = (\theta^1, \theta^2) = (\mu, \sigma^2)$。对数似然为：

$$\log p(x|\mu, \sigma^2) = -\frac{1}{2}\log(2\pi) - \frac{1}{2}\log\sigma^2 - \frac{(x-\mu)^2}{2\sigma^2} \tag{9.9}$$

对两个参数分别求导，得到 score 分量：

$$s_1 = \frac{\partial \log p}{\partial \mu} = \frac{x-\mu}{\sigma^2}, \qquad s_2 = \frac{\partial \log p}{\partial \sigma^2} = -\frac{1}{2\sigma^2} + \frac{(x-\mu)^2}{2\sigma^4} \tag{9.10}$$

计算 $F_{ij} = \mathbb{E}[s_i\, s_j]$ 需要以下关于 $x \sim \mathcal{N}(\mu, \sigma^2)$ 的矩：

$$\mathbb{E}[x-\mu] = 0, \quad \mathbb{E}[(x-\mu)^2] = \sigma^2, \quad \mathbb{E}[(x-\mu)^3] = 0, \quad \mathbb{E}[(x-\mu)^4] = 3\sigma^4 \tag{9.11}$$

下面逐个计算 Fisher 矩阵的各分量。

F_{11}（μ–μ 分量）

$$F_{11} = \mathbb{E}[s_1^2] = \mathbb{E}\left[\frac{(x-\mu)^2}{\sigma^4}\right] = \frac{\sigma^2}{\sigma^4} = \frac{1}{\sigma^2} \tag{9.12}$$

F_{22}（σ^2–σ^2 分量）

$$F_{22} = \mathbb{E}[s_2^2] = \mathbb{E}\left[\left(-\frac{1}{2\sigma^2} + \frac{(x-\mu)^2}{2\sigma^4}\right)^2\right] \tag{9.13}$$

展开平方，逐项取期望：

$$F_{22} = \frac{1}{4\sigma^4} - 2\cdot\frac{1}{2\sigma^2}\cdot\frac{\sigma^2}{2\sigma^4} + \frac{3\sigma^4}{4\sigma^8} = \frac{1}{4\sigma^4} - \frac{1}{2\sigma^4} + \frac{3}{4\sigma^4} = \frac{1}{2\sigma^4} \tag{9.14}$$

F_{12}（交叉分量）

$$F_{12} = \mathbb{E}[s_1\, s_2] = \mathbb{E}\left[\frac{x-\mu}{\sigma^2}\left(-\frac{1}{2\sigma^2} + \frac{(x-\mu)^2}{2\sigma^4}\right)\right] \tag{9.15}$$

展开后，各项分别含 $\mathbb{E}[x-\mu] = 0$ 和 $\mathbb{E}[(x-\mu)^3] = 0$，因此：

$$F_{12} = 0 \tag{9.16}$$

综合以上结果，一维高斯族的 Fisher 信息矩阵为：

$$\boxed{F = \begin{pmatrix} 1/\sigma^2 & 0 \\ 0 & 1/(2\sigma^4) \end{pmatrix}} \tag{9.17}$$

对角结构说明 μ 和 σ^2 在 Fisher 度量下正交——改变均值不影响对方差的信息，反之亦然。$F_{11} = 1/\sigma^2$ 表明方差越大，μ 方向越“短”（分布对均值变化越不敏感），与动机小节9.1.1中的直觉一致。

9.1.7 KL 散度与 Fisher 度量的关系

Proposition 9.4

对于统计流形上的邻近两点 θ 和 $\theta + d\theta$，KL 散度在局部由 Fisher 度量决定：

$$D_{\mathrm{KL}}(p_\theta \| p_{\theta+d\theta}) = \frac{1}{2}\sum_{i,j} F_{ij}(\theta)\, d\theta^i\, d\theta^j + O(|d\theta|^3) \tag{9.18}$$

右边的 $\sum_{i,j} F_{ij}\, d\theta^i\, d\theta^j$ 正是 Fisher 度量定义的黎曼距离平方 ds^2，因此 KL 散度在无穷小尺度下等于 $\frac{1}{2}\, ds^2$——系数 $\frac{1}{2}$ 来自 Taylor 展开的二阶项。

Proof. 从 KL 散度的定义出发：

$$D_{\mathrm{KL}}(p_\theta \| p_{\theta+d\theta}) = \mathbb{E}_{x\sim p_\theta}\left[\log \frac{p(x|\theta)}{p(x|\theta+d\theta)}\right] = \mathbb{E}_{x\sim p_\theta}[\log p(x|\theta) - \log p(x|\theta+d\theta)] \tag{9.19}$$

对 $\log p(x|\theta+d\theta)$ 在 θ 处作 Taylor 展开到二阶：

$$\log p(x|\theta+d\theta) = \log p(x|\theta) + \sum_i \frac{\partial \log p}{\partial \theta^i}\, d\theta^i + \frac{1}{2}\sum_{i,j} \frac{\partial^2 \log p}{\partial \theta^i \partial \theta^j}\, d\theta^i\, d\theta^j + O(|d\theta|^3) \tag{9.20}$$

代入 KL 散度的表达式，$\log p(x|\theta)$ 项相消：

$$D_{\mathrm{KL}} = \mathbb{E}_{x\sim p_\theta}\left[-\sum_i \frac{\partial \log p}{\partial \theta^i}\, d\theta^i - \frac{1}{2}\sum_{i,j} \frac{\partial^2 \log p}{\partial \theta^i \partial \theta^j}\, d\theta^i\, d\theta^j\right] + O(|d\theta|^3) \tag{9.21}$$

考察一阶项。将期望移入求和：

$$\mathbb{E}_{x\sim p_\theta}\left[\sum_i \frac{\partial \log p}{\partial \theta^i}\, d\theta^i\right] = \sum_i \mathbb{E}[s_i]\, d\theta^i = 0 \tag{9.22}$$

最后一步用到了上一小节证明的结论 $\mathbb{E}[s_i] = 0$（score 期望为零）。因此一阶项消失。

剩下二阶项：

$$D_{\mathrm{KL}} = -\frac{1}{2}\sum_{i,j} \mathbb{E}_{x\sim p_\theta}\left[\frac{\partial^2 \log p}{\partial \theta^i \partial \theta^j}\right] d\theta^i\, d\theta^j + O(|d\theta|^3) \tag{9.23}$$

由 Fisher 矩阵的 Hessian 等价定义 $F_{ij} = -\mathbb{E}\left[\frac{\partial^2 \log p}{\partial \theta^i \partial \theta^j}\right]$，代入即得：

$$D_{\mathrm{KL}}(p_\theta \| p_{\theta+d\theta}) = \frac{1}{2}\sum_{i,j} F_{ij}(\theta)\, d\theta^i\, d\theta^j + O(|d\theta|^3) \tag{9.24}$$

■

这个结果揭示了 Fisher 度量的统计本质：黎曼距离 $ds^2 = \sum_{i,j} F_{ij}\, d\theta^i\, d\theta^j$ 度量的正是两个邻近分布之间的 KL 散度。Fisher 度量不是人为选择的，而是从统计距离自然导出的——它是统计流形上唯一（在合理公理下）的内蕴度量。

9.1.8 自然梯度

普通梯度下降 $\theta \leftarrow \theta - \eta \nabla L$ 求解的是：在欧几里得度量下，固定步长时损失下降最快的方向。形式化地写：

$$\nabla L = \arg \min_{\|v\|_{\text{Euclid}}=1} \sum_i (\nabla L)_i \, v^i \tag{9.25}$$

这里 $\|v\|^2_{\text{Euclid}} = \sum_i (v^i)^2 = v^T I v$，度量矩阵是单位阵 I。

但我们已经知道，参数空间的正确度量不是 I 而是 Fisher 矩阵 F。自然梯度就是把度量从 I 换成 F：在 Fisher 度量下，固定步长时损失下降最快的方向：

$$\tilde{\nabla} L = \arg \min_{\|v\|_{\text{Fisher}}=1} \sum_i (\nabla L)_i \, v^i \tag{9.26}$$

其中 $\|v\|^2_{\text{Fisher}} = v^T F v$。

用 Lagrange 乘数法求解这个约束优化。构造 Lagrangian：

$$\mathcal{L}(v, \lambda) = \sum_i (\nabla L)_i \, v^i + \lambda (v^T F v - 1) \tag{9.27}$$

对 v 求导令其为零：

$$\nabla L + 2\lambda F v = 0 \quad \Longrightarrow \quad v = -\frac{1}{2\lambda} F^{-1} \nabla L \tag{9.28}$$

λ 由约束 $\|v\|_{\text{Fisher}} = 1$ 决定，只影响 v 的长度，不影响方向。因此自然梯度的方向为：

$$\boxed{\tilde{\nabla} L = F^{-1} \nabla L} \tag{9.29}$$

直觉上，F^{-1} 的作用是补偿各方向的灵敏度差异。Fisher 矩阵 F 大的方向（参数微小变化就引起分布剧变），F^{-1} 小，自然梯度自动缩小步长；F 小的方向（参数变化对分布影响甚微），F^{-1} 大，自然梯度自动放大步长。

参数化无关性 自然梯度的一个关键性质是它不依赖参数的选取方式。设 $\eta = \eta(\theta)$ 是一个重参数化，Jacobian 为 $J = \partial \eta / \partial \theta$。在新参数下：

$$F_\eta^{-1} \nabla_\eta L = J \, F_\theta^{-1} \nabla_\theta L = J \, \tilde{\nabla}_\theta L \tag{9.30}$$

右边正是切向量从 θ 坐标到 η 坐标的变换法则。换言之，自然梯度是流形上的真正切向量——它在坐标变换下协变地变换，而普通梯度 ∇L 做不到这一点。

高斯族上的例子 回到一维高斯族 $\theta = (\mu, \sigma^2)$，Fisher 矩阵为 $F = \text{diag}(1/\sigma^2,\ 1/(2\sigma^4))$，其逆为 $F^{-1} = \text{diag}(\sigma^2,\ 2\sigma^4)$。设欧几里得梯度为 $(g_\mu,\ g_{\sigma^2})^T$，则自然梯度为：

$$\tilde{\nabla} L = F^{-1} \nabla L = (\sigma^2 \, g_\mu,\ \ 2\sigma^4 \, g_{\sigma^2})^T \tag{9.31}$$

看 μ 方向：自然梯度的步长被乘以 σ^2。当 σ 很大时（分布很宽），μ 的微小变化对分布几乎没有影响（$F_{11} = 1/\sigma^2$ 很小），所以需要走更大的步才能产生同样的统计效果——σ^2 因子正好补偿了这一点。这与动机小节9.1.1中的直觉完全吻合。

9.1.9 与优化器的联系

自然梯度 $F^{-1}\nabla L$ 理论上最优，但完整的 Fisher 矩阵 F 是 $d \times d$ 的（d 为参数数量），现代网络 d 动辄上亿，存储 $O(d^2)$、求逆 $O(d^3)$，完全不可行。实际优化器可以理解为对 F^{-1} 的不同近似，在计算量和近似精度之间做取舍。

SGD：最粗糙的近似 SGD 直接用 ∇L 更新，等价于令 $F = I$——假设参数空间是平坦的，所有方向等权。这是最便宜的选择（$O(d)$），但也完全忽略了参数空间的几何结构。

Adam：对角近似 Adam 的核心思想可以从自然梯度的角度完整地理解。回顾自然梯度的更新规则：

$$\theta \leftarrow \theta - \eta\, F^{-1}\nabla L \tag{9.32}$$

写成逐参数的形式，如果只保留 F 的对角元（忽略参数间的耦合），第 i 个参数的更新为：

$$\theta^i \leftarrow \theta^i - \eta\, \frac{g_i}{F_{ii}}, \qquad g_i = \frac{\partial L}{\partial \theta^i}\,^{1} \tag{9.33}$$

其中 $F_{ii} = \mathbb{E}[s_i^2] = \mathbb{E}\left[\left(\frac{\partial \log p}{\partial \theta^i}\right)^2\right]$ 是 Fisher 矩阵的第 i 个对角元。问题在于我们无法精确计算 F_{ii}——它是一个关于数据分布的期望。

Adam 用经验估计来替代。在第 t 步，梯度 $g_{t,i}$ 是 s_i 的一个样本（一个 mini-batch 的估计），因此 $g_{t,i}^2$ 是 s_i^2 的一个样本。对这些样本做指数滑动平均：

$$v_{t,i} = \beta_2\, v_{t-1,i} + (1-\beta_2)\, g_{t,i}^2 \tag{9.34}$$

这就是 $\mathbb{E}[s_i^2] = F_{ii}$ 的在线估计。典型取值 $\beta_2 = 0.999$，即用最近约 1000 步的梯度平方来估计 Fisher 对角元。

如果严格按照对角自然梯度，更新应为 $\theta^i \leftarrow \theta^i - \eta\, g_i / v_{t,i}$。但 Adam 做了一个关键修改——除以 $\sqrt{v_{t,i}} + \epsilon$ 而不是 $v_{t,i}$：

$$\theta^i \leftarrow \theta^i - \eta\, \frac{\hat{m}_{t,i}}{\sqrt{\hat{v}_{t,i}} + \epsilon} \tag{9.35}$$

其中 $\hat{m}_{t,i}$ 和 $\hat{v}_{t,i}$ 是经过偏差修正的一阶和二阶矩估计。取平方根的效果是压缩动态范围：假设某个方向 $F_{ii} = 100$，另一个方向 $F_{ii} = 1$，直接除以 $v_{t,i}$ 两者步长相差 100 倍，除以 $\sqrt{v_{t,i}}$ 则只相差 10 倍。这让训练更稳定，不容易因个别方向步长过大而发散。ϵ（典型取值 10^{-8}）则防止分母为零。

此外，Adam 还维护梯度的一阶滑动平均 $m_{t,i} = \beta_1\, m_{t-1,i} + (1-\beta_1)\, g_{t,i}$ 作为动量项，这与 Fisher 近似无关，是为了平滑随机梯度的噪声。

Adagrad 和 RMSProp 的思路类似，区别在于如何累积历史信息：Adagrad 对 $g_{\tau,i}^2$ 从头到尾求和 $\sum_{\tau=1}^{t} g_{\tau,i}^2$，导致分母单调增长、后期步长趋于零；RMSProp 改用滑动平均解决了这个问题；Adam 在 RMSProp 基础上加入动量和偏差修正。三者都可以视为对角 Fisher 近似的不同变体。

[1] 此处 g_i 表示损失函数对第 i 个参数的偏导数，与黎曼度量 g_{ij} 无关。本节沿用优化文献的习惯记号，请勿混淆。

K-FAC：块 Kronecker 近似 K-FAC 走得更远，保留了 Fisher 矩阵的部分非对角结构。对于全连接层，权重梯度的 Fisher 矩阵可以近似为：

$$F_{\text{layer}} \approx A \otimes B \tag{9.36}$$

其中 A 是该层输入的协方差矩阵，B 是输出梯度的协方差矩阵。Kronecker 积的逆有简洁公式 $(A \otimes B)^{-1} = A^{-1} \otimes B^{-1}$，将求逆复杂度从 $O(m^3 n^3)$（m, n 为层的输入输出维度）降至 $O(m^3 + n^3)$。代价仍高于 Adam，但换来了更准确的曲率信息。

Table 9.1: 自然梯度视角下的优化器对比

优化器	对 F 的近似	更新中的分母	复杂度
SGD	$F = I$（无近似）	1	$O(d)$
Adagrad	对角，全历史累加	$\sqrt{\sum_\tau g_\tau^2} + \epsilon$	$O(d)$
RMSProp	对角，滑动平均	$\sqrt{v_t} + \epsilon$	$O(d)$
Adam	对角，滑动平均 + 动量	$\sqrt{v_t} + \epsilon$	$O(d)$
K-FAC	块 Kronecker $A \otimes B$	$(A \otimes B)^{-1}$	$O(m^3 + n^3)$
精确自然梯度	完整 F	F^{-1}	$O(d^3)$

汇总 从上到下，近似越精确，每步越贵但方向越好。实践中 Adam 凭借 $O(d)$ 复杂度和足够好的对角近似，成为最常用的选择。

Fisher 与 Hessian 的关系 对于以负对数似然为损失的情形，Fisher 矩阵等于 Hessian 的期望：$F = \mathbb{E}[-H]$，其中 $H_{ij} = \dfrac{\partial^2 L}{\partial \theta^i \partial \theta^j}$ 是损失函数的 Hessian 矩阵。

这让人联想到 Newton 法——经典优化中的二阶方法。Newton 法用 Hessian 的逆来修正梯度方向：

$$\theta \leftarrow \theta - \eta H^{-1} \nabla L \tag{9.37}$$

其动机和自然梯度相似：用二阶信息补偿各方向的曲率差异。但两者有关键区别。Hessian H 描述的是损失函数 $L(\theta)$ 这个标量场的局部曲率，它可能存在负特征值（例如在鞍点处），此时 $H^{-1}\nabla L$ 会指向损失增大的方向，导致优化发散。而 Fisher 矩阵 $F = \mathbb{E}[s_i s_j]$ 是平方的期望，天然正半定，$F^{-1}\nabla L$ 始终给出合理的下降方向。

换言之，自然梯度和 Newton 法都是 “用曲率信息修正梯度”，但自然梯度的曲率来自概率分布空间的几何（Fisher 度量），而 Newton 法的曲率来自损失曲面本身（Hessian）。前者的正定性提供了内在的稳定性保护。

9.2 流形优化

9.2.1 动机与通用框架

上一节讨论的自然梯度仍然是在无约束的参数空间 $\mathbb{R}^d$ 中做优化——参数可以自由取任何值。但很多场景下，参数本身带有结构约束。以下是几种常见的约束类型，实际问题中通常只涉及其中一种：

- 正交权重矩阵：$W^TW = I$（用于保持梯度范数、防止训练中梯度爆炸/消失）
- 对称正定矩阵：$P = P^T,\ P \succ 0$[2]（协方差矩阵、核矩阵）
- 归一化向量：$\|w\| = 1$（球面上的表示学习）
- 低秩矩阵：$\mathrm{rank}(W) \le r$（低秩适配、模型压缩）

这些约束集的共同特点是：它们都不是 $\mathbb{R}^d$ 的线性子空间，而是弯曲的流形。区别在哪里？线性子空间对加法封闭——取两个满足约束的点做线性组合，结果仍然满足约束，所以沿直线走不会离开。但上面的约束集不是这样。以球面 $\|w\| = 1$ 为例：取两个单位向量 w_1, w_2，它们的和 $w_1 + w_2$ 的模一般不等于 1，线性组合直接掉出了球面。正交矩阵也一样：W_1, W_2 都满足 $W^TW = I$，但 $W_1 + W_2$ 一般不正交。

这意味着普通梯度下降 $\theta \leftarrow \theta - \eta\nabla L$ 沿直线走一步，结果几乎必然离开流形[3]——比如 W 原本正交，减去一个梯度后 $W - \eta\nabla L$ 就不再满足 $W^TW = I$。

一个朴素的补救方法是：先走普通梯度步，再投影回流形。但投影本身可能很昂贵，而且反复投影会引入误差累积。流形优化提供了更系统的方案，其通用框架分为两步：

$$\text{欧氏梯度} \xrightarrow{\text{正交投影}} \text{黎曼梯度} \xrightarrow{\text{retraction}} \text{流形上的新点} \tag{9.38}$$

第一步解决“方向”问题：欧氏梯度 ∇L 在整个环境空间 $\mathbb{R}^d$ 中定义，通常不在流形的切空间内。将它正交投影到当前点的切空间 T_pM，得到黎曼梯度——这是在流形上能走的最速下降方向。

第二步解决“落点”问题：沿切空间走一步后，结果在切平面上而非流形上。Retraction 将切空间中的点拉回流形，保证更新后的参数仍满足约束。

接下来我们先精确定义 retraction，然后在三个具体流形（Stiefel 流形、球面、对称正定矩阵流形）上展示这个框架如何实例化。

9.2.2 Retraction

上一小节的框架中，第二步需要把切空间中的点拉回流形。精确的做法是沿**测地线**走——即使用指数映射 $\exp_p$。但测地线的计算往往很昂贵（例如在 Stiefel 流形上需要矩阵指数，复杂度 $O((n+p)^3)$）。Retraction 是指数映射的廉价替代品：它不要求精确沿测地线走，只要求方向对、起步对。

Definition 9.5 (Retraction)

流形 M 上一点 p 处的 retraction 是光滑映射 $R_p : T_pM \to M$，满足：

(1) $R_p(0) = p$：不走就留在原地。

(2) $dR_p(0) = \mathrm{id}_{T_pM}$：在原点处的导数是恒等映射，即走无穷小一步时，retraction 和指数映射

[2] $P \succ 0$ 表示 P 正定，即所有特征值严格大于零。这是矩阵序的标准记号，与标量的 $>$ 类比。

[3] 想象你站在地球表面（一个球面），往前迈一步。如果你沿地面走，你还在球面上。但如果你沿切线方向笔直走（不跟着地面弯），你就飞离地面了——走的是切线，不是曲面。

的结果一致。

条件 (2) 的含义值得展开。它说的是：对于很小的切向量 ξ，$R_p(\xi)$ 和 $\exp_p(\xi)$ 只差 $O(\|\xi\|^2)$ 的高阶项。换言之，retraction 是指数映射的一阶近似——方向完全正确，只是走的路径略有不同。步长 η 足够小时，这个差异可以忽略。

指数映射本身显然满足这两个条件，所以它是 retraction 的特例。但实际中我们往往能找到比指数映射便宜得多的 retraction。直觉上：$\exp_p$ 沿测地线精确地走一段弧，retraction 则先沿切平面走一段直线，再用某种简单操作（如归一化、QR 分解）把结果拉回流形。只要 “拉回” 的方式满足上面两个条件，优化的收敛性就有保证。

9.2.3 Stiefel 流形

Definition 9.6 (Stiefel 流形)

$n \times p$（$p \leq n$）的 Stiefel 流形定义为所有列正交矩阵的集合：

$$\mathrm{St}(n,p) = \{W \in \mathbb{R}^{n\times p} : W^T W = I_p\} \tag{9.39}$$

其维度为 $np - p(p+1)/2$。直觉上，W 有 np 个自由度，$W^T W = I_p$ 施加了 $p(p+1)/2$ 个独立约束（I_p 的上三角部分，包括对角线）。

两个重要的特例：$p = n$ 时 $W^T W = I_n$ 要求 W 是方阵且正交，$\mathrm{St}(n,n)$ 就是正交群 $O(n)$；$p = 1$ 时 W 退化为单位向量，$\mathrm{St}(n,1)$ 就是球面 S^{n-1}。

切空间 切向量 $Z \in T_W\mathrm{St}(n,p)$ 是从 W 出发、保持在流形上的无穷小位移。设 $W(t)$ 是流形上过 W 的一条曲线，$W(0) = W$，则 $W(t)^T W(t) = I_p$ 对所有 t 成立。对 t 求导并取 $t = 0$：

$$\dot{W}^T W + W^T \dot{W} = 0 \tag{9.40}$$

这说明 $W^T \dot{W}$ 是反对称矩阵。因此切空间为：

$$T_W\mathrm{St}(n,p) = \{Z \in \mathbb{R}^{n\times p} : W^T Z + Z^T W = 0\} \tag{9.41}$$

度量 Stiefel 流形作为 $\mathbb{R}^{n\times p}$ 的子流形，天然继承环境空间的内积。$\mathbb{R}^{n\times p}$ 上的标准内积是 Frobenius 内积，将它限制到切空间 $T_W\mathrm{St}(n,p)$ 上，就得到 Stiefel 流形的黎曼度量：

$$g_W(Z_1, Z_2) = \mathrm{tr}(Z_1^T Z_2), \qquad Z_1, Z_2 \in T_W\mathrm{St}(n,p) \tag{9.42}$$

这和球面 $S^2 \subset \mathbb{R}^3$ 的情形完全类比：球面上的度量就是 $\mathbb{R}^3$ 欧几里得内积限制在切平面上的结果，这里只是从三维推广到了矩阵空间。

Remark

$\mathrm{tr}(A^TB)$ 就是矩阵版的点积。将 $n \times p$ 矩阵 A 按列拉成 np 维向量 $\mathrm{vec}(A)$，则 $\mathrm{tr}(A^TB) = \mathrm{vec}(A)^T\mathrm{vec}(B) = \sum_{i,j} A_{ij}B_{ij}$，即逐元素相乘再求和。写成 tr 的形式只是为了在矩阵运算中更紧凑。

黎曼梯度 损失函数 $L(W)$ 的欧氏梯度 $\nabla L \in \mathbb{R}^{n\times p}$ 一般不在切空间内（不满足 $W^T(\nabla L)+(\nabla L)^TW = 0$）。需要将它正交投影到 $T_W\mathrm{St}(n,p)$，得到黎曼梯度：

$$\mathrm{grad}\, L = \nabla L - W\,\mathrm{sym}(W^T\nabla L), \qquad \mathrm{sym}(A) = \frac{A+A^T}{2} \tag{9.43}$$

可以验证结果确实在切空间内：

$$W^T\mathrm{grad}\, L + (\mathrm{grad}\, L)^TW = W^T\nabla L + (\nabla L)^TW - 2\,\mathrm{sym}(W^T\nabla L) = 0 \tag{9.44}$$

其中第一项 $W^T\nabla L + (\nabla L)^TW$ 恰好等于 $2\,\mathrm{sym}(W^T\nabla L)$，两者相消。

Retraction 有了黎曼梯度 $\xi = \mathrm{grad}\, L$，下一步是沿 ξ 方向走一步并回到流形上。Stiefel 流形上常用两种 retraction：

QR retraction：对 $W - \eta\xi$ 做 QR 分解。QR 分解将任意列满秩矩阵 $A \in \mathbb{R}^{n\times p}$ 分解为 $A = QR$，其中 $Q \in \mathbb{R}^{n\times p}$ 列正交（$Q^TQ = I_p$），$R \in \mathbb{R}^{p\times p}$ 上三角且对角元为正。取其中的正交因子 Q：

$$W_{\text{new}} = \mathrm{qf}(W - \eta\xi) \tag{9.45}$$

其本质是 Gram–Schmidt 正交化：依次处理 A 的每一列，将其减去在前面各列上的投影分量，再归一化为单位向量。结果 Q 的各列互相正交且模为 1，自动落在 Stiefel 流形上。Q 和原矩阵 A 张成相同的列空间，但列向量本身会有所不同——正交化过程改变了各列的方向以满足 $Q^TQ = I_p$。复杂度 $O(np^2)$。

极分解 retraction：任意列满秩矩阵 $A \in \mathbb{R}^{n\times p}$ 都有唯一的极分解 $A = UP$，其中 $U \in \mathrm{St}(n,p)$ 列正交，$P \in \mathbb{R}^{p\times p}$ 对称正定。其中 U 就是 Frobenius 范数意义下离 A 最近的正交矩阵：

$$U = \arg\min_{Q^TQ=I_p} \|Q - A\|_F \tag{9.46}$$

P 可以显式写出：$A^TA = P^TU^TUP = P^2$，所以 $P = (A^TA)^{1/2}$，从而 $U = AP^{-1} = A(A^TA)^{-1/2}$。将 $A = W - \eta\xi$ 代入：

$$W_{\text{new}} = (W - \eta\xi)\big((W - \eta\xi)^T(W - \eta\xi)\big)^{-1/2} \tag{9.47}$$

和 QR retraction 对比：QR 通过 Gram–Schmidt 正交化拉回流形，极分解通过找最近正交矩阵拉回流形。两者在 η 很小时只差 $O(\eta^2)$，都是合法的 retraction。极分解的几何意义更清晰（最近点投影），但需要计算矩阵平方根的逆 $(A^TA)^{-1/2}$，通常比 QR 分解更贵。

9.2.4 球面 S^{n-1}

球面 $S^{n-1} = \{w \in \mathbb{R}^n : \|w\| = 1\}$ 是 Stiefel 流形 $\mathrm{St}(n, 1)$ 的特例（$p = 1$ 的列正交 “矩阵” 就是单位向量）。由于结构最简单，它是理解流形优化各个步骤的最佳例子。

切空间 和 Stiefel 流形的推导完全类比：$w(t)^T w(t) = 1$ 对 t 求导得 $2\,w^T \dot{w} = 0$，因此切向量必须与 w 正交：

$$T_w S^{n-1} = \{z \in \mathbb{R}^n : w^T z = 0\} \tag{9.48}$$

几何上，这就是过 w 点与球面相切的超平面。

黎曼梯度 欧氏梯度 $\nabla L \in \mathbb{R}^n$ 一般不与 w 正交，需要投影到切空间。将 ∇L 分解为沿 w 方向的分量和垂直于 w 的分量，丢掉前者：

$$\operatorname{grad} L = \nabla L - (w^T \nabla L)\, w \tag{9.49}$$

这就是 ∇L 在 $T_w S^{n-1}$ 上的正交投影。可以验证：$w^T \operatorname{grad} L = w^T \nabla L - (w^T \nabla L)(w^T w) = 0$，确实在切空间内。

指数映射 球面上的测地线就是大圆弧。从 w 出发沿切向量 $\xi \in T_w S^{n-1}$ 走测地线，走的弧长为 $\|\xi\|$：

$$\exp_w(\xi) = \cos(\|\xi\|)\, w + \sin(\|\xi\|)\, \frac{\xi}{\|\xi\|} \tag{9.50}$$

这和二维单位圆上的运动 $(\cos\alpha, \sin\alpha)$ 是一回事，只是推广到了 n 维。$\cos(\|\xi\|)\, w$ 是沿原方向的收缩，$\sin(\|\xi\|)\, \xi/\|\xi\|$ 是沿切方向的偏移，合起来刚好在球面上走了一段弧。

归一化 retraction 指数映射需要算三角函数，归一化 retraction 提供了更简单的替代——沿切方向走一步后直接归一化：

$$R_w(\xi) = \frac{w + \xi}{\|w + \xi\|} \tag{9.51}$$

直觉上：$w + \xi$ 偏离了球面（模不再为 1），除以自身的模就把它拉回球面。这是球面上最自然的 retraction——一维情形下就是 “算完再归一化”。

验证 retraction 的两个条件。条件 (1)：$R_w(0) = w/\|w\| = w$，不走留原地。条件 (2)：当 ξ 很小时，$\|w+\xi\| = \sqrt{1 + 2w^T\xi + \|\xi\|^2}$。由于 $\xi \in T_w S^{n-1}$ 意味着 $w^T\xi = 0$，所以 $\|w+\xi\| = \sqrt{1 + \|\xi\|^2} = 1 + O(\|\xi\|^2)$，因此：

$$R_w(\xi) = \frac{w + \xi}{1 + O(\|\xi\|^2)} = (w + \xi)(1 + O(\|\xi\|^2)) = w + \xi + O(\|\xi\|^2) \tag{9.52}$$

在 $\xi = 0$ 处对 ξ 求导，得到恒等映射——和指数映射的一阶行为一致。

9.2.5 对称正定矩阵流形

对称正定矩阵流形定义为：

$$\mathrm{Sym}^+(n) = \{P \in \mathbb{R}^{n\times n} : P = P^T,\ P \succ 0\} \tag{9.53}$$

这是所有对称矩阵空间 $\mathrm{Sym}(n)$ 中正定的那部分，构成一个开子集（正定性是开条件——微小扰动不会破坏正定性）。协方差矩阵、核矩阵、扩散张量等都住在这个流形上。

切空间 由于 $\mathrm{Sym}^+(n)$ 是 $\mathrm{Sym}(n)$ 的开子集，切空间就是全体对称矩阵：

$$T_P\mathrm{Sym}^+(n) = \mathrm{Sym}(n) = \{Z \in \mathbb{R}^{n\times n} : Z = Z^T\}^4 \tag{9.54}$$

这和球面、Stiefel 流形不同——那些流形的切空间是受约束的子空间，而 $\mathrm{Sym}^+(n)$ 的切空间没有额外约束，任何对称方向都可以走。原因在于正定性是开条件：从正定矩阵出发沿任意对称方向走足够小的一步，结果仍然正定。

度量 最简单的选择是继承 Frobenius 内积 $\mathrm{tr}(Z_1^T Z_2)$，但这忽略了一个重要的事实：靠近边界（接近奇异）的矩阵应该比远离边界的矩阵更“敏感”——P 的特征值很小时，同样大小的扰动更容易把它推出正定锥。

仿射不变度量通过 P^{-1} 来补偿这一点：

$$g_P(Z_1, Z_2) = \mathrm{tr}(P^{-1}Z_1P^{-1}Z_2) \tag{9.55}$$

当 P 的特征值很小时，P^{-1} 很大，度量放大了该方向上的距离——走同样的欧氏步长，在度量意义下走了很远，于是自动缩小步长。这和 Fisher 度量的思想完全一致：在敏感方向上放大度量，让优化自适应地小心行走。

“仿射不变”是指：对任意可逆矩阵 A，映射 $P \mapsto APA^T$ 保持度量不变。这意味着度量不依赖于坐标系的选取（对基做线性变换不改变几何结构）。

测地线 在仿射不变度量下，从 P 出发沿切向量 $Z \in \mathrm{Sym}(n)$ 走的测地线为：

$$\gamma(t) = P^{1/2}\exp\left(tP^{-1/2}ZP^{-1/2}\right)P^{1/2} \tag{9.56}$$

其中 exp 是矩阵指数。这个公式的结构可以这样理解：$P^{-1/2}ZP^{-1/2}$ 先把切向量 Z 变换到 I 处的切空间（对称矩阵），矩阵指数 $\exp(\cdot)$ 在 I 处沿测地线走（I 处的测地线就是矩阵指数），最后 $P^{1/2}(\cdot)P^{1/2}$ 把结果搬回 P 附近。

关键性质：$\gamma(t)$ 在每个 t 处都是正定的。这是因为矩阵指数的结果总是正定的（$\exp(S) \succ 0$ 对任意对称矩阵 S），而 $P^{1/2}(\cdot)P^{1/2}$ 保持正定性。换言之，选对度量后，测地线自动留在流形内——不需要额外的 retraction 拉回操作。这是 $\mathrm{Sym}^+(n)$ 相比 Stiefel 流形的一个优美之处。

9.2.6 向量传输

前面介绍的流形优化框架——计算黎曼梯度然后 retraction——只描述了单步更新，还没有涉及动量。在欧氏空间 $\mathbb{R}^d$ 中，给任何优化器加动量是平凡的——所有梯度住在同一个空间里，直接做加权和即可。但在流形上，这件事不再平凡：每个点的切空间不同，上一步的动量和当前步的梯度无法直接相加。向量传输就是为了解决这个问题。

[4]对于 $\mathrm{Sym}^+(n)$，任何对称方向的无穷小位移都不会离开正定锥（特征值不会瞬间从正变为零），所以所有对称方向都在切空间里。

动量回顾 动量方法通过积累历史梯度来平滑更新方向：

$$m_t = \beta\, m_{t-1} + g_t, \qquad \theta \leftarrow \theta - \eta\, m_t \tag{9.57}$$

其中 β（典型取值 0.9）控制对历史的 “记忆” 程度。m_t 是所有历史梯度的指数加权和，效果是抑制随机噪声、在一致方向上加速。

流形上的困难 在 $\mathbb{R}^d$ 中，m_{t-1} 和 g_t 住在同一个空间里，可以直接相加。但在流形上，W_{t-1} 处的动量 $m_{t-1} \in T_{W_{t-1}}\mathrm{St}$ 和 W_t 处的梯度 $\xi_t \in T_{W_t}\mathrm{St}$ 在不同的切空间里，无法直接相加。精确的解决方案是沿测地线做平行移动，但计算昂贵。

向量传输：平行移动的廉价替代 向量传输放松精确性要求，只需将向量近似地搬到新切空间。对 Stiefel 流形，最简单的做法是直接投影到 W' 处的切空间：

$$\mathcal{T}_{W\to W'}(\xi) = \xi - W'\,\mathrm{sym}(W'^T\xi) \tag{9.58}$$

这和黎曼梯度的投影公式结构一模一样——都是减去不在切空间内的分量。区别在于：黎曼梯度投影的是欧氏梯度 ∇L（从环境空间到切空间），向量传输投影的是上一步的动量 m_{t-1}（从旧切空间到新切空间）。

带动量的流形优化 将以上各步组合，就得到流形上的动量 SGD：

(1) 在 W_t 处计算黎曼梯度 $\xi_t = \mathrm{grad}\, L$

(2) 将上一步动量搬到当前切空间：$m'_{t-1} = \mathcal{T}_{W_{t-1}\to W_t}(m_{t-1})$

(3) 更新动量：$m_t = \beta\, m'_{t-1} + \xi_t$

(4) 沿动量方向走一步并拉回流形：$W_{t+1} = \mathrm{qf}(W_t - \eta\, m_t)$

和欧氏空间的动量 SGD 相比，唯一多出来的是第 (2) 步的搬运和第 (4) 步的 retraction——前者处理切空间的变化，后者保证结果留在流形上。[5]

9.2.7 公式汇总

表 9.2将三个流形上的切空间、黎曼梯度、retraction 和向量传输并列，方便对照查阅。可以看到它们的结构高度统一：都是 “投影 → 走一步 → 拉回” 的框架，区别仅在于每一步的具体实现。

9.3 生成模型的几何视角

[5]标准 Adam 在欧氏空间 $\mathbb{R}^d$ 中工作，所有点的切空间相同，不需要第 (2) 步的向量传输；参数空间平坦，也不需要第 (4) 步的 retraction。Bécigneul & Ganea (2019, arXiv:1810.00760) 将 Adam 推广到黎曼流形上（Riemannian Adam），在每步中加入了向量传输和 retraction，使得 Adam 的自适应步长机制能够在流形约束下使用。

Table 9.2: 流形优化公式汇总表

	切空间	黎曼梯度	Retraction
$\mathrm{St}(n,p)$	$W^TZ+Z^TW=0$	$\nabla L - W\,\mathrm{sym}(W^T\nabla L)$	QR 分解
S^{n-1}	$w^Tz=0$	$\nabla L-(w^T\nabla L)w$	归一化
$\mathrm{Sym}^+(n)$	对称矩阵	本身在切空间	矩阵指数

9.3.1 总览

生成模型的核心任务是：学习一个从简单分布（如标准高斯 $\mathcal{N}(0,I)$）到复杂数据分布 p_{data} 的映射。训练数据（图像、文本、音频）看似杂乱，但实际上集中在高维空间的一个低维结构上。生成模型要做的就是找到这个结构，并能从中采样出新的数据点。

不同的生成模型选择了不同的数学工具来实现这个映射，而这些工具恰好对应不同的几何构造：

- **Normalizing flows**：构造一个可逆的光滑变换（微分同胚）f，直接将简单分布 “推” 成数据分布。核心工具是 Jacobian 行列式和体积形式的拉回。
- **连续 Normalizing flows / 神经 ODE**：不直接构造 f，而是定义一个速度场 $v(x,t)$，让 ODE 的流自动生成微分同胚。核心工具是散度和李导数。
- **扩散模型**：先用随机过程将数据逐步加噪为高斯，再学习逆向过程将高斯还原为数据。核心工具是 score 函数（向量场）和随机微分方程。
- **Flow matching**：学习一个时变向量场，用确定性 ODE 将高斯连续地变形为数据分布。训练时只需回归局部速度，比 Normalizing flows 更简单。

这些模型表面上看起来很不同（有的用可逆变换，有的用随机过程，有的用 ODE），但从微分几何的角度看，它们都在做同一件事：在概率分布的空间中，用不同的几何工具构造从简单分布到目标分布的路径。接下来我们逐一展开，看每种模型如何与具体的几何结构对应。

9.3.2 Normalizing Flows

基本思路 Normalizing flows 的策略最直接：构造一个可逆的光滑变换 $f:\mathbb{R}^n\to\mathbb{R}^n$，将简单分布 $z\sim\mathcal{N}(0,I)$ 直接映射为数据 $x=f(z)$。可逆性保证了 f 是微分同胚——既光滑又有光滑的逆，不会 “折叠” 空间。采样时从高斯抽 z，算 $f(z)$ 即可；密度估计需要反过来算 $f^{-1}(x)$。

变量替换公式 f 将 z 变为 x，概率不会凭空产生或消失，总概率必须守恒：$p_X(x)\,dV_x=p_Z(z)\,dV_z$。问题在于 f 可能拉伸或压缩空间的不同区域，使得同样大小的体积元 dV_z 被映射后变大或变小。这个体积变化率正是 Jacobian 行列式 $|\det(\partial f/\partial z)|$。由此得到变量替换公式：

$$p_X(x)=p_Z(f^{-1}(x))\left|\det\frac{\partial f}{\partial z}\right|^{-1}_{z=f^{-1}(x)} \tag{9.59}$$

右边第一项 $p_Z(f^{-1}(x))$ 是 x 在潜空间中对应点的高斯密度，第二项 $|\det(\partial f/\partial z)|^{-1}$ 修正了体积的缩放——f 在某处将空间放大 k 倍，密度就除以 k（概率被 “稀释” 了）。

微分形式视角 变量替换公式有一个优雅的微分形式表述。概率密度本质上是一个体积形式：$\omega_Z = p_Z(z)\,dz^1 \wedge \cdots \wedge dz^n$。$f$ 的拉回自动产生 Jacobian 行列式：

$$f^*(dx^1 \wedge \cdots \wedge dx^n) = \det\left(\frac{\partial f}{\partial z}\right) dz^1 \wedge \cdots \wedge dz^n \tag{9.60}$$

这说明 Jacobian 行列式不是人为引入的——它是微分形式在坐标变换下的内在性质。概率密度作为体积形式，其积分（总概率为 1）不依赖坐标选取，概率守恒是几何上自动保证的。

训练与计算 训练目标是最大化数据的对数似然，将变量替换公式取对数：

$$\log p_X(x) = \log p_Z(f^{-1}(x)) - \log\left|\det \frac{\partial f}{\partial z}\right|_{z=f^{-1}(x)} \tag{9.61}$$

第一项容易算（高斯密度），瓶颈在第二项：一般矩阵的行列式需要 $O(n^3)$。这驱动了架构设计——RealNVP、Glow 等模型精心设计 f 使得 Jacobian 为三角矩阵，行列式退化为对角元之积，复杂度降为 $O(n)$。代价是对 f 的表达能力施加了限制。

9.3.3 连续 Normalizing Flows 与神经 ODE

Normalizing flows 需要精心设计 f 的架构来保证可逆性和高效计算行列式，这限制了模型的表达能力。连续 Normalizing flows 换了一个思路：不直接构造 f，而是定义一个速度场，让流自动生成微分同胚。

从离散到连续 普通 Normalizing flows 将变换 f 写成有限步的复合 $f = f_K \circ \cdots \circ f_1$，每步是一个简单的可逆变换。连续版本将步数推到极限：用一个 ODE 描述连续变换

$$\frac{dx(t)}{dt} = v(x(t), t; \theta), \qquad x(0) = z \sim p_Z, \quad x(1) = x \tag{9.62}$$

其中 v 是一个神经网络参数化的速度场。从 $t = 0$（高斯噪声）到 $t = 1$（数据），$x(t)$ 沿速度场连续流动。ODE 的流映射 $\phi : x(0) \mapsto x(1)$ 自动是微分同胚——这是 ODE 理论保证的，不需要对 v 施加任何架构限制。

对数密度的演化 沿着流，概率密度如何变化？答案由以下 ODE 给出：

$$\frac{d \log p(x(t), t)}{dt} = -\mathrm{tr}\left(\frac{\partial v}{\partial x}\right) \tag{9.63}$$

右边 $\mathrm{tr}(\partial v/\partial x)$ 是速度场 Jacobian 的迹，即散度 $\mathrm{div}\, v$。这比 Normalizing flows 中的完整行列式 $\det(\partial f/\partial z)$ 便宜得多——迹是 $O(n)$，行列式是 $O(n^3)$。实践中还可以用 Hutchinson 估计进一步降低成本：$\mathrm{tr}(A) = \mathbb{E}_\epsilon[\epsilon^T A \epsilon]$，其中 ϵ 是随机向量，一次向量–Jacobian 乘积就够了。

Remark

上述密度演化公式的推导基于两个事实：(1) 速度场 v 以散度 $\mathrm{div}\, v$ 的速率膨胀体积元，即 $\frac{d}{dt}\delta V = (\mathrm{div}\, v)\,\delta V$；(2) 跟随流运动的概率总量守恒，即 $\frac{d}{dt}(p\,\delta V) = 0$。将两者结合，对 $p\,\delta V$ 用乘法求

导法则展开并消去 δV，得到 $\frac{dp}{dt} = -p \operatorname{div} v$，两边除以 p 即得 $\frac{d \log p}{dt} = -\operatorname{div} v$。最后一步用到 $\operatorname{div} v = \sum_i \frac{\partial v^i}{\partial x^i}$，而 $\frac{\partial v}{\partial x}$ 是速度场的 Jacobian 矩阵，其对角元之和就是迹，所以 $\operatorname{div} v = \operatorname{tr}(\frac{\partial v}{\partial x})$。写成迹的形式是因为在实现中 Jacobian 矩阵是神经网络输出对输入的导数，用迹来表达对计算更直接。

几何含义 这个密度演化公式有清晰的几何解读。$\operatorname{div} v = \operatorname{tr}(\partial v / \partial x)$ 度量的是速度场在某点的体积膨胀率：$\operatorname{div} v > 0$ 表示流在该处将空间撑开（体积增大），密度相应降低；$\operatorname{div} v < 0$ 表示流在该处压缩空间，密度升高。

用微分形式的语言，这就是李导数公式 $\mathcal{L}_v \omega = (\operatorname{div} v)\, \omega$，其中 ω 是概率体积形式。速度场对体积形式的李导数恰好等于散度乘以体积形式本身——概率密度的变化率完全由速度场的散度决定。

9.3.4 扩散模型

Normalizing flows 和连续 NF 都是构造确定性的映射将高斯变为数据。扩散模型换了一个策略：先用随机过程将数据逐步加噪为高斯（前向过程），再学习逆向的去噪过程将高斯还原为数据。

Remark (SDE 与 ODE 的统一视角)

本节沿用 Song et al. (2021, arXiv:2011.13456) 的经典表述，从前向加噪 SDE 出发，通过时间反演得到逆向 SDE。但也可以从另一个方向理解：先有 Flow matching 的 ODE，再通过 Fokker-Planck 方程构造具有相同概率演化的 SDE。这一视角将 ODE 和 SDE 统一为同一框架的不同实例。详见本书第3章。

前向过程：加噪 从一个数据点 $x_0 \sim p_{\text{data}}$ 出发，按以下随机微分方程（SDE）逐步加入噪声：

$$dx = -\frac{1}{2}\beta(t)\, x\, dt + \sqrt{\beta(t)}\, dW_t \tag{9.64}$$

其中 $\beta(t) > 0$ 控制加噪速度，dW_t 是标准布朗运动的增量。第一项 $-\frac{1}{2}\beta(t)\, x\, dt$ 将 x 向原点拉（收缩），第二项 $\sqrt{\beta(t)}\, dW_t$ 注入随机噪声。两者的联合效果是：随着 t 增大，数据的结构被逐渐抹去，$x(t)$ 的分布趋向标准高斯 $\mathcal{N}(0, I)$。这个过程不需要学习——$\beta(t)$ 是预先设定的。

逆向过程：去噪 Anderson (1982) 的关键结果：任何前向 SDE 都有一个对应的逆向 SDE，可以将噪声还原为数据：

$$dx = \left[-\frac{1}{2}\beta(t)\, x - \beta(t)\, \nabla_x \log p_t(x)\right] dt + \sqrt{\beta(t)}\, d\bar{W}_t \tag{9.65}$$

其中 $d\bar{W}_t$ 是逆向布朗运动。和前向过程相比，唯一多出来的项是 $-\beta(t)\, \nabla_x \log p_t(x)$。这个 $\nabla_x \log p_t(x)$ 就是 **score function**——t 时刻概率密度 $p_t(x)$ 的对数梯度。

Score function 的几何含义 Score function $\nabla_x \log p_t(x)$ 在每个点 x 给出一个向量，指向概率密度增长最快的方向。在低密度区域（数据稀疏处），score 指向高密度区域（数据集中处）。逆向过程沿 score 方向流动，就是不断把噪声“拉”回数据所在的高密度区域。

注意 score function 和前面信息几何中的 Fisher score 在数学形式上相同（都是对数概率的梯度），但方向不同：Fisher score $\nabla_\theta \log p(x|\theta)$ 是对**参数** θ 求梯度，度量参数变化对分布的影响；data score $\nabla_x \log p_t(x)$ 是对**数据** x 求梯度，指出密度增长的方向。

训练：denoising score matching 逆向 SDE 中的 score function $\nabla_x \log p_t(x)$ 是未知的（它依赖于 p_t，而 p_t 正是我们想建模的分布）。扩散模型用一个神经网络 $s_\theta(x,t)$ 来近似它，训练目标是：

$$\mathcal{L}(\theta) = \mathbb{E}_{t,x_0,\epsilon}\left[\|s_\theta(x_t,t) - \nabla_{x_t} \log p(x_t|x_0)\|^2\right] \tag{9.66}$$

巧妙之处在于：虽然 $p_t(x)$ 未知，但**条件**分布 $p(x_t|x_0)$ 是已知的——给定起点 x_0，前向 SDE 的转移核就是一个高斯分布，其均值和方差可以解析写出。因此训练只需要从数据中采样 x_0，加噪得到 x_t，然后让网络预测已知的条件 score $\nabla_{x_t} \log p(x_t|x_0)$。不需要知道 $p_t(x)$ 本身。

9.3.5 Flow Matching

Flow matching 可以看作连续 Normalizing flows 的简化训练方案。连续 NF 需要在训练时沿 ODE 积分来计算对数似然（通过散度的累积），计算昂贵。Flow matching 绕开了这个问题：不去最大化似然，而是直接回归速度场。

具体来说，目标仍然是学习一个时变速度场 $v_\theta(x,t)$，使得 ODE $dx/dt = v_\theta(x,t)$ 将 $x(0) \sim \mathcal{N}(0,I)$ 映射为 $x(1) \sim p_{\text{data}}$。训练时，给定数据点 x_1 和从高斯采样的 x_0，可以构造一条连接两者的条件路径（最简单的选择是线性插值 $x_t = (1-t)x_0 + tx_1$），其条件速度场 $u_t(x|x_1)$ 有解析表达式。训练损失只需让网络 v_θ 回归这个条件速度场即可——不需要 ODE 积分，不需要计算散度或行列式，一个简单的回归损失就够了。

Flow matching 的训练简洁性使其成为近年来生成模型的主流方法之一。关于其完整的数学推导（条件概率路径的构造、条件与边际速度场的关系、与 score matching 的等价性等），详见本书第1章。

9.3.6 黎曼流形上的生成模型

前面介绍的生成模型都假设数据住在欧几里得空间 $\mathbb{R}^n$ 中。但很多实际数据天然具有流形结构：分子构型住在旋转群 $SO(3)$ 上，地球上的气象数据住在球面 S^2 上，周期性信号（如角度、相位）住在环面 T^n 上，蛋白质的二面角住在高维环面上。对这些数据直接套用欧几里得空间的生成模型会遇到根本性困难。

欧几里得方法的失效 以球面 S^2 为例。标准扩散模型的前向过程在 $\mathbb{R}^n$ 中加高斯噪声，但高斯噪声会把点推离球面——加噪后的 x_t 不再在 S^2 上。Normalizing flows 需要微分同胚 $f:\mathbb{R}^n \to \mathbb{R}^n$，但球面和 $\mathbb{R}^n$ 在拓扑上不同胚（球面是紧致的），根本无法建立这样的映射。线性插值 $x_t = (1-t)x_0 + tx_1$ 在 Flow matching 中很自然，但两个球面上的点的线性组合一般不在球面上。

黎曼扩散模型 De Bortoli et al. (2022, arXiv:2202.02763) 提出了黎曼扩散模型，将扩散模型的每个组件替换为流形上的对应物：

- 前向过程：高斯噪声替换为流形上的布朗运动（由 Laplace–Beltrami 算子 Δ_M 驱动），噪声沿流形扩散而非飞出流形。

- Score function：$\nabla_x \log p_t(x)$ 替换为黎曼梯度 $\operatorname{grad} \log p_t(x)$，它是切空间中的向量，指向流形上概率密度增长最快的方向。
- 采样步骤：欧几里得空间中的 $x \leftarrow x + \eta \nabla \log p_t$ 替换为指数映射 $x \leftarrow \exp_x(\eta \operatorname{grad} \log p_t)$，保证更新后的点仍在流形上。

这正是前两个阶段建立的微分几何工具汇聚的地方：度量定义了 Laplace–Beltrami 算子，联络定义了平行移动（在流形上传播 score），指数映射将切空间的更新拉回流形，曲率影响布朗运动的局部行为。可以说，黎曼扩散模型是整个微分几何工具箱在生成建模中的完整应用。

9.3.7 模型对照

下表将五种生成模型的核心策略、几何结构和用到的微分几何工具并列对照。可以看到，从上到下模型越来越灵活（从显式可逆变换到随机过程），用到的几何工具也越来越丰富（从 Jacobian 行列式到完整的黎曼几何工具箱）。

Table 9.3: 生成模型几何结构与工具对照表

模型	核心策略	几何结构	微分几何工具
Normalizing flows	构造可逆变换	微分同胚	Jacobian 行列式、体积形式拉回
连续 NF / 神经 ODE	定义速度场	速度场的流	散度、李导数
扩散模型	加噪再去噪	随机过程	Score（向量场）、SDE
Flow matching	回归条件速度场	时变向量场	ODE 流映射
黎曼扩散	流形上扩散	流形布朗运动	度量、联络、Laplace–Beltrami

前四种模型都在欧几里得空间 $\mathbb{R}^n$ 中工作，最后一种将整个框架推广到黎曼流形上，是微分几何工具在生成建模中最完整的体现。

9.4 几何深度学习

9.4.1 核心思想

CNN 为什么用卷积？GNN 为什么用消息传递？Transformer 为什么用注意力？这些架构看似迥异，但 Bronstein et al. (2021, arXiv:2104.13478) 指出它们有统一的数学根源：都是数据对称性的产物。

核心论点是：如果你知道数据具有某种对称性（图像可以平移、图的节点可以重新编号、点云可以旋转），那么处理这些数据的神经网络应该尊重这种对称性——输入做了对称变换后，输出要相应地变换。这个要求叫**等变性**，它直接决定了网络的架构。卷积、消息传递、注意力这些操作之所以有效，是因为它们恰好满足数据对称性所要求的等变性约束——架构的形式由数学决定，工程设计只是重新发现了这一点。

描述对称性的语言是群和群作用。

9.4.2 群与群作用

Definition 9.7 (群)

集合 G 配二元运算 $\cdot : G \times G \to G$，若满足以下三个条件，则称 $(G, \cdot)$ 为一个**群**：

(1) **结合律**：$(g_1 \cdot g_2) \cdot g_3 = g_1 \cdot (g_2 \cdot g_3)$，$\forall g_1, g_2, g_3 \in G$。

(2) **单位元**：存在 $e \in G$，使得 $e \cdot g = g \cdot e = g$，$\forall g \in G$。

(3) **逆元**：对每个 $g \in G$，存在 $g^{-1} \in G$，使得 $g \cdot g^{-1} = g^{-1} \cdot g = e$。

群描述的是 “所有对称变换的集合”。例如：所有平移构成平移群，所有旋转构成旋转群，n 个元素的所有排列构成置换群 S_n。群的运算就是 “先做一个变换再做另一个”，逆元对应 “撤销一个变换”。

Definition 9.8 (群作用)

映射 $\rho : G \times \mathcal{X} \to \mathcal{X}$，记 $g \cdot x = \rho(g, x)$，若满足以下两个条件，则称 ρ 为群 G 在集合 $\mathcal{X}$ 上的（左）**作用**：

(1) **恒等性**：$e \cdot x = x$，$\forall x \in \mathcal{X}$。什么都不做等于不变。

(2) **相容性**：$(g_1 \cdot g_2) \cdot x = g_1 \cdot (g_2 \cdot x)$，$\forall g_1, g_2 \in G$，$x \in \mathcal{X}$。先做 g_2 再做 g_1，等于直接做 $g_1 g_2$。

群作用描述 “对称变换如何具体地施加在数据上”。同一个群可以用不同的方式作用在不同的数据上。深度学习中常见的群及其作用：

- 平移群 $(\mathbb{R}^2, +)$ 作用在图像上：$(g \cdot f)(x, y) = f(x - a, y - b)$，将图像整体平移。实际 CNN 中使用离散版本 $\mathbb{Z}^2$。
- 置换群 S_n 作用在图的节点特征上：$(\sigma \cdot X)_i = X_{\sigma^{-1}(i)}$，重新编号节点。
- 旋转群 $SO(3)$ 作用在三维点云上：$(R \cdot x) = Rx$，旋转所有点。

9.4.3 不变性与等变性

有了群作用，就可以精确定义 “尊重对称性” 的含义。

Definition 9.9 (不变性)

若映射 $f : \mathcal{X} \to \mathcal{Y}$ 满足 $f(g \cdot x) = f(x)$，$\forall g \in G$，则称 f 关于群 G 是**不变**的。输入做对称变换后，输出完全不变。

例：图像分类器应该是平移不变的——把猫的图片向右移 10 个像素，分类结果不应改变。

Definition 9.10 (等变性)

若映射 $f : \mathcal{X} \to \mathcal{Y}$ 满足 $f(g \cdot_{\mathcal{X}} x) = g \cdot_{\mathcal{Y}} f(x)$，$\forall g \in G$，则称 f 关于群 G 是**等变**的。输入做对称变换后，输出做相应的变换。

例：目标检测器应该是平移等变的——把图片向右移 10 个像素，检测到的边界框也应向右移 10 个像素。

不变性其实是等变性的特例：当 G 在输出空间上的作用是平凡的（$g \cdot_{\mathcal{Y}} y = y$），等变性就退化为不变性。实际网络中，中间层保持等变（保留对称信息），最后通过池化变为不变（丢弃位置信息，只保留“是什么”）。

9.4.4 CNN = 平移等变网络

卷积的定义：$(f * \kappa)(x) = \int f(y)\,\kappa(x-y)\,dy$。我们来验证它是平移等变的。设平移算子 T_a 将函数平移 a，即 $(T_a f)(x) = f(x-a)$。

Proof. [平移等变性的验证] 计算 $(T_a f) * \kappa$：

$$(T_a f * \kappa)(x) = \int f(y-a)\,\kappa(x-y)\,dy \tag{9.67}$$

换元 $y' = y - a$：

$$= \int f(y')\,\kappa(x-a-y')\,dy' = (f*\kappa)(x-a) = T_a(f*\kappa)(x) \tag{9.68}$$

因此 $T_a(f*\kappa) = (T_a f) * \kappa$：先平移再卷积 = 先卷积再平移。 ■

反过来的结论同样成立，而且更有意思：在温和的假设下，线性的平移等变映射**一定是**卷积。换言之，如果你要求网络的每一层是线性的且平移等变的，数学上唯一的选择就是卷积。权重共享（同一个卷积核扫过所有位置）不是工程上的巧妙设计，而是平移等变性的必然推论。

9.4.5 GNN = 置换等变网络

图没有“位置”的概念——节点的编号是任意的，重新编号不应改变网络的输出。这对应置换群 S_n 的对称性。

GNN 的消息传递框架：

$$h_i^{(l+1)} = \phi\left(h_i^{(l)}, \bigoplus_{j\in\mathcal{N}(i)} \psi(h_i^{(l)}, h_j^{(l)}, e_{ij})\right) \tag{9.69}$$

其中 $h_i^{(l)}$ 是第 l 层节点 i 的特征，$\mathcal{N}(i)$ 是 i 的邻居，ψ 计算每条边的“消息”，$\bigoplus$ 是置换不变的聚合操作（求和、平均或取最大值），ϕ 更新节点特征。

置换等变性由 $\bigoplus$ 保证：邻居的编号重新排列后，求和/平均/最大值不变，因此每个节点收到的聚合消息不变，整层的输出只是跟着节点编号重新排列——这正是置换等变的定义。

9.4.6 Transformer = 置换等变（无位置编码时）

Transformer 的输入是一个 token 序列，可以表示为矩阵 $X \in \mathbb{R}^{n\times d}$，每行是一个 token 的 d 维特征向量。对行做置换 $X \to P_\sigma X$（P_σ 是置换矩阵）对应重新排列 token 的顺序。我们来验证：不带位置编码的 self-attention 是置换等变的。

线性变换 Self-attention 首先将输入 X 分别乘以三个权重矩阵，得到查询（Query）、键（Key）、值（Value）：

$$Q = XW_Q, \qquad K = XW_K, \qquad V = XW_V \tag{9.70}$$

其中 $W_Q, W_K, W_V \in \mathbb{R}^{d\times d_k}$ 是可学习的权重矩阵。这一步在 Transformer 文献中常称为线性投影（linear projection），因为它将每个 token 的 d 维特征映射到 d_k 维的查询/键/值空间。Q 的第 i 行 $Q_i = X_i W_Q$ 只依赖第 i 个 token 的特征 X_i，行与行之间互不影响。因此先置换行再做矩阵乘法，等价于先做矩阵乘法再置换行：

$$Q' = (P_\sigma X)W_Q = P_\sigma(XW_Q) = P_\sigma Q, \qquad K' = P_\sigma K, \qquad V' = P_\sigma V \tag{9.71}$$

注意力矩阵 注意力分数矩阵为 $A = QK^T \in \mathbb{R}^{n\times n}$。置换后：

$$A' = Q'K'^T = (P_\sigma Q)(P_\sigma K)^T = P_\sigma Q K^T P_\sigma^T = P_\sigma A P_\sigma^T \tag{9.72}$$

$P_\sigma A P_\sigma^T$ 的含义是：A 的行和列同时做置换 σ。这很自然——如果 token i 和 token j 之间的注意力分数是 A_{ij}，重新编号后，同样的两个 token 之间的注意力分数不变，只是在矩阵中的位置跟着编号移动了。

Softmax Softmax 逐行操作：对 A' 的第 i 行做 softmax，等价于对 A 的第 $\sigma^{-1}(i)$ 行做 softmax（因为 P_σ 把第 $\sigma^{-1}(i)$ 行搬到了第 i 行）。Softmax 只看行内各元素的相对大小，不依赖行的编号，因此：

$$\mathrm{softmax}(A') = P_\sigma\, \mathrm{softmax}(A)\, P_\sigma^T \tag{9.73}$$

置换结构完整地穿过了 softmax。

输出 记 $S = \mathrm{softmax}(A)$，则 attention 的输出为 $\mathrm{Attn}(X) = SV$。置换后：

$$\mathrm{Attn}' = S'V' = (P_\sigma S P_\sigma^T)(P_\sigma V) = P_\sigma S \underbrace{P_\sigma^T P_\sigma}_{=I} V = P_\sigma SV = P_\sigma\, \mathrm{Attn}(X) \tag{9.74}$$

其中 $P_\sigma^T P_\sigma = I$ 是因为置换矩阵是正交矩阵。最终结果：输入行做置换 P_σ，输出行做同样的置换 P_σ——这正是置换等变的定义。

位置编码打破对称性 加入位置编码后，每个 token 的表示变为 $X + E$，其中 $E \in \mathbb{R}^{n\times d}$ 的第 i 行编码了位置 i 的信息。置换 token 顺序后，$P_\sigma X + E \neq P_\sigma(X + E)$——token 移到了新位置，但位置编码没有跟着动。这有意打破了置换对称性：语言有顺序，“狗咬人” 和 “人咬狗” 意思不同，需要位置信息来区分。

9.4.7 统一框架

以上所有架构可以纳入一个统一的表格：

Table 9.4: 几何深度学习统一框架表

域 Ω	对称群 G	等变映射	架构
网格 $\mathbb{Z}^2$	平移 $\mathbb{Z}^2$	卷积	CNN
图 (V, E)	置换 S_n	消息传递	GNN
集合	置换 S_n	注意力	Transformer
球面 S^2	旋转 $SO(3)$	球面卷积	球面 CNN
齐次空间 G/H	群 G	群卷积	群等变网络
流形 M	规范群	规范等变卷积	规范等变网络

从上到下，数据的域从规则（网格）到不规则（图、集合），再到连续弯曲（球面、一般流形），对称群也从简单（平移、置换）到复杂（旋转、规范群）。但核心逻辑始终如一：

$$\text{对称性} \;\rightarrow\; \text{等变约束} \;\rightarrow\; \text{架构被数学唯一确定} \tag{9.75}$$

对称性本身决定了架构必须是什么样——架构是对称性的推论，而非反过来。

9.4.8 与黎曼几何的联系

表格最后两行涉及弯曲流形，这正是黎曼几何与几何深度学习的交汇点。

在平坦空间（网格 $\mathbb{Z}^2$）上，卷积核可以在所有位置共享——把核从一个位置“平移”到另一个位置，含义不变。这是因为平坦空间有全局平移对称性。

但在弯曲流形上，没有全局平移。把一个卷积核从流形上的一点“搬”到另一点，需要回答：沿哪条路径搬？搬的过程中核怎么旋转？这些问题的答案正是前面建立的微分几何工具：

- 指数映射将邻域局部平坦化，使得卷积可以在切空间中定义。
- 平行移动沿测地线将卷积核从一点搬到另一点，保持核与流形的相对朝向不变。
- 但平行移动依赖路径——沿不同路径搬运同一个向量，到达同一点时结果可能不同。这正是曲率的体现，也是“规范”的来源：需要选择每点切空间的一组基（规范），卷积核的定义依赖于这个选择，网络必须对规范的选取方式保持等变，这就是规范等变网络的核心思想。

9.5 总结：从数学到深度学习的完整链条

经过三个阶段的铺垫，我们现在可以回顾整条链条。第一阶段建立了微分几何的基础语言：流形、切空间、黎曼度量。第二阶段在此基础上发展了核心工具：Christoffel 符号、协变导数、测地线、曲率。第三阶段将这些工具应用于深度学习的四个方向。下图将数学工具（左列）和深度学习应用（右列）的对应关系完整呈现：

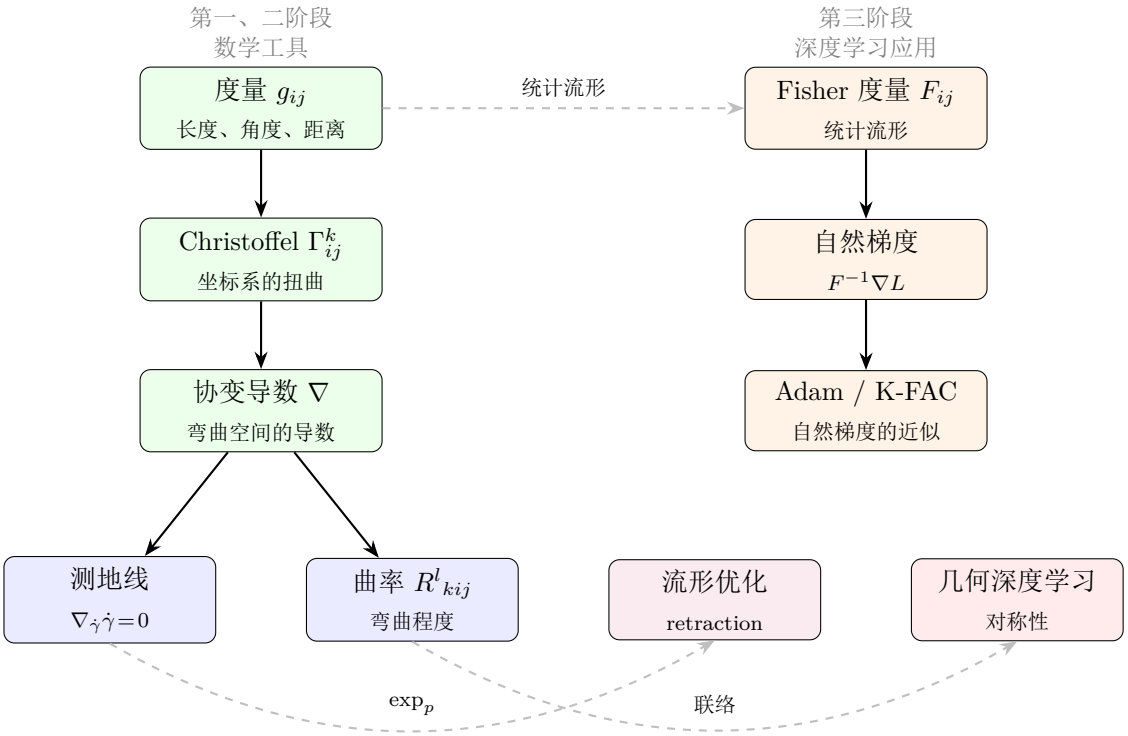

Figure 9.1: 从数学到深度学习的完整链条

左列是三个阶段逐步建立的微分几何核心链条：度量决定了 Christoffel 符号，Christoffel 符号定义了协变导数，协变导数向下分出测地线（加速度为零的曲线）和曲率（弯曲程度的度量）。右列是本阶段讨论的四个深度学习应用，每个应用从左列对应的数学工具自然流出：

- **度量 → 信息几何**：将黎曼度量实例化为 Fisher 信息矩阵，参数空间成为统计流形。Fisher 度量下的最速下降方向就是自然梯度 $F^{-1}\nabla L$，Adam 和 K-FAC 是它的不同精度的近似。
- **测地线 → 流形优化**：指数映射沿测地线走一步，retraction 是它的廉价替代。当参数被约束在 Stiefel 流形、球面或正定锥上时，流形优化用切空间投影和 retraction 取代普通梯度步，保证参数始终满足约束。
- **曲率 → 几何深度学习**：弯曲流形上没有全局平移，定义卷积需要联络来做平行移动。曲率导致平行移动依赖路径，由此引出规范等变网络的核心思想。
- **微分形式 → 生成模型**：体积形式的拉回给出 Normalizing flows 的变量替换公式，散度（李导数）给出连续 NF 的密度演化方程，score 函数驱动扩散模型的逆向过程。

整个大厦建在度量 g_{ij} 这一个基础上——选定度量，联络、测地线、曲率、体积形式全部随之确定，深度学习中的信息几何、流形优化、几何深度学习和生成模型也随之各就其位。